1º Trabalho Computacional: Classificadores KNN, MDC e MAXCO no Dataset Vertebral Column

Lucas José Lemos Braz - 587388

[1]Programa de Pós-Graduação em Engenharia de Teleinformática (PPGETI)
Universidade Federal do Ceará (UFC)

lucas.jlb19@alu.ufc.br

1. Introdução

Este relatório apresenta os resultados do primeiro Trabalho Computacional da disciplina de Reconhecimento de Padrões. O objetivo principal é implementar e avaliar o desempenho de diferentes algoritmos de classificação supervisionada: K-Vizinhos Mais Próximos (*K-Nearest Neighbors* - KNN), Classificador de Distância Mínima ao Centróide (*Minimum Distance to Centroid* - MDC) e o Classificador de Máxima Correlação de Cosseno (*Maximum Cosine Correlation* - MAXCO).

A análise é conduzida sobre o conjunto de dados *Vertebral Column*, que contém medições biomecânicas da coluna vertebral de pacientes, classificados em três categorias: Hérnia de Disco, Normal e Espondilolistese. O trabalho explora diferentes métricas de distância para o KNN (através da distância de Minkowski com variados ordens), versões robustas do MDC utilizando a mediana, e a influência da proporção de dados de treinamento no desempenho final dos modelos.

A estrutura deste relatório compreende a descrição da metodologia empregada, incluindo o pré-processamento e o protocolo experimental, seguida da apresentação e discussão dos resultados obtidos através de múltiplas rodadas de treinamento e teste.

2. Metodologia

2.1. Conjunto de Dados

O dataset *Vertebral Column* (ID 212 no repositório UCI) é composto por 310 amostras e 6 atributos biomecânicos: incidência pélvica, inclinação pélvica, ângulo de lordose lombar, inclinação sacral, raio pélvico e grau de espondilolistese. As amostras estão distribuídas em três classes: Hérnia (*Hernia*), Normal e Espondilolistese (*Spondylolisthesis*).

2.2. Algoritmos Implementados

Foram implementados em Python (utilizando apenas *NumPy* para a lógica dos modelos) os seguintes classificadores:

- **KNN**: Classifica uma nova amostra com base na classe majoritária entre seus K vizinhos mais próximos. Foi fixado $K = 1$ e explorada a distância de Minkowski de ordens $m \in \{0.5, 0.67, 1.0, 1.5, 2.0, 2.5\}$, onde $m = 1$ corresponde à distância de Manhattan e $m = 2$ à distância Euclidiana.
- **MDC**: Calcula o centróide de cada classe no espaço de atributos. Uma nova amostra é atribuída à classe cujo centróide está a uma distância Euclidiana mínima.

- **MDC Robusto**: Uma variação do MDC onde o centróide é definido pela mediana dos atributos de cada classe, visando mitigar o efeito de *outliers*.
- **MAXCO**: Atribui a amostra à classe cujo centróide apresenta a maior correlação de cosseno com a amostra, após a centralização de ambos os vetores pela média.

2.3. Protocolo Experimental

Para garantir a robustez estatística dos resultados, adotou-se o seguinte procedimento:

1. Os dados foram submetidos a uma codificação de rótulos (*Label Encoding*) para as classes.
2. Foram avaliadas cinco proporções de divisão treino/teste: 80/20, 70/30, 50/50, 30/70 e 20/80.
3. Para cada divisão, foram realizadas 100 execuções independentes utilizando amostragem aleatória estratificada (*stratified shuffle split*).
4. Em cada rodada, os modelos foram treinados e testados, registrando-se a acurácia, o tempo de treinamento e o tempo médio de teste por amostra.
5. Foram calculadas a média e o desvio padrão das métricas ao final das 100 rodadas.

2.4. Análise Estatística e Visual

Realizou-se uma análise exploratória para avaliar a distribuição das variáveis condicionadas às classes e a normalidade dos atributos via teste de Shapiro-Wilk e gráficos Q-Q. Adicionalmente, calculou-se a distância Euclidiana entre os centróides das classes para avaliar a separabilidade linear teórica do problema.

3. Resultados

3.1. Análise Exploratória e de Normalidade

A análise das densidades condicionais (Figura 1) revelou sobreposições significativas entre as classes Hérnia e Normal para a maioria dos atributos, enquanto a classe Espondilolistese apresentou-se mais separada, especialmente no atributo *degree_spondylolisthesis*.

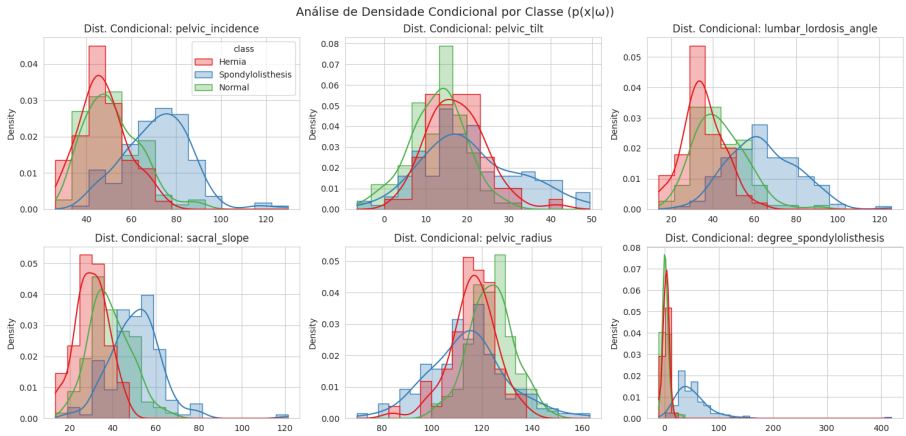

Figura 1. Densidades condicionais dos atributos por classe (p(x—w)).

O teste de Shapiro-Wilk (Tabela 1) e os gráficos Q-Q (Figura 2) confirmaram que nenhum dos atributos segue uma distribuição normal ($\alpha = 0.05$), o que justifica a exploração de métodos não paramétricos como o KNN e a versão robusta do MDC.

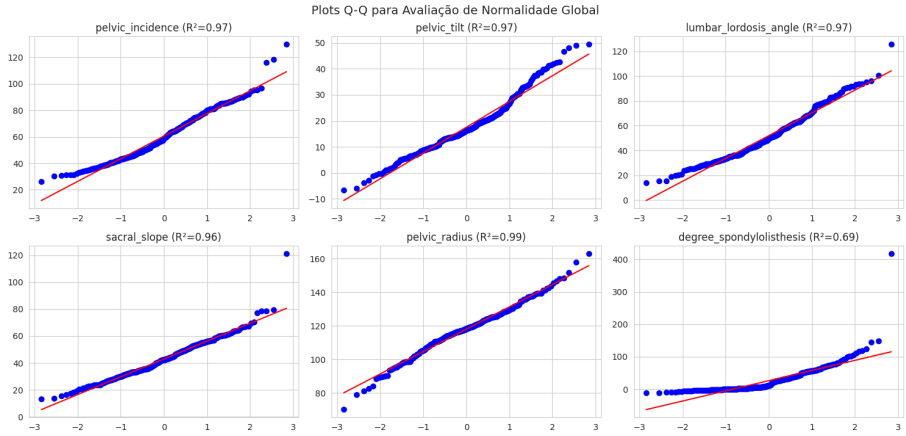

Figura 2. Gráficos Q-Q para avaliação de normalidade global.

Tabela 1. Resultados do teste de normalidade Shapiro-Wilk.

Atributo	Estatística W	p-valor	H0 (Normal)
pelvic_incidence	0.971	7.13×10^{-6}	Rejeitada
pelvic_tilt	0.966	1.32×10^{-6}	Rejeitada
lumbar_lordosis_angle	0.972	9.22×10^{-6}	Rejeitada
sacral_slope	0.964	5.88×10^{-7}	Rejeitada
pelvic_radius	0.989	1.66×10^{-2}	Rejeitada
degree_spondylolisthesis	0.697	2.90×10^{-23}	Rejeitada

3.2. Desempenho Geral dos Classificadores

A Tabela 2 apresenta o desempenho médio para a divisão de 80% treino e 20% teste ao longo de 100 execuções. O KNN com ordem de Minkowski $m = 2.0$ (Euclidiana) e $m = 1.5$ obtiveram os melhores desempenhos médios nesta configuração.

Tabela 2. Acurácia média e desvio padrão para a divisão 80/20 (100 rodadas).

Classificador	Acurácia Média	Desvio Padrão	Tempo Treino (ms)
KNN ($m = 2.00$)	0.8210	0.0422	0.0023
KNN ($m = 1.50$)	0.8161	0.0416	0.0023
MDC Robusto	0.7861	0.0450	0.1398
MDC	0.7629	0.0464	0.0680
MAXCO	0.7221	0.0600	0.0570

Observa-se que o MDC Robusto (mediana) superou o MDC tradicional (média), sugerindo que a presença de distribuições não-normais e possíveis *outliers* afeta negativamente o cálculo dos centróides via média. O MAXCO apresentou o menor desempenho, indicando que a correlação de cosseno pode não ser a métrica mais adequada para este espaço de atributos biomecânicos.

3.3. Efeito da Proporção de Treinamento

A acurácia média tendeu a aumentar conforme maior volume de dados foi disponibilizado para treinamento, como demonstrado na Tabela 3 e na Figura 3. O KNN manteve-se consistentemente como o melhor classificador em todas as divisões.

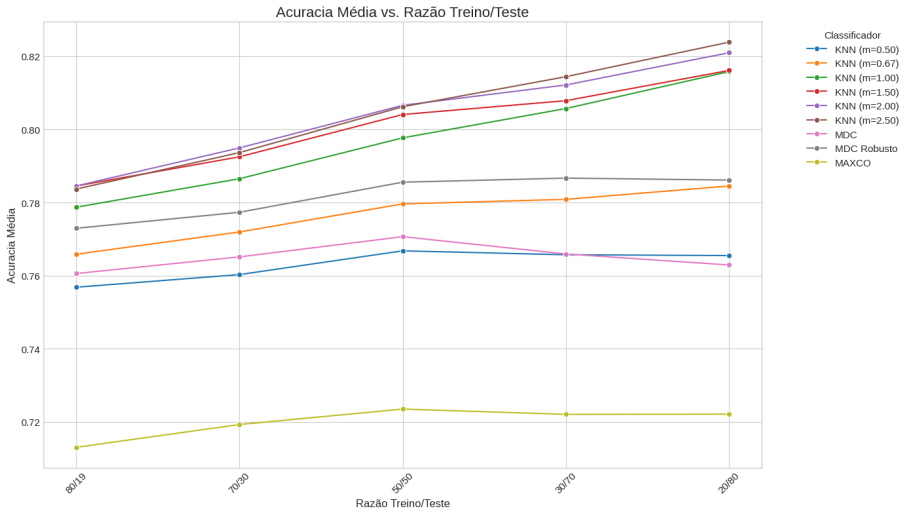

Figura 3. Acurácia média vs. razão de treinamento para os diferentes classificadores.

Tabela 3. Comparativo da acurácia média por porcentagem de treinamento.

Classificador	20% Treino	30% Treino	50% Treino	70% Treino	80% Treino
KNN ($m = 2.00$)	0.7845	0.7949	0.8065	0.8121	0.8210
KNN ($m = 1.00$)	0.7787	0.7864	0.7976	0.8056	0.8158
MDC Robusto	0.7729	0.7773	0.7855	0.7866	0.7861
MAXCO	0.7130	0.7192	0.7234	0.7220	0.7221

3.4. Matriz de Confusão e Relatório de Classificação

Para a melhor rodada do KNN na divisão 80/20, obteve-se acurácia superior a 0.90 em alguns casos. A análise das matrizes de confusão (Figura 4) revelou que o modelo é altamente eficaz na identificação de Espondilolistese, mas apresenta uma confusão sistemática entre as classes Hérnia e Normal, que possuem centróides mais próximos no espaço de atributos.

4. Conclusão

Este trabalho permitiu avaliar a eficácia de diferentes classificadores supervisionados no conjunto de dados biomecânicos *Vertebral Column*. Os resultados experimentais demonstraram que o algoritmo KNN (K=1) apresentou o desempenho superior de forma consistente, especialmente quando utilizado com a distância Euclidiana ($m = 2$) ou ordens superiores de Minkowski.

A análise do classificador MDC revelou que a utilização da mediana (MDC Robusto) em vez da média para a definição dos centróides resulta em ganhos de acurácia,

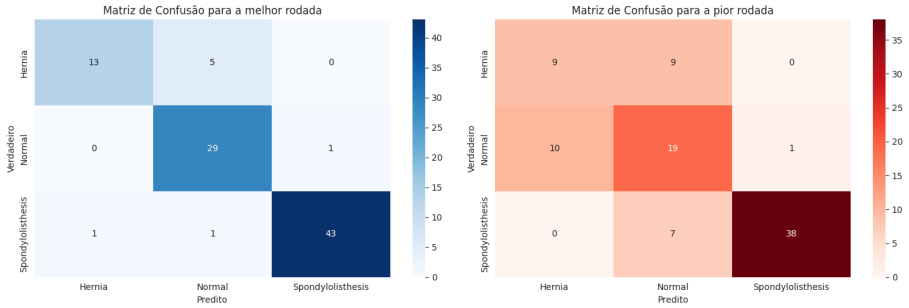

Figura 4. Matrizes de confusão para o melhor e pior caso do classificador KNN.

o que é coerente com a observação de que os atributos do dataset não seguem uma distribuição normal e apresentam assimetrias. O classificador MAXCO, embora teoricamente interessante, não se mostrou competitivo para este problema específico, sugerindo que a direção dos vetores de atributos não é tão informativa quanto a sua magnitude e posição relativa para distinguir as patologias da coluna.

Observou-se também que o desempenho de todos os modelos é sensível à quantidade de dados disponíveis para treinamento, com a acurácia média subindo gradualmente de 20% para 80% de treinamento. Por fim, a confusão entre as classes Hérnia e Normal destaca a complexidade biomecânica destas condições, indicando que novos atributos ou técnicas de engenharia de características poderiam ser explorados em trabalhos futuros para melhorar a separabilidade nestas regiões do espaço de atributos.