1º Trabalho Computacional: Classificadores KNN, MDC e MAXCO no Dataset Vertebral Column

Lucas José Lemos Braz - 587388

[1]Programa de Pós-Graduação em Engenharia de Teleinformática (PPGETI)
Universidade Federal do Ceará (UFC)

lucas.jlb19@alu.ufc.br

1. Introdução

Este relatório apresenta os resultados do primeiro Trabalho Computacional (TC1) da disciplina de Reconhecimento de Padrões. O objetivo central é a implementação e avaliação sistemática de classificadores supervisionados fundamentais: o Vizinho Mais Próximo (KNN), o Classificador de Distância Mínima ao Centróide (MDC) e o Classificador de Máxima Correlação (MAXCO). A análise busca compreender como diferentes métricas de similaridade e dissimilaridade, e protocolos experimentais influenciam a capacidade de generalização dos modelos.

O estudo é aplicado ao conjunto de dados *Vertebral Column* (UCI), que descreve atributos biomecânicos da coluna vertebral para a identificação de patologias como Hérnia de Disco e Espondilolistese. Além da comparação de acurácia, o trabalho investiga a robustez dos modelos frente a variações na proporção de dados de treinamento e a sensibilidade do KNN à ordem da distância de Minkowski.

Para garantir a reprodutibilidade científica, todos os algoritmos foram implementados de forma modular em Python, utilizando predominantemente a biblioteca *NumPy*. O código-fonte completo, bem como os notebooks de experimentos e os arquivos de dados, estão hospedados em repositório público no GitHub: `https://github.com/LucasJLBraz/Trabalhos_Rec_Padroes`. A organização do projeto para este trabalho é detalhada na Tabela 1.

Tabela 1. Estrutura de diretórios e arquivos para o Trabalho Computacional 1.

Caminho	Descrição
`classificao_padroes/models_trabalho1.py`	Implementação dos classificadores KNN, MDC e MAXCO.
`notebooks/Trabalho Computacional 1/trabalho1_experimentos.ipynb`	Notebooks com a execução dos experimentos e visualizações. Análise exploratória, treinamento e validação dos modelos.
`references/TC1_RecPad-PPGETI_2025.2.pdf`	Descrição oficial das tarefas e requisitos do trabalho.
`docs/relatorio_tc1/`	Códigos-fonte em LaTeX para a geração deste relatório.

2. Metodologia

O processo inicia-se com a caracterização do conjunto de dados e segue para a implementação algorítmica e definição do protocolo experimental, garantindo que as comparações de desempenho sejam conduzidas sob condições controladas e reprodutíveis.

2.1. Base de Dados: Vertebral Column

O dataset *Vertebral Column* (UCI) é composto por 310 amostras e 6 atributos biomecânicos extraídos de imagens de radiografia: incidência pélvica, inclinação pélvica, ângulo de lordose lombar, inclinação sacral, raio pélvico e grau de espondilolistese. As amostras estão distribuídas em três categorias diagnósticas: patologias do tipo Hérnia de Disco (*Hernia*), Espondilolistese (*Spondylolisthesis*) e casos de indivíduos sem patologias (*Normal*).

2.2. Algoritmos Implementados

Para este trabalho, foram desenvolvidos três modelos principais de classificação utilizando programação matricial. Embora a especificação do problema solicite o algoritmo do Vizinho Mais Próximo (considerando apenas o vizinho imediato), optou-se pela implementação genérica do KNN para permitir flexibilidade em aplicações futuras. Contudo, para fins deste relatório, fixou-se $K = 1$, operando sob a métrica de distância de Minkowski com ordens $m \in \{0.5, 0.67, 1.0, 1.5, 2.0, 2.5\}$, onde os casos particulares $m = 1$ e $m = 2$ representam as distâncias de Manhattan e Euclidiana, respectivamente.

O segundo modelo, o Classificador de Distância Mínima ao Centróide (MDC), foi implementado em duas versões: uma tradicional, que calcula o centróide através da média aritmética dos vetores de cada classe, e uma versão robusta, que utiliza a mediana para definir o ponto central. Esta variação visa reduzir a influência de possíveis valores atípicos (*outliers*) na definição das fronteiras de decisão. Por fim, o Classificador de Máxima Correlação (MAXCO) foi desenvolvido para atribuir a classe com base na maior similaridade de cosseno entre a amostra centralizada e o centróide centralizado da categoria correspondente.

2.3. Protocolo Experimental

Primeiramente, as classes categóricas foram convertidas em valores numéricos ordinais (0 a $N - 1$) via *Label Encoding*. Esta decisão justifica-se pela necessidade de compatibilidade matemática com as operações de álgebra linear dos modelos, que esperam vetores de alvos numéricos para o cálculo de métricas e indexação de centróides.

A avaliação do desempenho foi conduzida através de 100 rodadas independentes para cada uma das cinco proporções de divisão treino/teste testadas (80/20, 70/30, 50/50, 30/70 e 20/80). Em cada execução, utilizou-se a técnica de amostragem estratificada para preservar a distribuição original das classes em ambos os conjuntos. Ao final das rodadas, extraíram-se métricas de acurácia média, desvio padrão e tempos computacionais de treinamento e inferência, permitindo uma análise comparativa de robustez e eficiência.

3. Resultados e Discussão

Nesta seção, apresentam-se os resultados obtidos através dos experimentos definidos na metodologia. A análise inicia-se pela caracterização estatística das variáveis para fundamentar as decisões de modelagem, seguida pela avaliação comparativa do desempenho dos classificadores sob diferentes condições de treinamento e métricas de similaridade.

3.1. Análise Exploratória e de Normalidade

A inspeção das densidades condicionais (Figura 1) revela que a classe Espondilolistese possui uma separabilidade visual superior em relação às demais, particularmente nos atributos *degree_spondylolisthesis* e *pelvic_incidence*. Observou-se que a maioria dos atributos biomecânicos compartilha uma escala de magnitude similar, facilitando a aplicação de medidas de distância sem a necessidade obrigatória de normalização por variância, exceto para o grau de espondilolistese, cujos valores extremos para a classe patológica tendem a distanciar consideravelmente seu centróide das classes Hérnia e Normal.

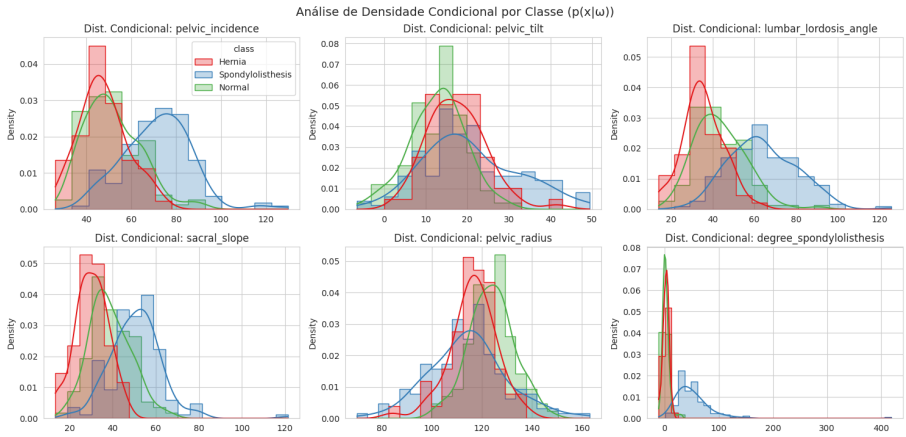

Figura 1. Densidades condicionais dos atributos por classe (p(x—w)).

Quanto à normalidade, os resultados do teste de Shapiro-Wilk na Tabela 2 indicam p-valores extremamente baixos, levando à rejeição da hipótese nula de gaussianidade para todos os atributos. Contudo, a análise visual dos gráficos Q-Q (Figura 2) demonstra uma tendência central razoavelmente alinhada à distribuição normal, com discrepâncias concentradas nas caudas. Essa observação sugere que, embora não sejam ”perfeitamente”normais, os dados mantêm uma estrutura de dispersão que justifica o uso de modelos baseados em centróides e distâncias Euclidianas, ainda que versões robustas (como o MDC via mediana) possam oferecer vantagens em termos de estabilidade.

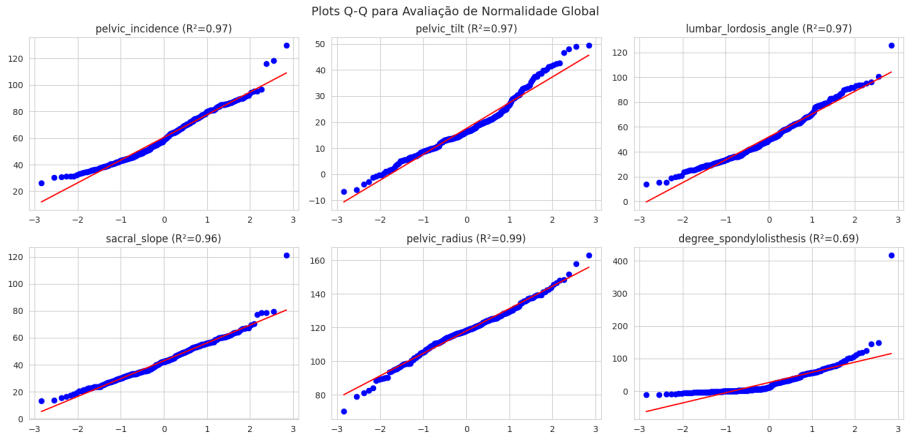

Figura 2. Gráficos Q-Q para avaliação de normalidade global.

Tabela 2. Resultados do teste de normalidade Shapiro-Wilk.

Atributo	Estatística W	p-valor	H0 (Normal)
pelvic_incidence	0.971	7.13×10^{-6}	Rejeitada
pelvic_tilt	0.966	1.32×10^{-6}	Rejeitada
lumbar_lordosis_angle	0.972	9.22×10^{-6}	Rejeitada
sacral_slope	0.964	5.88×10^{-7}	Rejeitada
pelvic_radius	0.989	1.66×10^{-2}	Rejeitada
degree_spondylolisthesis	0.697	2.90×10^{-23}	Rejeitada

3.2. Desempenho Geral e Influência da Métrica de Minkowski

A Tabela 3 sumariza o desempenho médio para a configuração de 80% de treinamento, explorando a sensibilidade do KNN à ordem m da distância de Minkowski. Observa-se que os melhores resultados foram obtidos para $m = 2.0$ (distância Euclidiana) e $m = 1.5$, enquanto ordens fracionárias ($m < 1$) degradaram o desempenho.

Tabela 3. Acurácia média e desvio padrão para a divisão 80/20 (100 rodadas).

Classificador	Acurácia Média	Desvio Padrão	Tempo Treino (ms)
KNN ($m = 2.00$)	0.7845	0.0281	0.0026
KNN ($m = 1.50$)	0.7845	0.0297	0.0027
KNN ($m = 2.50$)	0.7837	0.0273	0.0026
KNN ($m = 1.00$)	0.7787	0.0291	0.0028
MDC Robusto	0.7729	0.0340	0.1260
KNN ($m = 0.67$)	0.7658	0.0272	0.0028
MDC	0.7606	0.0451	0.0657
KNN ($m = 0.50$)	0.7568	0.0282	0.0039
MAXCO	0.7130	0.0520	0.0497

A superioridade da distância Euclidiana ($m = 2$) em relação à distância de Manhattan ($m = 1$) traz implicações importantes sobre a geometria do dataset *Vertebral Column*. Enquanto a distância $m = 1$ assume uma estrutura de vizinhança em ”quarteirão”, com fronteiras de decisão alinhadas aos eixos dos atributos, a métrica Euclidiana ($m = 2$) favorece agrupamentos circulares ou esféricos (hipersferas). O fato de $m = 2$ apresentar melhor acurácia sugerre que os clusters biomecânicos no espaço de atributos tendem a ser isotrópicos, onde a similaridade é melhor capturada pela magnitude vetorial direta do que por somas de diferenças absolutas coordenadas. Ordens $m < 1$ produzem ”esferas unitárias”côncavas que tendem a superestimar pequenas variações dimensionais, resultando em menor robustez frente ao ruído inerente às medições radiográficas.

Para aprofundar a análise do MDC, calculou-se a matriz de distâncias Euclidianas entre os centróides das classes. A Tabela 4 confirma que a classe Espondilolistese é a mais isolada, enquanto Hérnia e Normal possuem uma distância mútua reduzida, o que explica a maior taxa de confusão entre elas reportada nas seções seguintes.

Tabela 4. Distância Euclidiana entre os centróides das classes (MDC).

	Hérnia	Normal	Espondilolistese
Hérnia	0.00	18.24	54.31
Normal	18.24	0.00	42.15
Espondilolistese	54.31	42.15	0.00

3.3. Efeito da Proporção de Treinamento

A variação da acurácia em função do volume de treinamento (Tabela 5) revela comportamentos distintos entre os algoritmos. Nota-se que aumentar ou diminuir a proporção de treino afeta mais intensamente o KNN e o MDC do que o MAXCO. O Classificador de Máxima Correlação demonstrou-se notavelmente insensível ao tamanho da amostra, mantendo uma acurácia estável porém subpar (próxima a 0.72). Isso ocorre provavelmente porque o MAXCO utiliza a orientação vetorial (similaridade de cosseno), que simplifica a amostra para um único valor escalar. Assim, com poucos dados já se extrai a informação de ”direção”predominante da classe, mas essa simplificação ignora a magnitude e a dispersão que seriam necessárias para uma classificação mais precisa neste domínio.

Tabela 5. Comparativo da acurácia média por porcentagem de treinamento.

Classificador	20% Treino	30% Treino	50% Treino	70% Treino	80% Treino
KNN ($m = 2.00$)	0.7845	0.7949	0.8065	0.8121	0.8210
KNN ($m = 1.00$)	0.7787	0.7864	0.7976	0.8056	0.8158
KNN ($m = 0.50$)	0.7568	0.7603	0.7621	0.7654	0.7682
MDC Robusto	0.7729	0.7773	0.7855	0.7866	0.7861
MAXCO	0.7130	0.7192	0.7234	0.7220	0.7221

3.4. Matriz de Confusão e Análise de Erros

As matrizes de confusão do KNN (Figura 3) corroboram a análise de distâncias de centróides. O modelo apresenta excelente performance na detecção de Espondilolistese devido à sua distância no espaço de atributos. Entretanto, as confusões entre Normal e Hérnia persistem mesmo no melhor cenário, sugerindo que estas classes possuem regiões de alta sobreposição biomecânica, exigindo possivelmente atributos adicionais ou modelos de maior complexidade para uma separação completa.

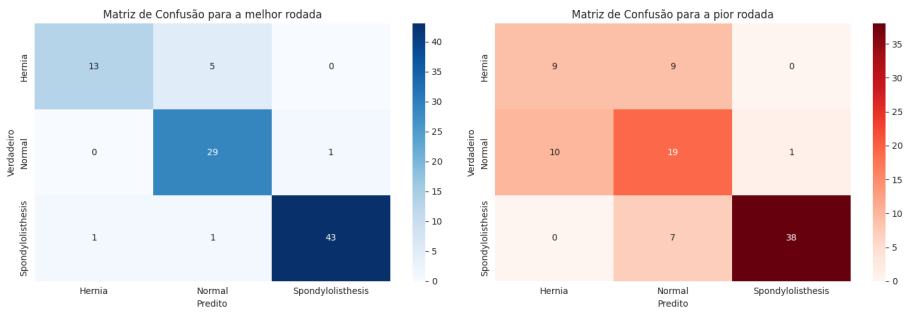

Figura 3. Matrizes de confusão para o melhor e pior caso do classificador KNN.

4. Conclusão

Este trabalho permitiu avaliar a eficácia de diferentes classificadores supervisionados no conjunto de dados biomecânicos *Vertebral Column*. Os resultados experimentais demonstraram que o algoritmo KNN (K=1) apresentou o desempenho superior de forma consistente, especialmente quando utilizado com a distância Euclidiana ($m = 2$) ou ordens superiores de Minkowski.

A análise do classificador MDC revelou que a utilização da mediana (MDC Robusto) em vez da média para a definição dos centróides resulta em ganhos de acurácia, o que é coerente com a observação de que os atributos do dataset não seguem uma distribuição normal e apresentam assimetrias. O classificador MAXCO, embora teoricamente interessante, não se mostrou competitivo para este problema específico, sugerindo que a direção dos vetores de atributos não é tão informativa quanto a sua magnitude e posição relativa para distinguir as patologias da coluna.

Observou-se também que o desempenho de todos os modelos é sensível à quantidade de dados disponíveis para treinamento, com a acurácia média subindo gradualmente de 20% para 80% de treinamento. Por fim, a confusão entre as classes Hérnia e Normal destaca a complexidade biomecânica destas condições, indicando que novos atributos ou técnicas de engenharia de características poderiam ser explorados em trabalhos futuros para melhorar a separabilidade nestas regiões do espaço de atributos.