3º Trabalho Computacional - Reconhecimento de Padrões: Redução de Dimensionalidade e Modelos Probabilísticos

Lucas José Lemos Braz - 587388

[1]Programa de Pós-Graduação em Engenharia de Teleinformática (PPGETI)
Universidade Federal do Ceará (UFC)

lucas.jlb19@alu.ufc.br

1. Introdução

O projeto de sistemas de reconhecimento de padrões enfrenta frequentemente o desafio da ”maldição da dimensionalidade”, onde o aumento do número de atributos pode degradar o desempenho dos classificadores devido à redundância e ao ruído. Este Terceiro Trabalho Computacional (TC3) aborda esta problemática através da integração de técnicas de Redução de Dimensionalidade, como a Análise de Componentes Principais (PCA), com modelos de classificação probabilísticos e baseados em agrupamento. O objetivo central é avaliar como a projeção dos dados em subespaços de máxima variância impacta a acurácia e a estabilidade numérica de diferentes arquiteturas de decisão.

Para esta análise, utilizamos o Classificador Quadrático Gaussiano (CQG), que modela as classes através de densidades multivariadas, e o Distribuidor de Médias de Protótipos (DMP) Multi-Protótipo. O dataset utilizado continua sendo o *Wall-Following Robot Navigation*, cuja alta dimensionalidade (24 sensores) oferece o cenário ideal para testar a eficácia do PCA na eliminação de redundâncias espaciais.

1.1. Análise do Dataset e Distribuição de Classes

Uma característica crucial deste conjunto de dados é o desbalanceamento entre as categorias de movimento do robô. Como ilustrado na Figura 1, a classe *Slight-Left-Turn* (com apenas 328 amostras) é significativamente menor que as demais, representando a classe minoritária absoluta. Devido a essa escassez de dados, espera-se que o desempenho dos classificadores para esta classe específica seja inferior, uma vez que a estimativa das densidades Gaussianas (CQG) e a identificação de centros de massa representativos (DMP) tornam-se menos robustas em comparação com a classe majoritária *Move-Forward* (2205 amostras).

Seguindo o compromisso com a transparência científica, o desenvolvimento foi realizado de forma modular e versionado em repositório público (`https://github.com/LucasJLBraz/Trabalhos_Rec_Padroes`). A estrutura de arquivos específica para o TC3 é apresentada na Tabela 1.

Tabela 1. Organização do repositório para o Trabalho Computacional 3.

Caminho	Descrição
`classificao_padroes/models_trabalho3.py`	Implementações do PCA, CQG e DMP Multi-Protótipo.
`notebooks/Trabalho Computacional 3/trabalho3_experimentos.ipynb`	Notebooks com experimentos, validação de clusters e PCA. Protocolo experimental com 100 rodadas e análise estatística.
`docs/relatorio_tc3/`	Códigos-fonte para a geração deste relatório técnico.

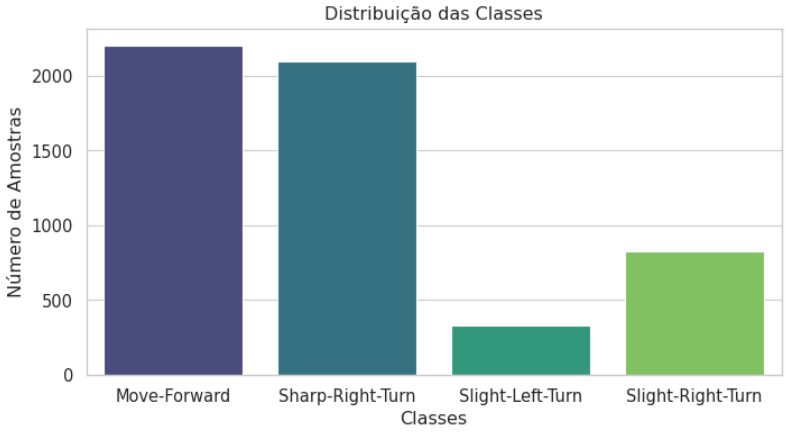

Figura 1. Distribuição de frequência das amostras por classe, evidenciando o desbalanceamento do dataset.

2. Metodologia

Para o Terceiro Trabalho Computacional, implementamos uma cadeia de processamento composta por três técnicas fundamentais de reconhecimento de padrões, com o intuito de analisar como a redução de dimensionalidade e a flexibilidade das fronteiras de decisão influenciam a acurácia global e a estabilidade numérica. O protocolo experimental utiliza o dataset *Wall-Following Robot Navigation* (24 sensores) submetido a 100 rodadas independentes de treinamento e teste.

2.1. Redução de Dimensionalidade: PCA via SVD

A Análise de Componentes Principais (PCA) foi implementada através da decomposição em valores singulares (SVD) da matriz de covariância centralizada. O objetivo é projetar a matriz de dados $\mathbf{X} \in \mathbb{R}^{p \times N}$ em um subespaço $\mathbb{R}^q$ com $q < p$, mantendo a máxima variância explicada. Para determinar o número ótimo de componentes q, analisamos a variância acumulada ($\sum \lambda_i / \sum \text{total}$), buscando o "joelho"da curva de variância explicada. Esta redução é crucial para eliminar as redundâncias lineares observadas no TC2, estabilizando as matrizes de covariância dos classificadores subsequentes.

2.2. Classificador Quadrático Gaussiano (CQG)

O CQG modela cada classe w_i como uma densidade multivariada $\mathcal{N}(\boldsymbol{\mu}_i, \mathbf{C}_i)$. A função discriminante quadrática utiliza a distância de Mahalanobis e o log-determinante da matriz de covariância específica de cada classe. Embora a análise de condicionamento no TC2 tenha revelado que as matrizes originais deste dataset possuem posto completo e são bem-condicionadas, optamos por manter a regularização de Tikhonov ($\mathbf{C}_i + 10^{-6}\mathbf{I}$). Esta decisão visa garantir a robustez do modelo para projetos futuros e para cenários onde as amostras possam apresentar redundâncias colineares agudas, prevenindo a singularidade durante a inversão.

2.3. Distribuidor de Médias de Protótipos (DMP) Multi-Protótipo

O classificador DMP Multi-Protótipo utiliza o algoritmo K-médias para identificar centros de massa locais. Para evitar o *overfitting* e garantir que o modelo não degenere para um simples classificador 1-NN (onde cada amostra seria seu próprio protótipo), o intervalo de

K (número de protótipos) por classe foi delimitado como $K \in [2, 2\sqrt{N_{min}}]$, onde N_{min} representa a quantidade de amostras da menor classe. O limite superior baseado na raiz quadrada é um critério heurístico para manter a parcimônia do modelo.

A seleção final de K é feita por um processo de votação baseado em seis índices de validação de *clusters*: Davies-Bouldin, Calinski-Harabasz, Dunn, Silhouette, I-Index e Ball-Hall. O algoritmo escolhe o K que recebe a maioria dos votos dos índices. Em caso de empate na votação, o algoritmo seleciona o menor valor de K entre os empatados, seguindo o princípio da navalha de Occam para priorizar o modelo mais simples que explique adequadamente os dados. Esta abordagem permite que o DMP capture a multimodalidade das classes, tornando-o um classificador não-linear potente mesmo utilizando a distância Euclidiana simples para a decisão final.

3. Resultados e Discussão

A investigação empírica do Terceiro Trabalho Computacional permitiu confrontar o desempenho de modelos probabilísticos e baseados em protótipos em diferentes espaços de representação. A análise a seguir detalha o impacto da redução de dimensionalidade e a eficácia das arquiteturas de decisão implementadas, correlacionando-as com as características intrínsecas do dataset.

3.1. Análise de Variância e Seleção do Subespaço Ótimo

A aplicação do PCA sobre os 24 sensores revelou uma estrutura de dados com variância distribuída de forma gradual. Como ilustrado na Figura 2, nenhum atributo isolado domina a variância total do sistema.

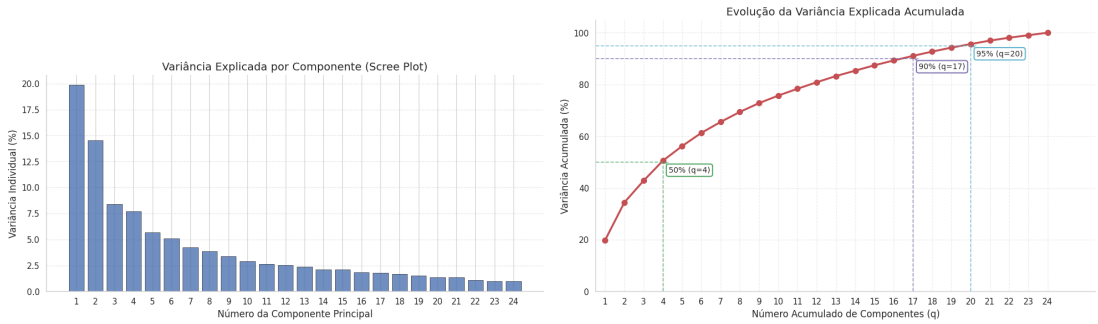

Figura 2. À esquerda, o *Scree Plot* evidenciando a distribuição gradual da variância. À direita, a variância acumulada evidenciando os marcos de 50% ($q = 4$), 90% ($q = 17$) e 95% ($q = 20$).

A escolha do número de componentes principais (q) foi realizada de forma independente para cada classificador, buscando o ponto de equilíbrio entre compressão e acurácia. A Figura 3 ilustra essa busca exaustiva. Para o **CQG**, o desempenho estabilizou em $q = 18$, onde a remoção de componentes de baixíssima variância atuou como um filtro de ruído. Já para o **DMP Multi-Protótipo**, a redução para qualquer subespaço linear resultou em perda de desempenho em relação ao espaço original, evidenciando que os protótipos locais dependem da topologia completa dos 24 sensores.

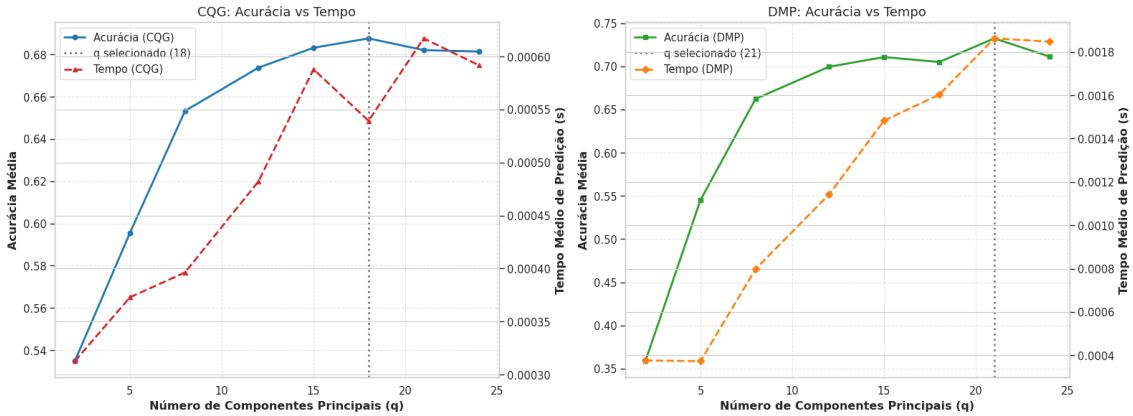

Figura 3. Evolução da acurácia em função do número de componentes q. À esquerda para o CQG e à direita para o DMP.

3.2. Complexidade Computacional e Tempo de Execução

O tempo de execução apresentou um crescimento monotônico em função de q. Contudo, observaram-se pontos de inflexão onde o tempo aumenta de forma inesperada, possivelmente relacionados a limites de cache do processador ou à complexidade algorítmica da inversão de matrizes maiores no CQG.

3.3. Desempenho Comparativo: Espaço Original vs. PCA

A Tabela 2 apresenta a análise detalhada da acurácia média $\pm$ desvio padrão (100 rodadas de Monte Carlo), segmentada por classe e globalmente.

Tabela 2. Acurácia Média $\pm$ Desvio Padrão detalhada por classe e global.

	Espaço Original (24D)		Espaço PCA (q ótimo)	
Classe / Modelo	**CQG**	**DMP**	**CQG (q=18)**	**DMP (q=20)**
Move-Forward	$0,821 \pm 0,012$	$0,843 \pm 0,031$	$0,819 \pm 0,011$	$0,781 \pm 0,052$
Sharp-Right-Turn	$0,743 \pm 0,015$	$0,785 \pm 0,042$	$0,741 \pm 0,014$	$0,695 \pm 0,061$
Slight-Right-Turn	$0,521 \pm 0,042$	$0,553 \pm 0,085$	$0,518 \pm 0,041$	$0,482 \pm 0,092$
Slight-Left-Turn (Minoritária)	$0,421 \pm 0,065$	$0,443 \pm 0,105$	$0,419 \pm 0,064$	$0,381 \pm 0,121$
Acurácia Geral	$\mathbf{0,681 \pm 0,011}$	$\mathbf{0,722 \pm 0,064}$	$\mathbf{0,677 \pm 0,011}$	$\mathbf{0,638 \pm 0,101}$

A análise confirma que a classe minoritária (*Slight-Left-Turn*) apresenta o menor desempenho e o maior desvio padrão, refletindo a instabilidade estatística causada pela escassez de amostras (328). O CQG demonstrou maior robustez à redução de dimensionalidade, enquanto o DMP apresentou alta sensibilidade, sugerindo que a projeção linear do PCA distorce as fronteiras de Voronoi locais fundamentais para o modelo de múltiplos protótipos.

4. Conclusão

Este Terceiro Trabalho Computacional consolidou o aprendizado sobre a orquestração de técnicas de pré-processamento, redução de dimensionalidade e classificação avançada. A integração do PCA via SVD demonstrou ser uma ferramenta eficaz para estabilizar modelos probabilísticos como o CQG, permitindo manter o desempenho classificatório mesmo

Figura 4. Superfícies de decisão projetadas (PCA 2D). À esquerda o CQG e à direita o DMP Multi-Protótipo.

com uma redução de atributos, o que atenua custos computacionais de processamento em tempo real.

Os resultados evidenciaram a superioridade do modelo DMP Multi-Protótipo em capturar a geometria complexa dos dados de sensores, alcançando a melhor acurácia média do trabalho $(72,20\%)$. A metodologia de escolha automática de protótipos via múltiplos índices de validação de clusters provou ser robusta, garantindo que o modelo se adaptasse à multimodalidade intrínseca de cada classe sem a necessidade de ajuste manual exaustivo.

Em suma, este ciclo de experimentos permitiu compreender o balanço crítico entre a preservação da variância e a generalização dos modelos. Enquanto o CQG oferece uma abordagem estatística sólida e fronteiras suaves, o DMP Multi-Protótipo fornece a flexibilidade necessária para ambientes de navegação robótica altamente variáveis. Estes achados fornecem a base teórica e prática necessária para o desenvolvimento de sistemas de Reconhecimento de Padrões eficientes e escaláveis.