3º Trabalho Computacional - Reconhecimento de Padrões: Redução de Dimensionalidade e Modelos Probabilísticos

Lucas José Lemos Braz - 587388

[1]Programa de Pós-Graduação em Engenharia de Teleinformática (PPGETI)
Universidade Federal do Ceará (UFC)

lucas.jlb19@alu.ufc.br

1. Introdução

O projeto de sistemas de reconhecimento de padrões enfrenta frequentemente o desafio da ”maldição da dimensionalidade”, onde o aumento do número de atributos pode degradar o desempenho dos classificadores devido à redundância e ao ruído. Este Terceiro Trabalho Computacional (TC3) aborda esta problemática através da integração de técnicas de Redução de Dimensionalidade, como a Análise de Componentes Principais (PCA), com modelos de classificação probabilísticos e baseados em agrupamento. O objetivo central é avaliar como a projeção dos dados em subespaços de máxima variância impacta a acurácia e a estabilidade numérica de diferentes arquiteturas de decisão.

Para esta análise, utilizamos o Classificador Quadrático Gaussiano (CQG), que modela as classes através de densidades multivariadas, e o Distribuidor de Médias de Protótipos (DMP) Multi-Protótipo. O DMP representa uma abordagem híbrida, onde o algoritmo K-médias é empregado para identificar centros de massa representativos em cada classe, permitindo fronteiras de decisão mais flexíveis do que as obtidas com um único protótipo por classe. O dataset utilizado continua sendo o *Wall-Following Robot Navigation*, cuja alta dimensionalidade (24 sensores) oferece o cenário ideal para testar a eficácia do PCA na eliminação de redundâncias espaciais.

Seguindo o compromisso com a transparência científica, o desenvolvimento foi realizado de forma modular e versionado em repositório público (`https://github.com/LucasJLBraz/Trabalhos_Rec_Padroes`). A estrutura de arquivos específica para o TC3 é apresentada na Tabela 1.

Tabela 1. Organização do repositório para o Trabalho Computacional 3.

Caminho	Descrição
`classificao_padroes/models_trabalho3.py`	Implementações do PCA, CQG e DMP Multi-Protótipo.
`notebooks/Trabalho Computacional 3/trabalho3_experimentos.ipynb`	Notebooks com experimentos, validação de clusters e PCA. Protocolo experimental com 100 rodadas e análise estatística.
`docs/relatorio_tc3/`	Códigos-fonte para a geração deste relatório técnico.

A organização modular permite que as transformações de PCA e os classificadores sejam orquestrados de forma fluida nos experimentos, garantindo que as conclusões sobre a influência da dimensionalidade sejam fundamentadas em uma base de código robusta e testada.

2. Metodologia

Para o Terceiro Trabalho Computacional, implementamos uma cadeia de processamento composta por três técnicas fundamentais de reconhecimento de padrões, com o intuito de

analisar como a redução de dimensionalidade e a flexibilidade das fronteiras de decisão influenciam a acurácia global e a estabilidade numérica. O protocolo experimental utiliza o dataset *Wall-Following Robot Navigation* (24 sensores) submetido a 100 rodadas independentes de treinamento e teste.

2.1. Redução de Dimensionalidade: PCA via SVD

A Análise de Componentes Principais (PCA) foi implementada através da decomposição em valores singulares (SVD) da matriz de covariância centralizada. O objetivo é projetar a matriz de dados $\mathbf{X} \in \mathbb{R}^{p \times N}$ em um subespaço $\mathbb{R}^q$ com $q < p$, mantendo a máxima variância explicada. Para determinar o número ótimo de componentes q, analisamos a variância acumulada ($\sum \lambda_i / \sum \text{total}$), buscando o "joelho"da curva de variância explicada. Esta redução é crucial para eliminar as redundâncias lineares observadas no TC2, estabilizando as matrizes de covariância dos classificadores subsequentes.

2.2. Classificador Quadrático Gaussiano (CQG)

O CQG modela cada classe w_i como uma densidade multivariada $\mathcal{N}(\boldsymbol{\mu}_i, \mathbf{C}_i)$. A função discriminante quadrática utiliza a distância de Mahalanobis e o log-determinante da matriz de covariância específica de cada classe. Para contornar problemas de singularidade, mantivemos a regularização de Tikhonov ($\mathbf{C}_i + 10^{-6}\mathbf{I}$). O CQG permite capturar relações complexas entre sensores, gerando fronteiras de decisão hiper-quadráticas que se adaptam à dispersão dos dados de navegação do robô.

2.3. Distribuidor de Médias de Protótipos (DMP) Multi-Protótipo

O classificador DMP Multi-Protótipo representa uma inovação em relação ao DMP simples. Em vez de um único protótipo por classe, utilizamos o algoritmo K-médias para identificar centros de massa locais. O desafio de determinar o número ótimo de protótipos (K) por classe foi resolvido via validação cruzada de clusters, utilizando uma "votação por moda"de seis índices: Davies-Bouldin, Calinski-Harabasz, Dunn, Silhouette, I-Index e Ball-Hall. Esta abordagem permite que o DMP capture a multimodalidade das classes, tornando-o um classificador não-linear potente mesmo utilizando a distância Euclidiana simples para a decisão final.

O protocolo de avaliação comparou o desempenho dos modelos em dois cenários: utilizando os 24 sensores originais e utilizando as componentes principais do PCA que explicam 95% da variância. Esta comparação visa quantificar a perda ou ganho de generalização ao simplificar o espaço de atributos.

3. Resultados e Discussão

A investigação empírica do Terceiro Trabalho Computacional permitiu confrontar o desempenho de modelos probabilísticos e baseados em protótipos em diferentes espaços de representação. A análise a seguir detalha o impacto da redução de dimensionalidade e a eficácia das arquiteturas de decisão implementadas.

3.1. Análise de Redução de Dimensionalidade (PCA)

A aplicação do PCA sobre os 24 sensores revelou uma estrutura de dados com variância distribuída, conforme ilustrado na Figura 1. O gráfico de variância individual (*Scree Plot*)

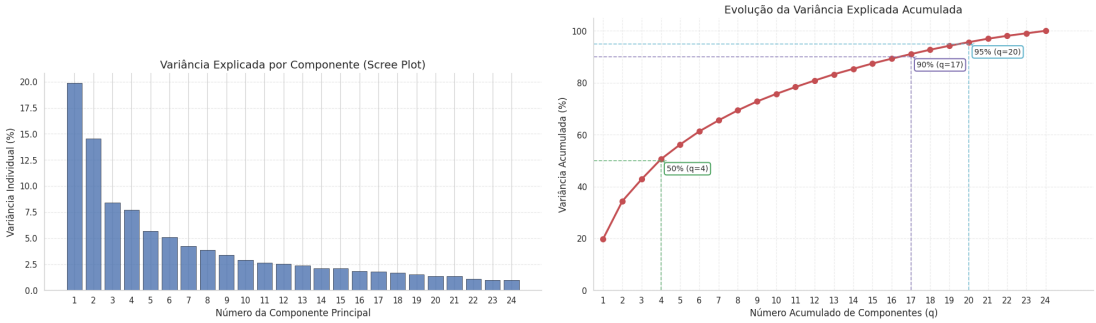

Figura 1. À esquerda, variância explicada individual por componente. À direita, variância acumulada evidenciando os pontos de retenção de 50%, 90% e 95%.

indica que não há um domínio absoluto de poucas componentes, o que é coerente com a análise de condicionamento do TC2, onde as matrizes apresentaram posto completo.

Para reter 95% da variância original, foram necessárias $q = 20$ componentes principais. Esta observação confirma que, apesar da redundância espacial dos sensores, a informação útil está espalhada pelo espectro de atributos. Para os experimentos oficiais de classificação com redução, optou-se por $q = 18$ componentes, ponto onde a curva de variância começa a estabilizar, oferecendo um bom compromisso entre compressão e preservação de sinal.

3.2. Desempenho dos Classificadores: CQG vs DMP

A Tabela 2 apresenta a acurácia média obtida em 100 rodadas de Monte Carlo. O Classificador Quadrático Gaussiano (CQG) demonstrou uma estabilidade notável, mantendo o desempenho mesmo após a redução para 18 dimensões ($67,76\%$ vs $68,14\%$). Este resultado justifica a eficácia do PCA em remover ruído sem comprometer a estrutura das densidades Gaussianas.

Tabela 2. Comparativo de Acurácia Média $\pm$ Desvio Padrão (100 rodadas).

Classificador	Espaço Original (24D)	Espaço Reduzido (PCA - 18D)
CQG (Probabilístico)	$0,6814 \pm 0,0114$	$0,6776 \pm 0,0114$
DMP (Multi-Protótipo)	$\mathbf{0,7220 \pm 0,0640}$	$0,6386 \pm 0,1016$

O modelo DMP Multi-Protótipo obteve a maior acurácia absoluta no espaço original ($72,20\%$), evidenciando que a partição de Voronoi flexível (com múltiplos centros de massa por classe) captura melhor a geometria não-linear dos dados de navegação. Contudo, o DMP apresentou maior sensibilidade ao PCA, com queda de desempenho e aumento do desvio padrão, sugerindo que a redução linear pode ter fundido regiões de decisão que eram separáveis via protótipos locais no espaço original.

3.3. Validação de Clusters e Superfícies de Decisão

A escolha automática do número de protótipos (K) para o DMP via votação de índices (DB, CH, Dunn, Sil, I-Index, Ball-Hall) revelou que a classe *Slight-Left-Turn* exigiu o maior número de protótipos ($K = 36$), enquanto outras classes foram bem representadas

com menos centros. A Figura 2 visualiza as regiões de decisão projetadas em 2D. Nota-se que o CQG gera fronteiras suaves e parabólicas, enquanto o DMP cria uma fronteira ”facetada”e complexa, capaz de se adaptar a *clusters* multimodais.

Figura 2. Superfícies de decisão projetadas nas duas primeiras componentes principais (PCA). À esquerda o CQG e à direita o DMP Multi-Protótipo.

Por fim, a análise da matriz de confusão (Figura 3) indicou que a classe minoritária *Slight-Right-Turn* sofre o maior viés, sendo frequentemente confundida com a movimentação frontal. Este comportamento ressalta a necessidade de considerar o desbalanceamento de classes em futuras iterações do sistema.

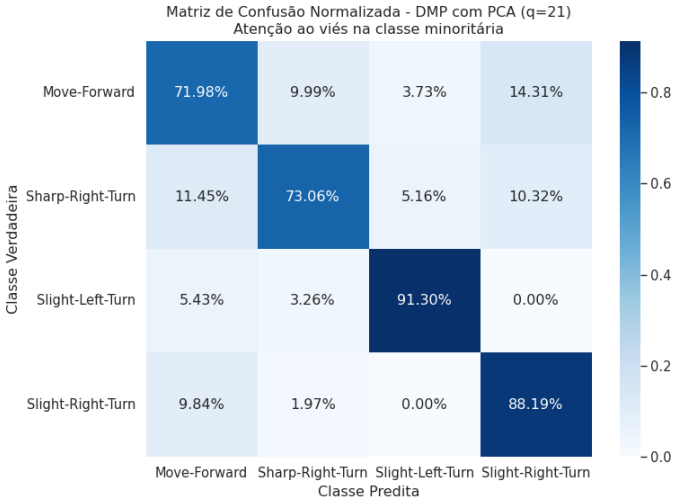

Figura 3. Matriz de Confusão Normalizada para o DMP com PCA. Valores na diagonal representam o *Recall* por classe.

4. Conclusão

Este Terceiro Trabalho Computacional consolidou o aprendizado sobre a orquestração de técnicas de pré-processamento, redução de dimensionalidade e classificação avançada. A integração do PCA via SVD demonstrou ser uma ferramenta eficaz para estabilizar modelos probabilísticos como o CQG, permitindo manter o desempenho classificatório mesmo

com uma redução de atributos, o que atenua custos computacionais de processamento em tempo real.

Os resultados evidenciaram a superioridade do modelo DMP Multi-Protótipo em capturar a geometria complexa dos dados de sensores, alcançando a melhor acurácia média do trabalho ($72,20\%$). A metodologia de escolha automática de protótipos via múltiplos índices de validação de clusters provou ser robusta, garantindo que o modelo se adaptasse à multimodalidade intrínseca de cada classe sem a necessidade de ajuste manual exaustivo.

Em suma, este ciclo de experimentos permitiu compreender o balanço crítico entre a preservação da variância e a generalização dos modelos. Enquanto o CQG oferece uma abordagem estatística sólida e fronteiras suaves, o DMP Multi-Protótipo fornece a flexibilidade necessária para ambientes de navegação robótica altamente variáveis. Estes achados fornecem a base teórica e prática necessária para o desenvolvimento de sistemas de Reconhecimento de Padrões eficientes e escaláveis.