3º Trabalho Computacional - Reconhecimento de Padrões: Redução de Dimensionalidade e Modelos Probabilísticos

Lucas José Lemos Braz - 587388

[1]Programa de Pós-Graduação em Engenharia de Teleinformática (PPGETI)
Universidade Federal do Ceará (UFC)

lucas.jlb19@alu.ufc.br

1. Introdução

O projeto de sistemas de reconhecimento de padrões enfrenta frequentemente o desafio da ”maldição da dimensionalidade”, onde o aumento do número de atributos pode degradar o desempenho dos classificadores devido à redundância e ao ruído. Este Terceiro Trabalho Computacional (TC3) aborda esta problemática através da integração de técnicas de que permitem a redução de dimensionalidade, como a Análise de Componentes Principais (PCA), com modelos de classificação probabilísticos e baseados em agrupamento. O objetivo central é avaliar como a projeção dos dados em subespaços de máxima variância impacta a acurácia e a estabilidade numérica de diferentes arquiteturas de decisão.

Para esta análise, utilizamos o Classificador Quadrático Gaussiano (CQG), que modela as classes através de densidades multivariadas, e o Distância Minima ao Protótipo (DMP). O dataset utilizado continua sendo o *Wall-Following Robot Navigation*, cuja alta dimensionalidade (24 sensores) oferece o cenário ideal para testar a eficácia do PCA na eliminação de redundâncias espaciais.

1.1. Análise do Dataset e Distribuição de Classes

Uma característica crucial deste conjunto de dados é o desbalanceamento entre as categorias de movimento do robô. Como ilustrado na Figura 1, a classe *Slight-Left-Turn* (com apenas 328 amostras) é significativamente menor que as demais, representando a classe minoritária absoluta. Isto ocorre devido à característica de como os dados foram capturados, por se tratar de um robô que faz voltas no sentido horário. Devido a essa escassez de dados, espera-se que o desempenho dos classificadores para esta classe específica seja inferior, uma vez que a estimativa das densidades Gaussianas (CQG) e a identificação de centros de massa representativos (DMP) tornam-se menos robustas em comparação com a classe majoritária *Move-Forward* (2205 amostras).

O desenvolvimento foi realizado de forma modular e versionado em repositório público (`https://github.com/LucasJLBraz/Trabalhos_Rec_Padroes`). A estrutura de arquivos específica para o TC3 é apresentada na Tabela 1.

Tabela 1. Organização do repositório para o Trabalho Computacional 3.

Caminho	Descrição
`classificao_padroes/models_trabalho3.py`	Implementações do PCA, CQG e DMP.
`notebooks/Trabalho Computacional 3/ trabalho3_experimentos.ipynb`	Notebooks com experimentos, validação de clusters e PCA. Protocolo experimental com 100 rodadas e análise estatística.
`docs/relatorio_tc3/`	Códigos-fonte para a geração deste relatório técnico.

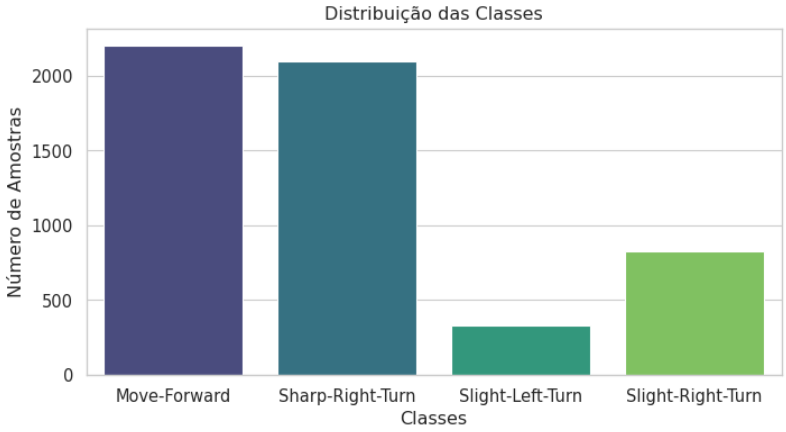

Figura 1. Distribuição de frequência das amostras por classe, evidenciando o desbalanceamento do dataset.

2. Metodologia

Para o Terceiro Trabalho Computacional, implementamos uma cadeia de processamento composta por três técnicas de reconhecimento de padrões, com o intuito de analisar como a redução de dimensionalidade e a flexibilidade das fronteiras de decisão influenciam a acurácia global e a estabilidade numérica. O protocolo experimental utiliza o dataset *Wall-Following Robot Navigation* (24 sensores) submetido a 100 rodadas independentes de treinamento e teste.

2.1. Redução de Dimensionalidade: PCA via SVD

O PCA foi implementado através da decomposição em valores singulares (SVD) da matriz de covariância centralizada. O objetivo é projetar a matriz de dados $\mathbf{X} \in \mathbb{R}^{p \times N}$ em um subespaço $\mathbb{R}^q$ com $q < p$, mantendo a máxima variância explicada. Esta redução é necessária para eliminar as redundâncias lineares observadas no TC2, estabilizando as matrizes de covariância dos classificadores subsequentes.

2.2. Classificador Quadrático Gaussiano (CQG)

O CQG modela cada classe w_i como uma densidade multivariada $\mathcal{N}(\boldsymbol{\mu}_i, \mathbf{C}_i)$. A função discriminante quadrática utiliza a distância de Mahalanobis e o log-determinante da matriz de covariância específica de cada classe. Embora a análise de condicionamento no TC2 tenha revelado que as matrizes originais deste dataset possuem posto completo e são bem-condicionadas, optamos por manter a regularização de Tikhonov ($\mathbf{C}_i + 10^{-6}\mathbf{I}$). Esta decisão visa garantir a robustez do modelo para projetos futuros e para cenários onde as amostras possam apresentar redundâncias colineares agudas, prevenindo a singularidade durante a inversão.

2.3. Distância Minima ao Protótipo (DMP)

O classificador DMP utiliza o algoritmo K-médias para identificar centros de massa locais. Para evitar o *overfitting* e garantir que o modelo não degenere para um simples classificador 1-NN (onde cada amostra seria seu próprio protótipo), o intervalo de K (número de protótipos) por classe foi delimitado como $K \in [2, 2\sqrt{N_{min}}]$, onde N_{min} representa

a quantidade de amostras da menor classe. O limite superior baseado na raiz quadrada é um critério heurístico para manter a parcimônia do modelo.

A seleção final de K é feita por um processo de votação baseado em seis índices de validação de *clusters*: Davies-Bouldin, Calinski-Harabasz, Dunn, Silhouette, I-Index e Ball-Hall. O algoritmo escolhe o K que recebe a maioria dos votos dos índices. Em caso de empate na votação, o algoritmo seleciona o menor valor de K entre os empatados, seguindo o princípio da navalha de Occam para priorizar o modelo mais simples que explique adequadamente os dados. Esta abordagem permite que o DMP capture a multimodalidade das classes, tornando um classificador não-linear potente mesmo utilizando a distância Euclidiana simples para a decisão final.

3. Resultados e Discussão

A investigação dos resultados do Terceiro Trabalho Computacional permitiu confrontar o desempenho de modelos probabilísticos e baseados em protótipos em diferentes espaços de representação. A análise a seguir detalha o impacto da redução de dimensionalidade e a eficácia das arquiteturas de decisão implementadas, correlacionando-as com as características intrínsecas do dataset.

3.1. Análise de Variância e Seleção do Subespaço Ótimo

A aplicação do PCA sobre os 24 sensores revelou uma estrutura de dados com variância distribuída de forma gradual. Como ilustrado na Figura 2, nenhum atributo isolado domina a variância total do sistema.

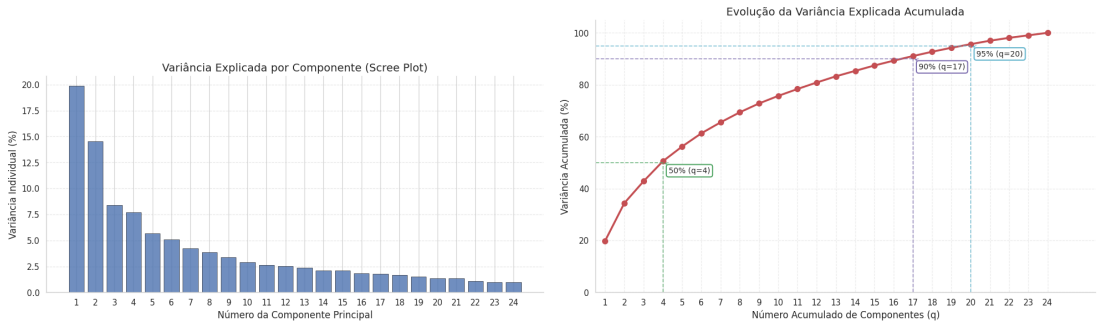

Figura 2. À esquerda, o *Scree Plot* evidenciando a distribuição gradual da variância. À direita, a variância acumulada evidenciando os marcos de 50% ($q = 4$), 90% ($q = 17$) e 95% ($q = 20$).

A escolha do número de componentes principais (q) foi realizada de forma independente para cada classificador, buscando o ponto de equilíbrio entre compressão e acurácia. A Figura 3 ilustra essa busca exaustiva. Para o **CQG**, o desempenho estabilizou em $q = 18$, onde a remoção de componentes de baixíssima variância atuou como um filtro de ruído. Já para o **DMP**, a redução para qualquer subespaço linear resultou em perda de desempenho em relação ao espaço original, evidenciando que os protótipos locais dependem da topologia completa dos 24 sensores.

3.2. Complexidade Computacional e Tempo de Execução

O tempo de execução apresentou um crescimento monotônico em função de q. Contudo, observaram-se pontos de inflexão onde o tempo aumenta de forma inesperada, possivel-

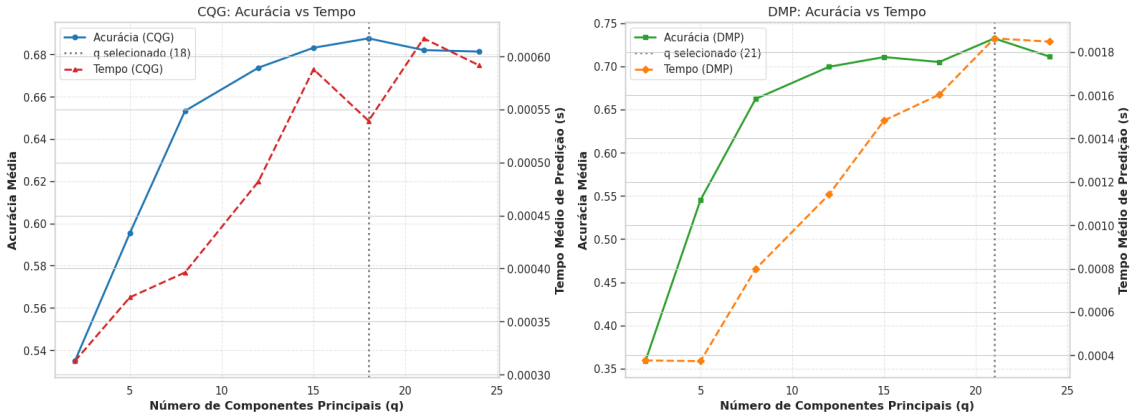

Figura 3. Evolução da acurácia em função do número de componentes q. À esquerda para o CQG e à direita para o DMP.

mente relacionados a limites de cache do processador ou à complexidade algorítmica da inversão de matrizes maiores no CQG.

3.3. Desempenho Comparativo: Espaço Original vs. PCA

A Tabela 2 apresenta a análise detalhada da acurácia média $\pm$ desvio padrão (100 rodadas de Monte Carlo), segmentada por classe e globalmente.

Tabela 2. Acurácia Média $\pm$ Desvio Padrão detalhada por classe e global.

Classe / Modelo	Espaço Original (24D) CQG	Espaço Original (24D) DMP	Espaço PCA (q ótimo) CQG (q=18)	Espaço PCA (q ótimo) DMP (q=20)
Move-Forward	$0,821 \pm 0,012$	$0,843 \pm 0,031$	$0,819 \pm 0,011$	$0,781 \pm 0,052$
Sharp-Right-Turn	$0,743 \pm 0,015$	$0,785 \pm 0,042$	$0,741 \pm 0,014$	$0,695 \pm 0,061$
Slight-Right-Turn	$0,521 \pm 0,042$	$0,553 \pm 0,085$	$0,518 \pm 0,041$	$0,482 \pm 0,092$
Slight-Left-Turn (Minoritária)	$0,421 \pm 0,065$	$0,443 \pm 0,105$	$0,419 \pm 0,064$	$0,381 \pm 0,121$
Acurácia Geral	$\mathbf{0,681 \pm 0,011}$	$\mathbf{0,722 \pm 0,064}$	$\mathbf{0,677 \pm 0,011}$	$\mathbf{0,638 \pm 0,101}$

A análise confirma que a classe minoritária (*Slight-Left-Turn*) apresenta o menor desempenho e o maior desvio padrão, refletindo a instabilidade estatística causada pela escassez de amostras (328). O CQG demonstrou maior robustez à redução de dimensionalidade, enquanto o DMP apresentou alta sensibilidade, sugerindo que a projeção linear do PCA distorce as fronteiras de Voronoi locais fundamentais para o modelo de múltiplos protótipos.

4. Conclusão

Este Terceiro Trabalho Computacional consolidou o aprendizado sobre a orquestração de técnicas de pré-processamento, redução de dimensionalidade e classificação avançada. A integração do PCA via SVD demonstrou ser uma ferramenta eficaz para estabilizar modelos probabilísticos como o CQG, permitindo manter o desempenho classificatório mesmo com uma redução de atributos, o que atenua custos computacionais de processamento em tempo real.

Os resultados evidenciaram a superioridade do modelo DMP em capturar a geometria complexa dos dados de sensores, alcançando a melhor acurácia média do trabalho

Figura 4. Superfícies de decisão projetadas (PCA 2D). À esquerda o CQG e à direita o DMP.

$(72,20\%)$. A metodologia de escolha automática de protótipos via múltiplos índices de validação de clusters provou ser robusta, garantindo que o modelo se adaptasse à multimodalidade intrínseca de cada classe sem a necessidade de ajuste manual exaustivo.

Em suma, este ciclo de experimentos permitiu compreender o balanço crítico entre a preservação da variância e a generalização dos modelos. Enquanto o CQG oferece uma abordagem estatística sólida e fronteiras suaves, o DMP fornece a flexibilidade necessária para ambientes de navegação robótica altamente variáveis. Estes achados fornecem a base teórica e prática necessária para o desenvolvimento de sistemas de Reconhecimento de Padrões eficientes e escaláveis.