trabalho2_experimentos

February 22, 2026

1 Experimentos do Trabalho 2 - Reconhecimento de Padrões

- Aluno: Lucas José Lemos Braz

1.0.1 1. Imports e Configurações

[1]:
```
import time
import warnings
import os
import sys

import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
from scipy import stats

# Adicionando o diretório raiz ao path para importar os modelos
sys.path.append(os.path.abspath("../../.."))
from classificao_padroes.models_trabalho2 import mcovar1, mcovar2, mcovar3,␣
↪mcovar4

warnings.filterwarnings('ignore')
sns.set_theme(style="whitegrid")
```

```
2025-12-28 18:33:16.577 | INFO     |
classificao_padroes.config:<module>:11 -
PROJ_ROOT path is: /home/apo-pc/Documents/Github/Trabalhos_Rec_Padroes
```

1.0.2 2. Carregamento dos Dados

Nesta seção, carregamos os datasets do robô Wall-Following. - `sensor_readings_24.data`: 24 sensores de ultrassom. - `sensor_readings_4.data`: 4 sensores de ultrassom simplificados.

[2]:
```
# Caminhos relativos para os arquivos de dados
data_path_24 = "../../data/interin/wall+following+robot+navigation+data/
↪sensor_readings_24.data"
```

```
data_path_4 = "../../data/interin/wall+following+robot+navigation+data/
↪sensor_readings_4.data"

# Nomes das colunas
col_names_24 = [f"US{i+1}" for i in range(24)] + ["Class"]
col_names_4 = ["SD_front", "SD_left", "SD_right", "SD_back", "Class"]

# Carregando os datasets
data_24_df = pd.read_csv(data_path_24, names=col_names_24)
data_4_df = pd.read_csv(data_path_4, names=col_names_4)

# Separando features (X)
X_24 = data_24_df.drop("Class", axis=1).values
X_4 = data_4_df.drop("Class", axis=1).values

print(f"Dataset 24 sensores: {data_24_df.shape}")
print(f"Dataset 4 sensores: {data_4_df.shape}")
```

```
Dataset 24 sensores: (5456, 25)
Dataset 4 sensores: (5456, 5)
```

1.0.3 3. Funções Auxiliares

Definimos as funções para cálculo de covariância, norma e utilitários para plotagem e benchmarking. Agora incluímos também os métodos `mcovar1`, `mcovar2` e `mcovar4`.

[3]:
```
def calc_cov_matrix(data):
    """Calcula a matriz de covariância (variáveis nas colunas) usando NumPy."""
    return np.cov(data, rowvar=False, bias=True)

def calc_norm_diff(cov_np: np.ndarray, data: np.ndarray):
    """Calcula a norma entre o a matriz de covariância e a matriz de␣
↪covariância calculada pelo numpy."""
    return np.linalg.norm(cov_np - data)

def plot_covariance_heatmap(data, col_labels, title):
    """Plota o heatmap da matriz de covariância."""
    cov_matrix = calc_cov_matrix(data)
    plt.figure(figsize=(12, 10))
    sns.heatmap(cov_matrix, annot=True, cmap="coolwarm", fmt=".1f",␣
↪square=True,cbar=False,
                xticklabels=col_labels, yticklabels=col_labels)
    plt.title(title)
    plt.show()

def run_benchmark(data, n_rounds=100):
    """Executa o benchmark e retorna listas de tempos."""
```

```
    methods = ['mcovar1', 'mcovar2', 'mcovar3', 'mcovar4', 'NumPy Cov']
    results = {m: [] for m in methods}

    # Dados transpostos para os métodos mcovar (esperam (p, N))
    data_T = data.T

    for _ in range(n_rounds):

        # mcovar1 (Loop)
        start = time.perf_counter()
        mcovar1(data_T)
        results['mcovar1'].append(time.perf_counter() - start)

        # mcovar2 (Matrix Ops)
        start = time.perf_counter()
        mcovar2(data_T)
        results['mcovar2'].append(time.perf_counter() - start)

        # mcovar3 (Outer Product)
        start = time.perf_counter()
        mcovar3(data_T)
        results['mcovar3'].append(time.perf_counter() - start)

        # mcovar4 (Outer Product)
        start = time.perf_counter()
        mcovar4(data_T)
        results['mcovar4'].append(time.perf_counter() - start)

        # NumPy Covariance
        start = time.perf_counter()
        calc_cov_matrix(data)
        results['NumPy Cov'].append(time.perf_counter() - start)

    return results
```

1.0.4 4. Análise da Matriz de Covariância

Visualização da matriz de covariância para ambos os casos.

[4]:
```
# Visualização da Matriz de Covariância para 24 Sensores
plot_covariance_heatmap(X_24, col_names_24[:-1], "Matriz de Covariância (24␣
↪Sensores)")

# Visualização da Matriz de Covariância para 4 Sensores
plot_covariance_heatmap(X_4, col_names_4[:-1], "Matriz de Covariância (4␣
↪Sensores)")
```

Matriz de Covariância (24 Sensores)

	US1	US2	US3	US4	US5	US6	US7	US8	US9	US10	US11	US12	US13	US14	US15	US16	US17	US18	US19	US20	US21	US22	US23	US24
US1	0.6	0.3	0.1	0.1	0.0	-0.1	-0.3	-0.2	-0.3	-0.3	-0.2	-0.2	-0.2	-0.3	-0.2	0.1	0.1	0.1	0.2	0.2	0.2	0.4	0.4	0.4
US2	0.3	2.0	0.6	0.3	0.3	0.1	-0.1	-0.0	-0.1	-0.2	-0.4	-0.3	-0.4	-0.3	-0.1	-0.0	-0.1	-0.0	0.0	0.1	0.1	-0.0	0.1	0.2
US3	0.1	0.6	1.6	0.6	0.6	0.3	-0.1	-0.3	-0.4	-0.3	-0.3	-0.4	-0.3	-0.3	-0.3	-0.0	-0.1	-0.1	-0.1	-0.0	-0.0	0.3	0.2	0.1
US4	0.1	0.3	0.6	1.7	1.1	0.5	-0.1	-0.2	-0.3	-0.2	-0.2	-0.3	-0.3	-0.6	-0.6	0.0	-0.1	-0.2	-0.3	-0.1	-0.1	0.6	0.3	0.1
US5	0.0	0.3	0.6	1.1	1.8	0.8	0.1	-0.0	-0.3	-0.2	-0.2	-0.2	-0.2	-0.6	-0.7	-0.1	-0.2	-0.3	-0.4	-0.3	-0.2	0.2	0.2	0.1
US6	-0.1	0.1	0.3	0.5	0.8	1.6	0.7	0.3	0.2	-0.0	-0.3	-0.3	-0.2	-0.3	-0.4	-0.2	-0.3	-0.3	-0.4	-0.3	-0.2	-0.2	-0.2	-0.1
US7	-0.3	-0.1	-0.1	-0.1	0.1	0.7	2.0	0.6	0.8	0.5	0.2	0.1	0.0	0.2	0.2	-0.2	-0.3	-0.3	-0.4	-0.4	-0.3	-0.8	-0.4	-0.4
US8	-0.2	-0.0	-0.3	-0.2	-0.0	0.3	0.6	1.2	0.8	0.8	0.4	0.0	-0.0	-0.0	-0.1	-0.2	-0.2	-0.2	-0.3	-0.3	-0.3	-0.5	-0.2	-0.2
US9	-0.3	-0.1	-0.4	-0.3	-0.3	0.2	0.8	0.8	1.8	1.0	0.5	-0.0	0.0	0.1	0.3	-0.2	-0.3	-0.3	-0.4	-0.2	-0.2	-0.6	-0.5	-0.5
US10	-0.3	-0.2	-0.3	-0.2	-0.2	-0.0	0.5	0.8	1.0	1.7	0.8	0.2	0.1	-0.0	0.1	-0.0	-0.2	-0.3	-0.4	-0.3	-0.2	-0.4	-0.4	-0.4
US11	-0.2	-0.4	-0.3	-0.2	-0.2	-0.3	0.2	0.4	0.5	0.8	1.9	0.6	0.5	0.1	-0.1	-0.0	-0.1	-0.1	-0.3	-0.4	-0.4	-0.2	-0.2	-0.3
US12	-0.2	-0.3	-0.4	-0.3	-0.2	-0.3	0.1	0.0	-0.0	0.2	0.6	1.6	0.8	0.7	0.3	-0.1	0.0	0.0	0.0	-0.2	-0.3	-0.6	-0.3	-0.2
US13	-0.2	-0.4	-0.3	-0.3	-0.2	-0.2	0.0	-0.0	0.0	0.1	0.5	0.8	2.0	1.1	0.5	-0.1	0.0	0.1	0.1	-0.1	-0.2	-0.4	-0.3	-0.2
US14	-0.3	-0.3	-0.3	-0.6	-0.6	-0.3	0.2	-0.0	0.1	-0.0	0.1	0.7	1.1	2.5	1.0	-0.0	0.1	0.1	0.2	0.1	-0.1	-0.7	-0.6	-0.4
US15	-0.2	-0.1	-0.3	-0.6	-0.7	-0.4	0.2	-0.1	0.3	0.1	-0.1	0.3	0.5	1.0	2.9	0.2	0.1	0.1	0.1	0.1	0.1	-0.5	-0.4	-0.4
US16	0.1	-0.0	-0.0	0.0	-0.1	-0.2	-0.2	-0.2	-0.2	-0.0	-0.0	-0.1	-0.1	-0.0	0.2	1.2	0.4	0.2	0.0	0.1	0.2	0.2	0.1	0.0
US17	0.1	-0.1	-0.1	-0.1	-0.2	-0.3	-0.3	-0.2	-0.3	-0.2	-0.1	0.0	0.0	0.1	0.1	0.4	0.9	0.4	0.3	0.1	0.1	0.1	0.2	0.2
US18	0.1	-0.0	-0.1	-0.2	-0.3	-0.3	-0.3	-0.2	-0.3	-0.3	-0.1	0.0	0.1	0.1	0.1	0.2	0.4	0.8	0.4	0.2	0.1	0.1	0.1	0.2
US19	0.2	0.0	-0.1	-0.3	-0.4	-0.4	-0.4	-0.3	-0.4	-0.4	-0.3	0.0	0.1	0.2	0.1	0.0	0.3	0.4	1.3	0.4	0.2	0.1	0.1	0.2
US20	0.2	0.1	-0.0	-0.1	-0.3	-0.3	-0.4	-0.3	-0.2	-0.3	-0.4	-0.2	-0.1	0.1	0.1	0.1	0.1	0.2	0.4	1.3	0.3	0.3	0.2	0.1
US21	0.2	0.1	-0.0	-0.1	-0.2	-0.2	-0.3	-0.3	-0.2	-0.2	-0.4	-0.3	-0.2	-0.1	0.1	0.2	0.1	0.1	0.2	0.3	0.8	0.5	0.4	0.3
US22	0.4	-0.0	0.3	0.6	0.2	-0.2	-0.8	-0.5	-0.6	-0.4	-0.2	-0.6	-0.4	-0.7	-0.5	0.2	0.1	0.1	0.1	0.3	0.5	2.5	0.9	0.5
US23	0.4	0.1	0.2	0.3	0.2	-0.2	-0.4	-0.2	-0.5	-0.4	-0.2	-0.3	-0.3	-0.6	-0.4	0.1	0.2	0.1	0.1	0.2	0.4	0.9	1.7	0.7
US24	0.4	0.2	0.1	0.1	0.1	-0.1	-0.4	-0.2	-0.5	-0.4	-0.3	-0.2	-0.2	-0.4	-0.4	0.0	0.2	0.2	0.2	0.1	0.3	0.5	0.7	1.3

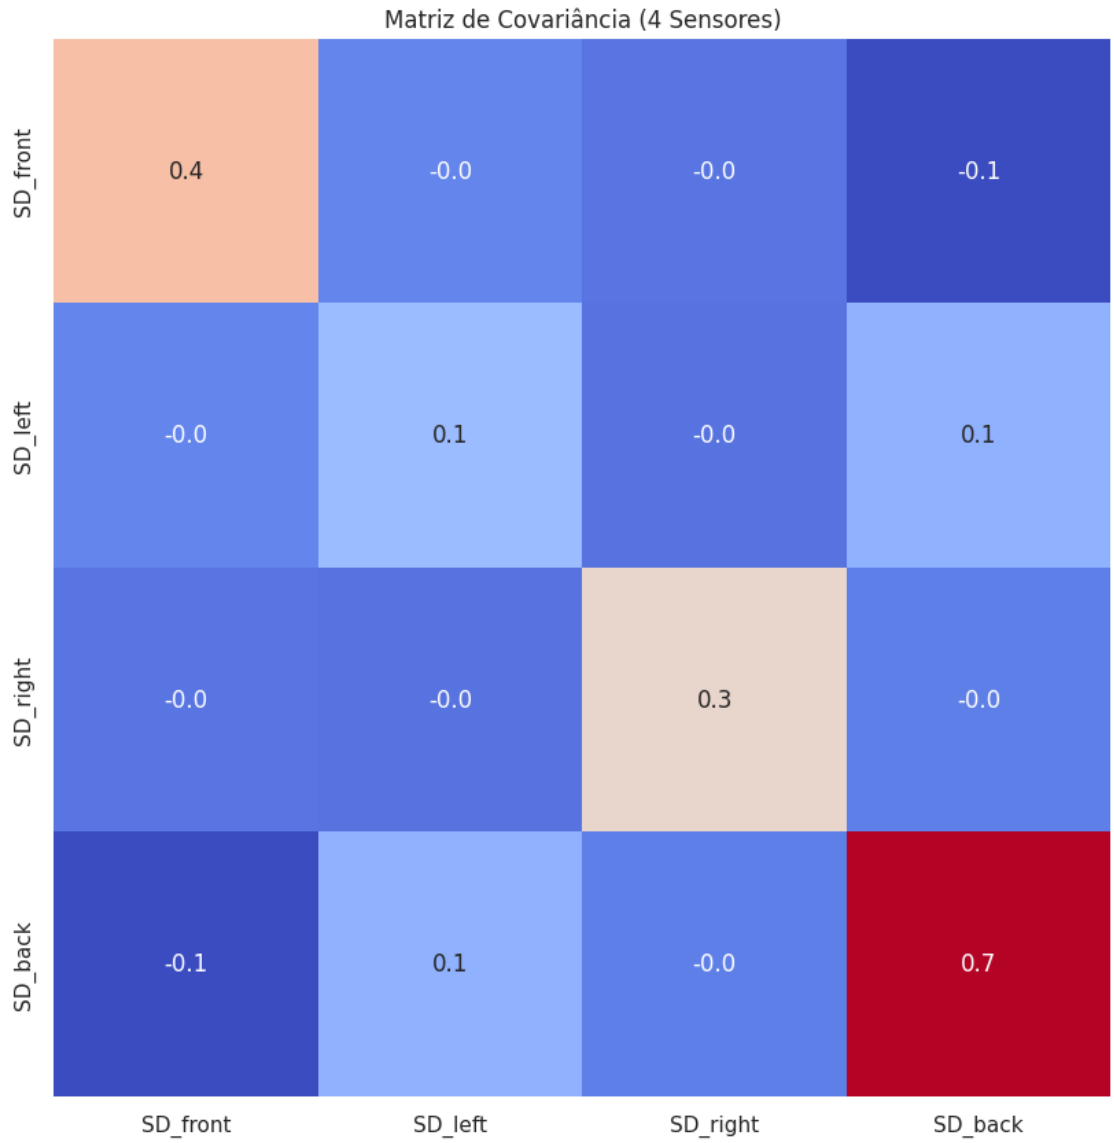

1.0.5 Calculando norma das matrizes de covariância

[5]:
```
# Calculando a norma entre a matriz de covariancia e a matriz de covariancia de␣
↪referencia para cada metodo.
mcovars = [mcovar1, mcovar2, mcovar3, mcovar4]
C_ref_4 = np.cov(X_4.T)
C_ref_24 = np.cov(X_24.T)
normas_4 = []
normas_24 = []
print("Norma p/ 4 sensores.")
for i in range(4):
    C = mcovars[i](X_4.T)
```

```
    norma = np.linalg.norm(C - C_ref_4)
    normas_4.append(norma)
    print(f"Mcovar {i+1} | norma(C - C_ref): {norma}")

print("-" * 50)
print("Norma p/ 24 sensores.")
for i in range(4):
    C = mcovars[i](X_24.T)
    norma = np.linalg.norm(C - C_ref_24)
    normas_24.append(norma)
    print(f"Mcovar {i+1} | norma(C - C_ref): {norma}")
```

```
Norma p/ 4 sensores.
Mcovar 1 | norma(C - C_ref): 0.0001611620742082004
Mcovar 2 | norma(C - C_ref): 0.00016116207420584133
Mcovar 3 | norma(C - C_ref): 0.00016116207420160746
Mcovar 4 | norma(C - C_ref): 0.00016116207420574234
--------------------------------------------------
Norma p/ 24 sensores.
Mcovar 1 | norma(C - C_ref): 0.00212266396148315
Mcovar 2 | norma(C - C_ref): 0.002122663961456295
Mcovar 3 | norma(C - C_ref): 0.0021226639614547486
Mcovar 4 | norma(C - C_ref): 0.0021226639614562023
```

1.0.6 5. Comparativo de Desempenho (Lado a Lado)

Executamos o benchmark para ambos os datasets, agora incluindo os métodos externos `mcovar1`, `mcovar2`, e `mcovar4`. Note que `mcovar1` utiliza um loop explícito e pode ser significativamente mais lento.

[6]:
```
# 1. Executar Benchmarks
print("Executando benchmark para 24 sensores (100 rodadas)...")
results_24 = run_benchmark(X_24)

print("Executando benchmark para 4 sensores (100 rodadas)...")
results_4 = run_benchmark(X_4)

# 2. Preparar DataFrames
def prepare_df(results):
    data_list = []
    for method, times in results.items():
        for t in times:
            # Convertendo segundos para milissegundos
            data_list.append({'Tempo (ms)': t * 1000, 'Método': method})
    return pd.DataFrame(data_list)

df_24 = prepare_df(results_24)
df_4 = prepare_df(results_4)
```

```python
# 3. Plotagem Lado a Lado (2x2 Grid)
fig, axes = plt.subplots(2, 2, figsize=(18, 14))

# Paleta de Cores
color_palette = {
    'mcovar1': 'blue',
    'mcovar2': 'green',
    'mcovar3': 'red',
    'mcovar4': 'purple',
    'NumPy Cov': 'orange'
}

# Histograma - 24 Sensores
sns.histplot(data=df_24, x='Tempo (ms)', hue='Método', kde=True,␣
 ↪element="step", ax=axes[0, 0], palette=color_palette, log_scale=True,␣
 ↪stat="density")
axes[0, 0].set_title('Histograma - 24 Sensores')

# Histograma - 4 Sensores
sns.histplot(data=df_4, x='Tempo (ms)', hue='Método', kde=True, element="step",␣
 ↪ax=axes[0, 1], palette=color_palette, log_scale=True, stat="density")
axes[0, 1].set_title('Histograma - 4 Sensores')

# Violin Plot - 24 Sensores
sns.violinplot(data=df_24, x='Método', y='Tempo (ms)', inner="quartile",␣
 ↪ax=axes[1, 0], palette=color_palette, log_scale=True)
axes[1, 0].set_title('Violin Plot - 24 Sensores')

# Violin Plot - 4 Sensores
sns.violinplot(data=df_4, x='Método', y='Tempo (ms)', inner="quartile",␣
 ↪ax=axes[1, 1], palette=color_palette, log_scale=True)
axes[1, 1].set_title('Violin Plot - 4 Sensores')

plt.tight_layout()
plt.show()
```

```
Executando benchmark para 24 sensores (100 rodadas)…

Executando benchmark para 4 sensores (100 rodadas)…
```

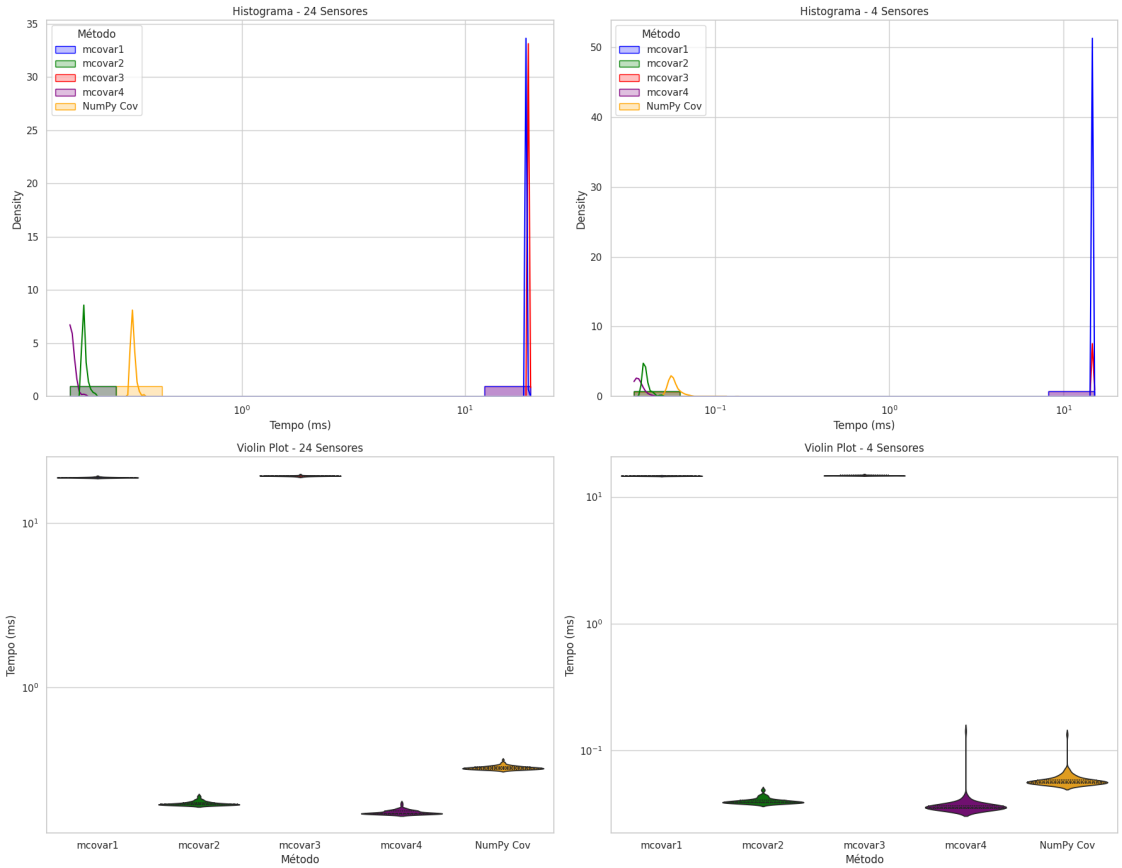

[7]:
```
import pandas as pd
from IPython.display import display

def print_stats(results, title):
    df = pd.DataFrame([
        [method, np.mean(times) * 1000, np.std(times) * 1000]
        for method, times in results.items()
    ], columns=["Método", "Média (ms)", "Desvio (ms)"])
    print(f"\n{title}")
    display(df)

print_stats(results_24, "Resultados Estatísticos (24 Sensores)")
print_stats(results_4, "Resultados Estatísticos (4 Sensores)")
```

```
Resultados Estatísticos (24 Sensores)

      Método  Média (ms)  Desvio (ms)
0    mcovar1   18.839858     0.098792
1    mcovar2    0.196583     0.005727
2    mcovar3   19.265788     0.107479
```

```
3    mcovar4    0.173840     0.005420
4  NumPy Cov    0.324168     0.008225


Resultados Estatísticos (4 Sensores)

      Método  Média (ms)  Desvio (ms)
0    mcovar1   14.620077     0.051505
1    mcovar2    0.040232     0.002213
2    mcovar3   14.734377     0.073001
3    mcovar4    0.037364     0.010726
4  NumPy Cov    0.058722     0.008501
```

1.0.7 Testando estatisticas sobre os resultados

- Agora testaremos se o calculo de covariancia do numpy e os metodos implementados, entre si, são estatisticamente diferentes, estamos interessados especialmente se `mcovar1` e `mcovar3` são estatisticamente diferentes. Assim como `mcovar4`e `NumPy Cov`.

[8]:
```
from scipy.stats import mannwhitneyu
df_24_m1 = df_24[df_24['Método'] == 'mcovar1']
df_24_m2 = df_24[df_24['Método'] == 'mcovar2']
df_24_m3 = df_24[df_24['Método'] == 'mcovar3']
df_24_m4 = df_24[df_24['Método'] == 'mcovar4']
df_24_m5 = df_24[df_24['Método'] == 'NumPy Cov']
```

[9]:
```
stats, p = mannwhitneyu(df_24_m5['Tempo (ms)'], df_24_m4['Tempo (ms)'])
if p < 0.05:
    print("Existem diferenças significativas entre os métodos mcovar4 e Numpy␣
 ↪Cov")
else:
    print("Não existem diferenças significativas entre os métodos")
```

```
Existem diferenças significativas entre os métodos mcovar4 e Numpy Cov
```

[10]:
```
stats, p = mannwhitneyu(df_24_m2['Tempo (ms)'], df_24_m4['Tempo (ms)'])
if p < 0.05:
    print("Existem diferenças significativas entre os métodos mcovar2 e␣
 ↪mcovar4")
else:
    print("Não existem diferenças significativas entre os métodos")
```

```
Existem diferenças significativas entre os métodos mcovar2 e mcovar4
```

[11]:
```
stats, p = mannwhitneyu(df_24_m1['Tempo (ms)'], df_24_m3['Tempo (ms)'])
if p < 0.05:
    print("Existem diferenças significativas entre os métodos mcovar1 e␣
 ↪mcovar3")
else:
```

```
    print("Não existem diferenças significativas entre os métodos")
```

```
Existem diferenças significativas entre os métodos mcovar1 e mcovar3
```

1.1 Q3 - Avaliação da invertibilidade com base no metodo mais rapido.

[12]:
```
data_24_df.head()
```

[12]:
```
     US1    US2    US3    US4  US5    US6  US7    US8    US9   US10  …  \
0  0.438  0.498  3.625  3.645  5.0  2.918  5.0  2.351  2.332  2.643  …
1  0.438  0.498  3.625  3.648  5.0  2.918  5.0  2.637  2.332  2.649  …
2  0.438  0.498  3.625  3.629  5.0  2.918  5.0  2.637  2.334  2.643  …
3  0.437  0.501  3.625  3.626  5.0  2.918  5.0  2.353  2.334  2.642  …
4  0.438  0.498  3.626  3.629  5.0  2.918  5.0  2.640  2.334  2.639  …

    US16   US17   US18   US19   US20   US21   US22   US23   US24  \
0  0.593  0.502  0.493  0.504  0.445  0.431  0.444  0.440  0.429
1  0.592  0.502  0.493  0.504  0.449  0.431  0.444  0.443  0.429
2  0.593  0.502  0.493  0.504  0.449  0.431  0.444  0.446  0.429
3  0.593  0.502  0.493  0.504  0.449  0.431  0.444  0.444  0.429
4  0.592  0.502  0.493  0.504  0.449  0.431  0.444  0.441  0.429

               Class
0  Slight-Right-Turn
1  Slight-Right-Turn
2  Slight-Right-Turn
3  Slight-Right-Turn
4  Slight-Right-Turn

[5 rows x 25 columns]
```

[13]:
```
# Usando mcovar4 iremos estimar a matriz de covariancia de cada classe.
import numpy as np

def analyze_invertibility(df, label):
    print(f"Análise de Invertibilidade: {label}")
    X = df.drop(columns=['Class'])
    y = df['Class']

    # Matriz de Covariância Global
    cov_global = mcovar4(X)
    rank_g = np.linalg.matrix_rank(cov_global)
    cond_g = np.linalg.cond(cov_global)
    rcond_g = 1 / cond_g
    print(f"Global -> Posto: {rank_g}, Cond: {cond_g:.2e}, RCond: {rcond_g:.
 ↪2e}")
```

```
    # Matrizes de Covariância por Classe
    for c in np.unique(y):
        X_c = X[y == c]
        cov_c = mcovar4(X_c)
        rank_c = np.linalg.matrix_rank(cov_c)
        cond_c = np.linalg.cond(cov_c)
        rcond_c = 1 / cond_c
        print(f"Classe {c} -> Posto: {rank_c}, Cond: {cond_c:.2e}, RCond:␣
↪{rcond_c:.2e}")
    print("-" * 50)

analyze_invertibility(data_24_df, "data_24_df")
analyze_invertibility(data_4_df, "data_4_df")
```

```
Análise de Invertibilidade: data_24_df

Global -> Posto: 23, Cond: 4.61e+20, RCond: 2.17e-21
Classe Move-Forward -> Posto: 23, Cond: 3.39e+20, RCond: 2.95e-21
Classe Sharp-Right-Turn -> Posto: 23, Cond: 2.65e+20, RCond: 3.77e-21
Classe Slight-Left-Turn -> Posto: 23, Cond: 4.02e+19, RCond: 2.49e-20
Classe Slight-Right-Turn -> Posto: 23, Cond: 2.09e+20, RCond: 4.78e-21
--------------------------------------------------
Análise de Invertibilidade: data_4_df
Global -> Posto: 3, Cond: 5.14e+34, RCond: 1.94e-35
Classe Move-Forward -> Posto: 3, Cond: 6.19e+33, RCond: 1.62e-34
Classe Sharp-Right-Turn -> Posto: 3, Cond: 2.07e+34, RCond: 4.84e-35
Classe Slight-Left-Turn -> Posto: 3, Cond: 3.79e+18, RCond: 2.64e-19
Classe Slight-Right-Turn -> Posto: 3, Cond: 6.31e+34, RCond: 1.58e-35
--------------------------------------------------
```

1.1.1 As matrizes acimas são singulares, não possuem posto completo. Assim, não podem ser invertidas e iremos regularizar.

[14]:
```
def reg_matriz(df: pd.DataFrame) -> pd.DataFrame:
    """
    Adiciona regularização a uma matriz de covariância.
    """

    lamb = 0.1
    lambI = lamb * np.eye(df.shape[1])
    return df + lambI
```

[15]:
```
def inverter_reg(df, label):
    print(f"Análise de Invertibilidade: {label}")
    X = df.drop(columns=['Class'])
    y = df['Class']
```

```python
    # Matriz de Covariância Global
    cov_global = mcovar4(X)

    cov_global = reg_matriz(cov_global)

    # Tentar inverter, se possivel, retornar mensagem de erro
    try:
        np.linalg.inv(cov_global)
        print("Global -> Invertível")
    except np.linalg.LinAlgError:
        print("Global -> Não Invertível")

    rank_g = np.linalg.matrix_rank(cov_global)
    cond_g = np.linalg.cond(cov_global)
    rcond_g = 1 / cond_g
    print(f"Global -> Posto: {rank_g}, Cond: {cond_g:.2e}, RCond: {rcond_g:.
 ↪2e}")

    # Matrizes de Covariância por Classe
    for c in np.unique(y):
        X_c = X[y == c]
        cov_c = mcovar4(X_c)

        cov_c = reg_matriz(cov_c)

        try:
            np.linalg.inv(cov_c)
            print(f"Classe {c} -> Invertível")
        except np.linalg.LinAlgError:
            print(f"Classe {c} -> Não Invertível")

        rank_c = np.linalg.matrix_rank(cov_c)
        cond_c = np.linalg.cond(cov_c)
        rcond_c = 1 / cond_c
        print(f"Classe {c} -> Posto: {rank_c}, Cond: {cond_c:.2e}, RCond:␣
 ↪{rcond_c:.2e}")
    print("-" * 50)

analyze_invertibility(data_24_df, "data_24_df")
analyze_invertibility(data_4_df, "data_4_df")
```

```
Análise de Invertibilidade: data_24_df
Global -> Posto: 23, Cond: 4.61e+20, RCond: 2.17e-21
Classe Move-Forward -> Posto: 23, Cond: 3.39e+20, RCond: 2.95e-21
Classe Sharp-Right-Turn -> Posto: 23, Cond: 2.65e+20, RCond: 3.77e-21
Classe Slight-Left-Turn -> Posto: 23, Cond: 4.02e+19, RCond: 2.49e-20
Classe Slight-Right-Turn -> Posto: 23, Cond: 2.09e+20, RCond: 4.78e-21
```

```
--------------------------------------------------
Análise de Invertibilidade: data_4_df
Global -> Posto: 3, Cond: 5.14e+34, RCond: 1.94e-35
Classe Move-Forward -> Posto: 3, Cond: 6.19e+33, RCond: 1.62e-34
Classe Sharp-Right-Turn -> Posto: 3, Cond: 2.07e+34, RCond: 4.84e-35
Classe Slight-Left-Turn -> Posto: 3, Cond: 3.79e+18, RCond: 2.64e-19
Classe Slight-Right-Turn -> Posto: 3, Cond: 6.31e+34, RCond: 1.58e-35
--------------------------------------------------
```