1º Trabalho Computacional

Lucas José Lemos Braz - 587388

[1]Programa de Pós-Graduação em Engenharia de Teleinformática

lucas.jlb19@alu.ufc.br

1. Introdução

Este relatório realiza a análise de diferentes modelos de regressão para o problema de avaliação de imóveis, utilizando o dataset *Real Estate Valuation*. A análise comparativa é estendida para incluir os resultados do trabalho de referência de Yeh & Hsu (2018), o que estabelece um benchmark para os modelos desenvolvidos. Entre eles estão o de Mínimos Quadrados (MQ), o Perceptron Logístico (PS), o Perceptron Multicamadas (MLP) com uma e duas camadas ocultas (MLP-H1 e MLP-H2), além de modelos de referência provenientes de bibliotecas.

A análise subsequente mostrará que, quando acompanhado de um pré-processamento criterioso dos dados, até mesmo modelos lineares podem rivalizar com arquiteturas não lineares mais complexas, enquanto as abordagens baseadas em árvores de decisão se destacam por oferecer o desempenho mais robusto diante deste problema.

2. Metodologia

2.1. Análise exploratória e preparação dos dados

O conjunto de dados *Real Estate Valuation* (UCI) foi organizado em matriz de atributos $\mathbf{X}$ e vetor-alvo $\mathbf{y}$, correspondente ao preço por unidade de área. A inspeção inicial incluiu estatísticas descritivas, verificação de valores ausentes, não foram identificados dados faltantes, análise de histogramas univariados para avaliar assimetria e presença de caudas, além de uma análise bivariada com base na matriz de correlação entre atributos e alvo. Constatou-se baixa associação linear entre a data de transação e o preço, o que motivou testes preliminares com e sem a utilização dessa variável. Optou-se, contudo, por mantê-la nas análises finais a fim de preservar a comparabilidade com o estudo de referência.

2.2. Esquemas de normalização e experimentos de controle

Foram conduzidos quatro experimentos paralelos para avaliar o efeito do pré-processamento das entradas. Salvo indicação em contrário, apenas $\mathbf{X}$ foi transformada e $\mathbf{y}$ permaneceu na escala original. Os esquemas investigados foram: (i) sem normalização; (ii) padronização por z-score (centralização pela média e escala pelo desvio-padrão); (iii) transformação *min–max* (reescala para $[0, 1]$); e (iv) normalização robusta por mediana e intervalo interquartil (IQR). Todas as transformações foram ajustadas exclusivamente nos dados de treino de cada *fold* e aplicadas aos conjuntos de validação e teste, de modo a evitar vazamento de informação. O PS emprega ativação sigmoide na saída, cujo suporte é $(0, 1)$. Para compatibilizar a faixa do alvo $y \in [8, 110]$ com essa saída, adotamos **normalização *min–max* apenas para $\mathbf{y}$ no treinamento/validação do PS**. As predições do PS foram sempre revertidas para a escala original antes de calcular métricas e gerar gráficos. Nos demais modelos, $\mathbf{y}$ permaneceu na escala original.

2.3. Protocolo de treinamento, validação e teste

Os dados foram particionados uma única vez em treino/teste (66/34), como no estudo de referência. A seleção de hiperparâmetros ocorreu *exclusivamente* no conjunto de treinamento, por Validação Cruzada (CV) com $k = 5$. Para cada configuração, o modelo foi ajustado nos *folds* de treino e avaliado nos *folds* de validação, com as normalizações estimadas apenas nos dados de treino de cada partição. Ao término desse processo, a configuração com melhor desempenho médio em validação foi selecionada. Em seguida, o modelo final foi reestimado utilizando todo o conjunto de treinamento e, por fim, avaliado no conjunto de teste retido. Todas as partições e inicializações foram conduzidas com sementes fixas, assegurando a plena reprodutibilidade dos resultados. Além das médias de CV, agregamos predições *out-of-fold* (OOF) para diagnóstico global de resíduos em treino, sem uso do conjunto de teste.

2.4. Métricas e procedimentos de avaliação

A aderência dos modelos foi examinada por meio de gráficos de dispersão entre valores observados e preditos (treinamento e teste), acompanhados dos respectivos coeficientes de correlação linear. As métricas primárias de desempenho consideradas foram Hit@10, Hit@20, R^2 e RMSE. Adicionalmente, reportamos o RMSE normalizado pelo preço médio (RMSE/Preço).

Definição formal do Hit@k. Para cada amostra i, dizemos que houve acerto relativo a k se

$$\frac{|y_i - \hat{y}_i|}{y_i} \leq \frac{k}{100}. \tag{1}$$

O indicador Hit@k é a fração de acertos no conjunto considerado:

$$\text{Hit@}k = \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}\left(\frac{|y_i - \hat{y}_i|}{y_i} \leq \tfrac{k}{100}\right), \tag{2}$$

onde $\mathbf{1}(\cdot)$ é a função indicadora.

Os resíduos de treino dos modelos selecionados foram analisados via histograma e teste de Shapiro–Wilk (nível $\alpha = 0{,}05$). Sempre que observada discrepância em relação à gaussianidade (caudas pesadas/assimetria), discutimos implicações para inferência e escolha de métricas.

2.5. Critério de seleção de modelos

Para escolher um "melhor" por família (MQ, PS, MLP-1C, MLP-2C e *benchmarks*), adotamos critério lexicográfico: **Hit@10 (maior)** $\rightarrow$ **Hit@20 (maior)** $\rightarrow$ $\mathbf{R^2}$ (maior) $\rightarrow$ **RMSE (menor)**. O critério é aplicado uniformemente em todas as buscas e relatórios.

2.6. Espaços de hiperparâmetros e procedimentos de busca

A seleção de hiperparâmetros foi conduzida por meio de *random search*, com orçamento de 60 testes, aplicado às redes neurais e ao PS. Para o MQ, empregou-se *grid search*. Em todos os casos, a busca foi realizada com validação cruzada $k = 5$, com as normalizações estimadas exclusivamente a partir dos dados de treinamento.

Tabela 1. Espaços de hiperparâmetros e procedimentos de busca utilizados nos modelos.

Modelo	Hiperparâmetros	Valores considerados	Procedimento de busca
MLP-1C	Neurônios na camada oculta	4, 8, 16, 32, 64, 128, 256, 512	Random Search (60 amostras)
	Função de ativação	`sigmoid`, `tanh`, `relu`, `leaky_relu`	
	Épocas	100, 150, 200, 300	
	Taxa de aprendizado	$10^{-3}, 5 \cdot 10^{-3}, 10^{-2}$	
	Normalização	none, zscore, minmax, iqr	
	Critério de seleção	desempenho médio em CV (5 folds)	
MLP-2C	Neurônios na 1ª camada	4, 8, 16, 32, 64, 128, 256, 512	Random Search (60 amostras)
	Neurônios na 2ª camada	4, 8, 16, 32, 64, 128, 256, 512	
	Função de ativação	`sigmoid`, `tanh`, `relu`, `leaky_relu`	
	Épocas	100, 150, 200, 300	
	Taxa de aprendizado	$10^{-3}, 5 \cdot 10^{-3}, 10^{-2}$	
	Normalização	none, zscore, minmax, iqr	
PS (PS)	Épocas	100, 150, 200, 300	Random Search (60 amostras)
	Taxa de aprendizado	$10^{-3}, 5 \cdot 10^{-3}, 10^{-2}$	
	Normalização	none, zscore, minmax, iqr	
	Ativação	sigmoide (saída compatível com min–max do alvo)	
MQ (Ridge)	Parâmetro de regularização (λ)	0.0, 10^{-4}, 10^{-3}, 10^{-2}, $5 \cdot 10^{-2}$, 10^{-1}, 0.5, 1.0, 2.0, 5.0, 10.0	Grid Search
	Normalização	none, zscore, minmax, iqr	
	Critério de seleção	desempenho médio em CV (5 folds)	

2.7. Modelos de referência e comparação

Como *benchmark*, ajustamos Support Vector Regression (SVR), Random Forest e Gradient Boosting (`scikit-learn`) sob o mesmo protocolo de particionamento, normalização das entradas e validação cruzada do conjunto de treinamento, com avaliação final no teste retido pelas mesmas métricas. Houve uma busca manual dos hiperparâmetros para esses *benchmarks*; os valores foram **pré-fixados** e mantidos constantes em toda a avaliação.

Tabela 2. Modelos e hiperparâmetros selecionados.

Modelo	Pré-processamento	Hiperparâmetros
Random Forest	`StandardScaler`	n_estimators=100; max_depth=None; max_features=1.0; min_samples_split=2; min_samples_leaf=1; bootstrap=True; criterion='squared_error'; random_state=42; n_jobs=-1
Gradient Boosting	`RobustScaler`	n_estimators=100; learning_rate=0.1; max_depth=3; subsample=1.0; loss='squared_error'; criterion='friedman_mse'; alpha=0.9; random_state=42; tol=1e-4; validation_fraction=0.1
SVR (RBF)	`RobustScaler`	kernel='rbf'; C=1.0; epsilon=0.1; gamma='scale'; tol=1e-3; max_iter=-1; shrinking=True

2.8. Implementação e Reprodutibilidade

Os modelos principais (MQ, PS, MLP-1C e MLP-2C) foram implementados em Python com rotinas matriciais de baixo nível, o que permitiu controle direto sobre inicialização, função de custo e retropropagação. Os *benchmarks* comparativos foram ajustados com `scikit-learn`. Todo o material necessário para reprodução dos experimentos, incluindo análises exploratórias (EDA), variações de normalização e geração de figuras, encontra-se disponível em repositório público no GitHub:

`https://github.com/LucasJLBraz/Trabalhos_IC_Aplicada`

As versões de Python e bibliotecas, assim como as sementes aleatórias utilizadas, estão registradas nos notebooks e no arquivo de configuração do projeto.

A Tabela 3 resume os arquivos e diretórios mais relevantes para a reprodutibilidade do Trabalho 1.

Tabela 3. Arquivos e diretórios relevantes para a reprodutibilidade do Trabalho 1.

Caminho	Descrição
`README.md`	Instruções detalhadas para configuração do ambiente e execução dos experimentos.
`notebooks/TC1/`	Diretório principal contendo os Jupyter Notebooks dos experimentos.
`MQO.ipynb`	Experimento de Regressão Linear por Mínimos Quadrados (MQ).
`perceptron-...ipynb`	Experimento com o modelo Perceptron de Regressão.
`MLP_H1.ipynb`	Experimento com MLP de uma camada oculta.
`MLP_H2.ipynb`	Experimento com MLP de duas camadas ocultas.
`trabalho_ic_aplicada/`	Pacote Python que contém a lógica dos modelos e funções de suporte.
`models/ridge_reg....py`	Implementação da Regressão Linear (MQ).
`models/reg_perc....py`	Implementação do Perceptron para Regressão.
`models/reg_mlp.py`	Implementação da MLP para Regressão.
`models/aux.py`	Funções auxiliares para métricas (REQM, R^2), validação cruzada e geração de gráficos.
`results/TC1/`	Diretório destinado às saídas dos experimentos (histogramas de resíduos, gráficos de dispersão, etc.).

2.9. Ameaças à validade e controles

Toda análise empírica está sujeita a limitações que podem comprometer a validade interna e externa dos resultados. No presente trabalho, destacamos algumas ameaças relevantes e as estratégias adotadas para mitigá-las, para assegurar maior robustez às conclusões.

1. **Tamanho amostral moderado** ($n = 414$), sujeito à influência de pontos extremos.
2. **Heterocedasticidade e caudas pesadas**, que podem afetar a confiabilidade das inferências.
3. **Colinearidade entre atributos espaciais**, inflando potencialmente as incertezas em modelos lineares.
4. **Particionamento aleatório**, que não controla a autocorrelação espacial existente nos dados.

Como medidas de controle, evitamos vazamento nas normalizações, utilizamos validação cruzada no conjunto de treinamento, reportamos predições OOF agregadas para diagnóstico e mantivemos critérios uniformes de seleção de modelos.

3. Resultados

Esta seção apresenta os principais achados obtidos a partir dos experimentos conduzidos. Inicialmente, descrevemos uma análise exploratória detalhada do conjunto de dados, seguida pelo diagnóstico estatístico das variáveis. Em seguida, relatamos o desempenho dos diferentes modelos ajustados, comparando-os de forma sistemática segundo os critérios estabelecidos na metodologia.

3.1. Análise Exploratória e Diagnóstico dos Dados

O conjunto *Real Estate Valuation* apresenta preditores em escalas muito distintas, o que justifica a avaliação sistemática de diferentes esquemas de normalização. A estatística descritiva (Tabela 4) evidencia contrastes relevantes, uma vez que a distância à estação de metrô (MRT) apresenta forte assimetria à direita, com média de 1084 e desvio padrão de 1262, ao passo que o número de lojas de conveniência constitui uma variável discreta de baixa cardinalidade.

Tabela 4. Sumário descritivo das variáveis preditoras.

	X1 transaction date	X2 house age	X3 distance to MRT	X4 # convenience stores	X5 latitude	X6 longitude
count	414	414	414	414	414	414
mean	2013.15	17.71	1083.89	4.09	24.97	121.53
std	0.28	11.39	1262.11	2.95	0.01	0.02
min	2012.67	0	23.38	0	24.93	121.47
25%	2012.92	9.03	289.32	1	24.96	121.53
50%	2013.17	16.10	492.23	4	24.97	121.54
75%	2013.42	28.15	1454.28	6	24.98	121.54
max	2013.58	43.80	6488.02	10	25.01	121.57

A matriz de correlação (Figura 1) confirma associações lineares consistentes com a literatura. Observa-se uma correlação negativa elevada entre o preço e a distância ao MRT, com $r \approx -0.67$, além de correlações positivas moderadas com o número de lojas ($r \approx 0.57$) e com as coordenadas geográficas (latitude, $r \approx 0.55$; longitude, $r \approx 0.52$). Também se destaca a alta correlação entre os próprios preditores espaciais, como distância ao MRT e longitude ($r \approx -0.81$), o que sugere a presença de colinearidade, aspecto relevante para a estabilidade de modelos lineares.

3.2. Análise de Desempenho dos Modelos Implementados

A seguir, detalha-se o desempenho dos melhores modelos de cada classe, selecionados conforme o critério lexicográfico (*Hit@10* $\rightarrow$ *Hit@20* $\rightarrow R^2 \rightarrow$ RMSE) aplicado sobre os resultados da validação cruzada.

3.2.1. Modelo de Mínimos Quadrados (MQ)

O melhor modelo linear foi obtido com normalização robusta, baseada no intervalo interquartil, e regularização *Ridge* ($\lambda = 0.5$). No conjunto de teste, o modelo apresentou desempenho satisfatório, com $\mathrm{RMSE} = 7.06$ e $R^2 = 0.689$.

A Figura 2 evidencia um bom alinhamento entre os valores preditos e observados, ainda que se note uma tendência à subestimação em imóveis de maior valor. Esse comportamento, frequentemente encontrado em dados imobiliários, sugere a presença de

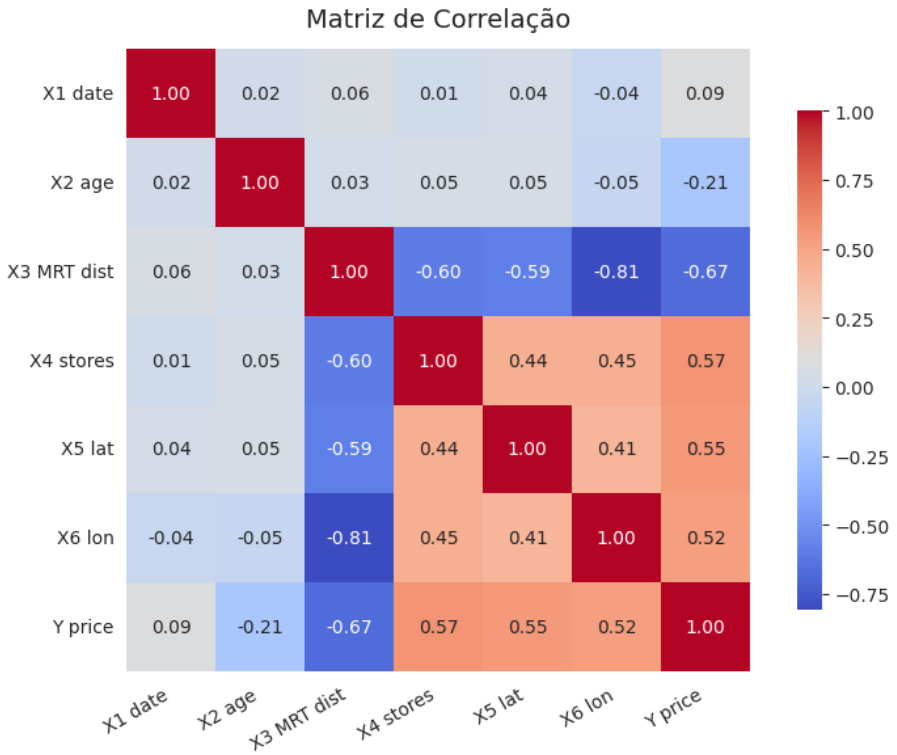

Figura 1. Matriz de correlação entre as variáveis preditoras e a variável alvo (preço).

heterocedasticidade, já que a variância do erro tende a crescer com o preço do imóvel. O histograma dos resíduos de treino reforça essa interpretação, exibindo uma cauda longa à direita, associada principalmente a *outliers* de alto valor. A análise formal por meio do teste de Shapiro–Wilk confirmou a ausência de normalidade nos resíduos ($W = 0.819$, $p < 10^{-4}$), em consonância com a assimetria previamente observada.

Apesar dessas limitações, a correlação entre valores observados e preditos (Tabela 5) mostrou-se elevada e consistente tanto no treino quanto no teste, indicando boa generalização. Esse resultado reforça que a combinação de normalização robusta (IQR) e regularização L2 estabilizou a estimação frente à colinearidade e aos *outliers*, mantendo coeficientes interpretáveis e coerentes com o domínio (Tabela 6). Os coeficientes referem-se às variáveis preditoras na escala normalizada por IQR.

Tabela 5. MQ: Correlação (r) entre valores observados e preditos.

Conjunto	Correlação r
Treino	0.816
Teste	0.831

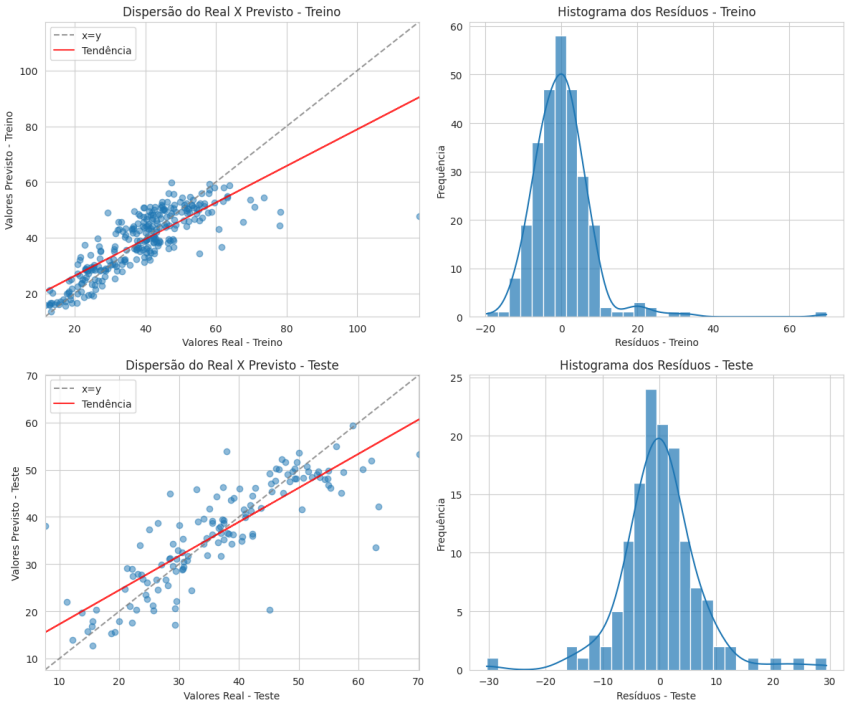

Figura 2. MQ: Dispersão observado vs. predito e histograma dos resíduos (treino/teste).

Tabela 6. MQ: Coeficientes estimados do modelo Ridge ($\lambda = 0.5$) com normalização robusta.

Variável	**Coeficiente** (b_i)
Intercepto (b_0)	40.42
X1: Data da transação	6.01
X2: Idade do imóvel	-8.57
X3: Distância até estação de MRT	-23.18
X4: Número de lojas de conveniência	4.82
X5: Latitude	14.67
X6: Longitude	2.61

3.2.2. Perceptron Logístico (PS)

O melhor modelo de Perceptron, configurado a função de ativação logística, foi treinado a partir de dados padronizados por z-score, empregando taxa de aprendizado de 0.005 e 300 épocas de treinamento. No conjunto de teste, o desempenho obtido correspondeu a $\mathrm{RMSE} = 7.79$ e $R^2 = 0.622$.

A análise das dispersões apresentadas na Figura 3 evidencia uma compressão na faixa de predições, fenômeno característico de funções de ativação sigmoides, que tende a provocar subestimação dos valores mais extremos. O padrão dos resíduos mostrou-se semelhante ao verificado no modelo MQ, destacando-se a presença de caudas pesadas e assimetria à direita no conjunto de treinamento. A avaliação estatística por meio do teste de Shapiro–Wilk rejeitou a hipótese de normalidade ($W = 0.822$, $p < 10^{-4}$), resultado

coerente com a assimetria observada.

As correlações reportadas na Tabela 7 revelam associações moderadamente altas entre valores observados e preditos, ainda que inferiores às verificadas no modelo MQ. A proximidade dos resultados entre os conjuntos de treino e teste sugere ausência de sobreajuste relevante, reforçando a estabilidade do modelo.

Em síntese, a padronização dos dados mostrou-se determinante para assegurar a convergência do algoritmo. Apesar de capturar adequadamente a tendência geral do fenômeno, as limitações inerentes à função de ativação logística comprometeram a capacidade de previsão em faixas de preços mais elevados, o que resultou em desempenho inferior ao do modelo linear regularizado.

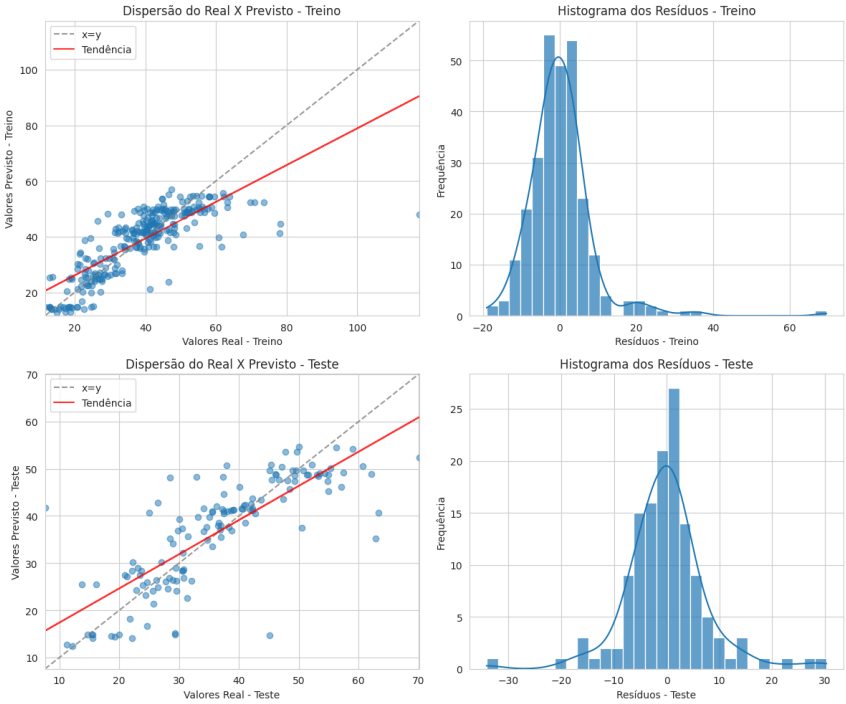

Figura 3. PS: Dispersão observado vs. predito e histograma dos resíduos (treino/teste).

Tabela 7. PS: Correlação (r) entre valores observados e preditos.

Conjunto	Correlação r
Treino	0.793
Teste	0.797

3.2.3. MLP com Uma Camada Oculta (MLP-1C)

A melhor MLP com uma camada oculta empregou padronização pelo z-score, função de ativação `leaky_relu`, 256 neurônios, e foi treinada por 200 épocas com taxa de aprendizado $lr = 0.005$. No conjunto de teste, o modelo alcançou $\mathrm{RMSE} = 7.65$ e $R^2 =$

0.635, resultados que, embora satisfatórios, já antecipam limitações quando comparados ao *baseline* linear.

A análise gráfica (Figura 4) confirma um alinhamento geral adequado, mas evidencia tendência de subestimação nos valores extremos. Esse comportamento decorre da maior capacidade representacional do modelo, possibilitada pelos 256 neurônios na camada oculta, que lhe permitiu ajustar-se aos dados de treinamento.

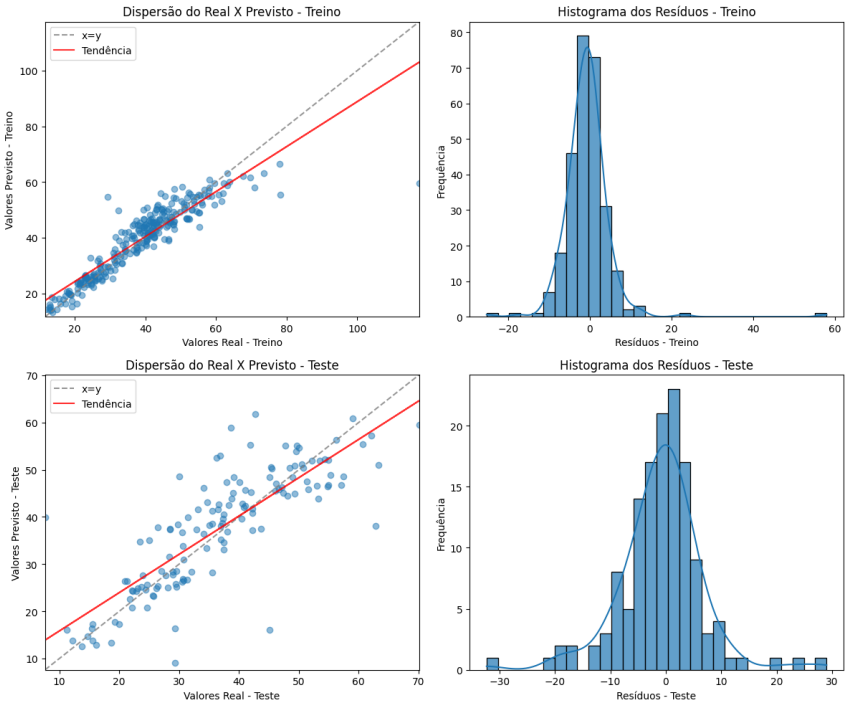

Figura 4. MLP-1C: Dispersão observado vs. predito e histograma dos resíduos (treino/teste).

Essa hipótese é corroborada pela análise dos resíduos. O teste de Shapiro–Wilk rejeitou a normalidade ($W = 0.745$, $p < 10^{-4}$), indicando caudas mais pesadas do que as observadas nos demais modelos. De forma consistente, as correlações apresentadas na Tabela 8 revelam diferença substancial entre treino ($r = 0.911$) e teste ($r = 0.818$), caracterizando a ocorrência de sobreajuste.

A combinação da função `leaky_relu` com a elevada capacidade da camada oculta favoreceu a memorização de parte dos dados de treinamento. Embora tenha capturado a tendência geral do fenômeno, o modelo não superou o *baseline* linear, o que indica que sua complexidade mostrou-se excessiva para o tamanho do conjunto de dados disponível.

Tabela 8. MLP-1C: Correlação (r) entre valores observados e preditos.

Conjunto	Correlação r
Treino	0.911
Teste	0.818

3.2.4. MLP com Duas Camadas Ocultas (MLP-2C)

A melhor arquitetura com duas camadas ocultas, configurada com $[64, 32]$ neurônios, empregou normalização *min–max*, função de ativação `tanh` e taxa de aprendizado $lr = 0.01$. No conjunto de teste, o modelo apresentou $\mathrm{RMSE} = 7.18$ e $R^2 = 0.679$, valores competitivos em relação ao baseline linear.

A análise gráfica (Figura 5) revela um desempenho visualmente próximo ao obtido pelo modelo MQ, caracterizado por ajuste robusto, ainda que sujeito à heterocedasticidade presente nos dados. A inspeção dos resíduos confirmou essa limitação, uma vez que o teste de Shapiro–Wilk rejeitou a hipótese de normalidade ($W = 0.804$, $p < 10^{-4}$). As correlações reportadas na Tabela 9 mostraram-se elevadas e bastante próximas entre treino ($r = 0.841$) e teste ($r = 0.828$), sugerindo que esta arquitetura, embora mais profunda, foi menos suscetível ao sobreajuste do que a MLP-1C, possivelmente em razão do menor número total de parâmetros.

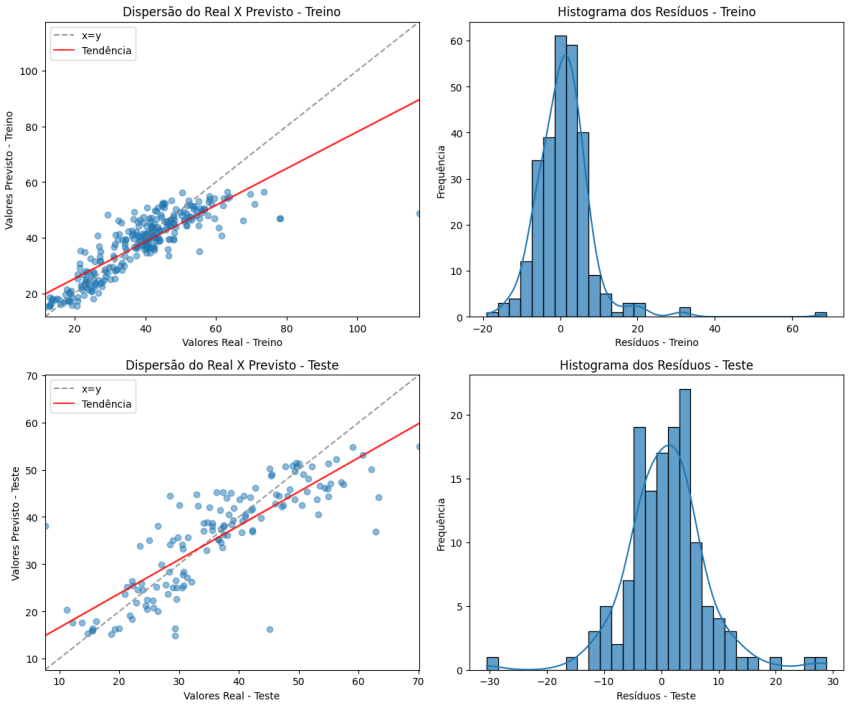

Figura 5. MLP-2C: Dispersão observado vs. predito e histograma dos resíduos (treino/teste).

Tabela 9. MLP-2C: Correlação (r) entre valores observados e preditos.

Conjunto	Correlação r
Treino	0.841
Teste	0.828

A combinação da normalização *min–max* com a função de ativação `tanh` mostrou-se adequada para esta configuração, permitindo que o modelo atingisse desempenho competitivo e comparável ao do MQ. Esses resultados indicam que, neste problema,

arquiteturas não lineares mais profundas podem reproduzir a eficácia de um modelo linear bem regularizado, sem necessariamente superá-lo.

3.2.5. Random Forest (RF)

O modelo de Random Forest, treinado a partir de dados padronizados, apresentou o melhor desempenho geral entre os algoritmos avaliados. No conjunto de teste, alcançou o menor erro ($\mathrm{RMSE} = 6.69$) e o maior coeficiente de determinação ($R^2 = 0.721$), superando tanto os modelos lineares quanto as redes neurais analisadas.

A inspeção dos gráficos de dispersão (Figura 6) evidencia o alinhamento mais consistente entre valores observados e preditos, com menor viés sistemático nos imóveis de maior valor. Esse comportamento reflete a capacidade intrínseca de modelos baseados em árvores de capturar interações não lineares e efeitos de ordem superior, aspecto que mostrou-se particularmente relevante neste problema.

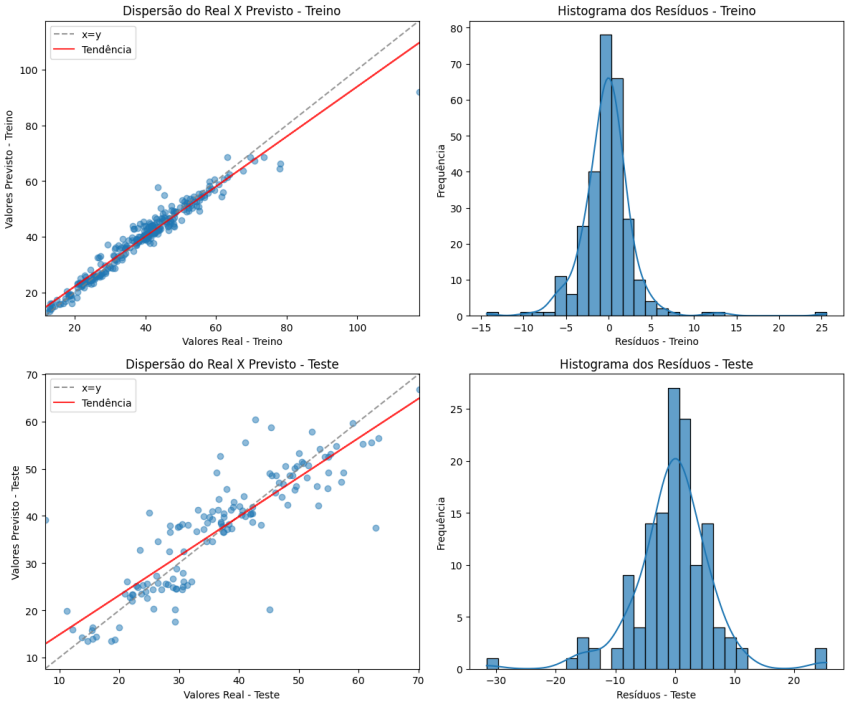

Figura 6. RF: Dispersão observado vs. predito e histograma dos resíduos (treino/teste).

Embora a hipótese de normalidade dos resíduos tenha sido rejeitada pelo teste de Shapiro–Wilk ($W = 0.828$, $p < 10^{-4}$), tal pressuposto não constitui requisito para o funcionamento de algoritmos de árvores. As correlações confirmam o bom ajuste: no conjunto de teste, obteve-se $r = 0.857$, o valor mais elevado entre todos os modelos, enquanto a correlação em treino ($r = 0.976$) revela certo grau de sobreajuste. Esse comportamento, no entanto, é esperado no Random Forest e tende a ser atenuado pela agregação via *bagging*, que contribui para a estabilidade do modelo.

Outro aspecto distintivo do Random Forest é a possibilidade de estimar a importância relativa das variáveis. A análise baseada em permutação indicou que a **distância**

Tabela 10. RF: Correlação (r) entre valores observados e preditos.

Conjunto	Correlação r
Treino	0.976
Teste	0.857

ao MRT constitui o preditor mais relevante, seguida pelo **número de lojas de conveniência** e pela **latitude**. Em contraste, a data da transação mostrou-se a variável menos informativa, o que está em consonância com os achados da análise exploratória. Esses resultados reforçam a evidência de que a localização é o fator predominante na determinação do preço dos imóveis neste conjunto de dados.

3.3. Análise Comparativa e Discussão com a Referência

A Tabela 11 sumariza os resultados do teste de Shapiro-Wilk para os resíduos de treino de todos os modelos. A rejeição por todos os modelos da hipótese de normalidade ($p < 0.001$) é uma evidência de que os erros neste problema não seguem uma distribuição gaussiana, principalmente devido à presença de *outliers*.

Tabela 11. Teste de Shapiro-Wilk para os resíduos de treino por modelo.

Modelo	**Estatística** W	p**-valor**
Mínimos Quadrados (MQ)	0.819	$< 10^{-4}$
Perceptron Logístico (PS)	0.822	$< 10^{-4}$
MLP-1C	0.745	$< 10^{-4}$
MLP-2C	0.804	$< 10^{-4}$
Random Forest (RF)	0.828	$< 10^{-4}$

Já a Tabela 12 compara o desempenho dos modelos desenvolvidos neste trabalho com os resultados reportados por Yeh & Hsu (2018). Os modelos de referência são MVR (*Multiple Regression Valuation*), MLP e QCA (*Qualitative Comparative Analysis with Case-Based Reasoning*).

Tabela 12. Comparativo de desempenho no conjunto de teste.

Modelo	**RMSE**	R^2	**Hit@10%**	**Hit@20%**	**Preço Médio**	**RMSE/Preço Médio**
Random Forest (RF)	6.69	0.721	56.9	78.80	50.30	0.133
GradBoost	6.70	0.719	54.7	77.37	48.91	0.137
Mínimos Quadrados (MQ)	7.06	0.689	52.6	79.60	49.37	0.143
MLP-2C (64, 32)	7.18	0.679	46.7	83.20	45.16	0.159
SVR (RBF)	8.05	0.595	48.9	70.0	50.41	0.159
MLP-1C (256)	7.65	0.635	46.7	78.10	47.52	0.161
Perceptron Logístico (PS)	7.79	0.622	54.0	75.20	47.21	0.165
QCA (Referência)	6.85	0.582	48.1	78.0	36.05	0.190
MLP (Referência)	7.12	0.541	45.9	76.10	35.60	0.200
MVR (Referência)	8.04	0.392	39.1	68.70	35.89	0.224

É notável que múltiplos modelos desenvolvidos neste estudo superaram os benchmarks do artigo de referência em métricas como R^2 e *Hit@k*. O modelo Random Forest

demonstrou um desempenho superior ao melhor modelo de referência. Até mesmo nosso modelo linear (MQ), superou significativamente a MLP da referência.

Essas diferenças podem ser atribuídas ao nosso protocolo mais extensivo de busca de hiperparâmetros e à avaliação sistemática de diferentes esquemas de pré-processamento, que se mostraram cruciais para extrair o máximo de desempenho de cada classe de modelo. A principal conclusão é que, com um tratamento de dados e um ajuste de modelo cuidadosos, é possível obter resultados de ponta, com o modelo Random Forest se destacando como a abordagem mais precisa para este problema.

4. Conclusão

O estudo demonstrou que, para o dataset avaliado, um modelo linear simples (MQ), quando combinado com uma estratégia de pré-processamento robusta, pode superar o desempenho de modelos não-lineares mais complexos como as redes MLP.

Este resultado desafia a premissa de que a complexidade crescente do modelo invariavelmente leva a um melhor desempenho e destaca a importância crítica da preparação dos dados. A análise de diagnóstico revelou a presença de pontos influentes e heterocedasticidade, enquanto a não-normalidade universal dos resíduos aponta para características intrínsecas dos dados.