Funções de Probabilidade Normal e Propriedades

Guilherme de Alencar Barreto

gbarreto@ufc.br

Grupo de Aprendizado de Máquinas – GRAMA
Programa de Pós-Graduação em Engenharia de Teleinformática
Universidade Federal do Ceará – UFC
http://www.researchgate.net/profile/Guilherme_Barreto2/

Conteúdo da Apresentação

1. Objetivo Geral
2. FDP e FDA Gaussianas
3. Transformação de Box-Cox
4. Transformação Z-score e sua inversa
5. FDP Gaussiana Padronizada
6. Geração de Números Aleatórios
7. Histograma de Frequência
8. FDA Empírica
9. Exemplos no Matlab/Octave

Objetivo Geral

Objetivo Geral da Aula

Introduzir noções elementares sobre a função densidade de probabilidade (FDP) e a função de distribuição acumulada (FDA) normal e algumas de suas propriedades.

Parte I

FDP e FDA Gaussiana e Propriedades

Importância da FDP Gaussiana

- A FDP gaussiana é uma das mais importantes em ETI e em Ciências de um modo geral, pois é usada como modelo das flutuações aleatórias (ruído) que distorcem valores medidos de um determinada variável.
- Outras aplicações da FDP gaussiana:
  1. Ruídos em canais de comunicações.
  2. Robôs manipuladores (repetibilidade).
  3. Modelos de ruído em imagens digitais.
  4. Ruídos de medida em instrumentação eletrônica.
  5. Detecção de anomalias em Monitoramento de Processos.

Definição

- Uma VA contínua é chamada de *normal* ou *gaussiana* se sua FDP é dada por

$$\boxed{f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}} \tag{1}$$

ou

$$\boxed{f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}} \tag{2}$$

em que $\mu \in \mathbb{R}$ e $\sigma \in \mathbb{R}_{\geq 0}$ são constantes.

- O domínio da variável X é a reta dos números reais, ou seja, $-\infty < X < +\infty$.

Definição (cont.-1)

- A FDP gaussiana é completamente especificada por dois parâmetros:

$$\mu = E[X] = \int_{-\infty}^{\infty} x f_X(x) dx \quad (3)$$

$$\sigma^2 = E[(X-\mu)^2] = \int_{-\infty}^{\infty} (x-\mu)^2 f_X(x) dx \quad (4)$$

- Notação simplificada:

$$X \sim N(\mu, \sigma^2) \quad (5)$$

Definição (cont.-2)

- É equivalente fazer uma das seguintes afirmações:

1. Uma VA X segue uma lei de distribuição de probabilidade dada pela função gaussiana, cujos parâmetros são a média $\mu = E[X]$ e a variância $\sigma^2 = E[(X-\mu)^2]$.
2. Uma VA X está *distribuída* segundo uma FDP gaussiana de média $\mu = E[X]$ e variância $\sigma^2 = E[(X-\mu)^2]$.

Definição

- A FDA de uma VA contínua gaussiana é dada pela seguinte expressão:

$$
\begin{aligned}
F_X(x) &= P(X \leq x) = 1 - P(X > x) && (6)\\
&= \int_{-\infty}^{x} f_X(u)du \\
&= \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(u-\mu)^2}{2\sigma^2}\right\} du && (7)
\end{aligned}
$$

- Porém, **não** existe solução analítica exata para a FDA gaussiana.
- Soluções numéricas aproximadas são comumente dadas em tabelas.

Gráficos Genéricos da FDA e FDP Gaussianas

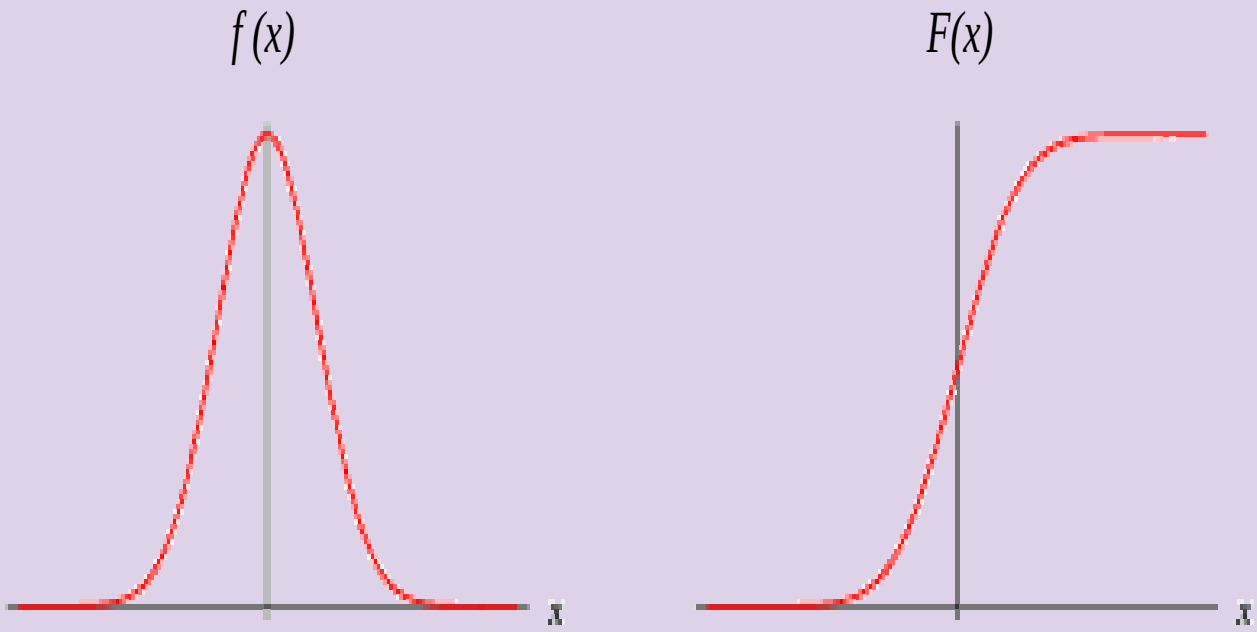

Probabilidade como a área sob a curva $f_X(x)$

- Pode-se mostrar que, para uma variável X contínua com FDP $f_X(x)$, probabilidades são dadas por

$$\Pr(a \leq X \leq b) = \int_a^b f_X(x)dx = F_X(b) - F_X(a), \qquad (8)$$

  ou seja, a $\Pr(a \leq X \leq b)$ é dada pela área sob a curva no intervalo $[a, b]$.
- Por isso, em um gráfico de PDF, não se lê probabilidades no eixo vertical, mas na área sob a curva.

Probabilidade como a área sob a curva $f_X(x)$

Dois resultados interessantes derivam da Equação 8.

1. Probabilidade de uma variável contínua assumir um valor específico é zero.
   Demonstração: Fazendo $a = b$ na Equação (8), tem-se

$$\Pr(a \leq X \leq a) = \Pr(X = a) = \int_a^a f_X(x)dx = F_X(a) - F_X(a) = 0. \tag{9}$$

2. Área total sob a curva de uma FDP é 1.
   Demonstração: Fazendo $a = -\infty$ e $b = +\infty$ na Equação (8), tem-se

$$\Pr(-\infty < X < +\infty) = \int_{-\infty}^{+\infty} f_X(x)dx = 1. \tag{10}$$

Gráficos das FDPs e FDAs para médias iguais ($\mu = 2$) e desvios-padrão diferentes $\sigma_1 = 1$, $\sigma_2 = 2$ e $\sigma_3 = 3$.

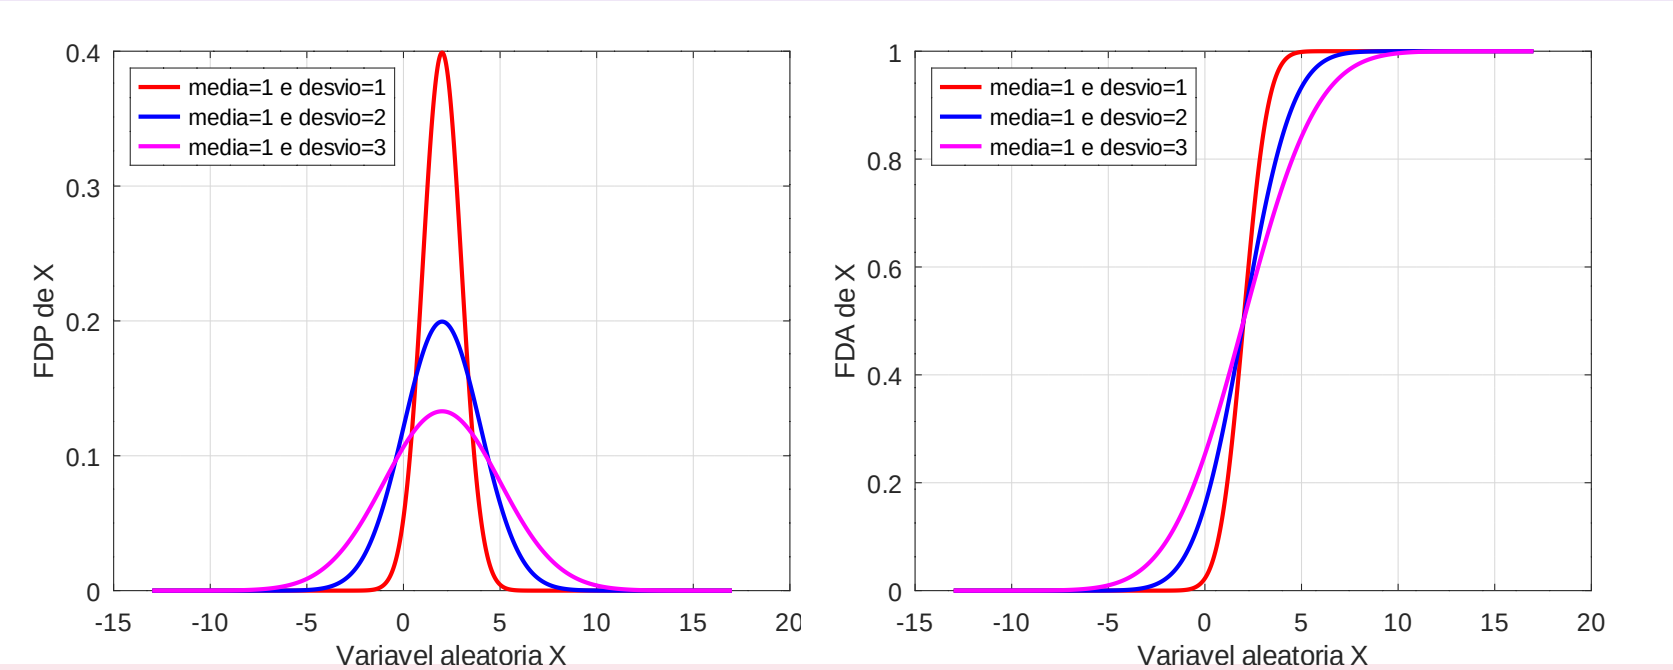

Definição (cont.-1)

- A FDP gaussiana é especificada por dois parâmetros:

$$\mu = \text{média populacional} \quad (11)$$
$$\sigma^2 = \text{variância populacional} \quad (12)$$

- O desvio padrão populacional é dado por $\sigma = \sqrt{\sigma^2}$.
- Que podem ser estimadas pelas seguintes fórmulas:

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n} \quad \text{(média amostral)} \quad (13)$$
$$s^2 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})^2}{n-1} \quad \text{(variância amostral)} \quad (14)$$
$$s = \sqrt{s^2} \quad \text{(desvio padrão amostral)} \quad (15)$$

Cálculo da Variância Amostral

X_1	$d_1 = x_1 - \bar{x}_1$	$d_1^2 = (x_1 - \bar{x}_1)^2$
480	-54=480-534	2916
500	-34=500-534	1156
380	-154=380-534	23716
1100	+566=1100-534	320356
1100	+566=1100-534	320356
230	-304=230-534	92416
490	-44=490-534	1936
250	-284=250-534	80656
300	-234=300-534	54756
510	-24=510-534	576
$\bar{x}_1 = 534$	$\sum(x_1 - \bar{x}_1) \approx 0$	$\sum(x_1 - \bar{x}_1)^2 = 898840$
$s^2 = \sum_{n=1}^{10}(x_1(n) - \bar{x}_1)^2/(10-1) = 898840/9 = 99871,11$		

Table: Tabela para cálculo passo-a-passo da variância amostral.

Gráfico da FDP Gaussiana e Probabilidades Intervalares

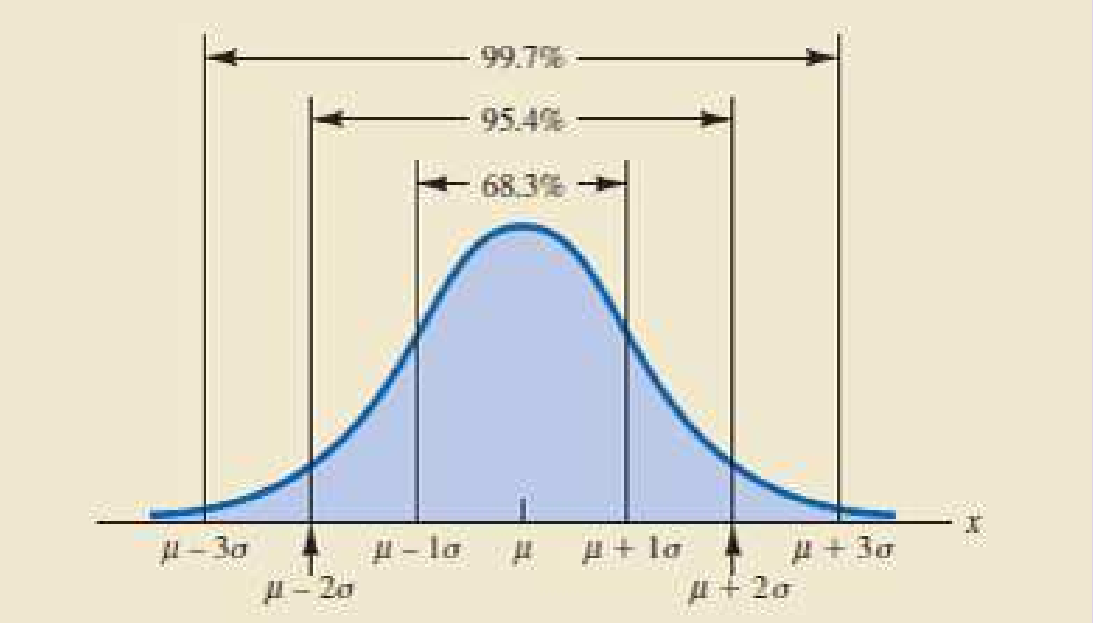

Entendendo a FDP Gaussiana

- Com base no gráfico anterior da FDP Gaussiana temos que:
  1. 68% dos valores de X estarão no intervalo $[\mu - \sigma, \mu + \sigma]$.

$$\Pr(\mu - \sigma \leq X \leq \mu + \sigma) \approx 0{,}68$$

  2. 95% dos valores de X estarão no intervalo $[\mu - 2\sigma, \mu + 2\sigma]$.

$$\Pr(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 0{,}95$$

  3. 99% dos valores de X estarão no intervalo $[\mu - 3\sigma, \mu + 3\sigma]$.

$$\Pr(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 0{,}99$$

- Esta propriedade da FDP gaussiana é usada para detecção de observações atípicas ou anômalas.

Aplicação em Detecção de Anormalidades em Processos

- Suponha que estejamos monitorando (medindo e armazenando) uma grandeza física X que representa o estado de um processo industrial.
- Se há razões para assumir que $X \sim N(\mu, \sigma^2)$, então podemos usar a seguinte regra de decisão:

$$\begin{array}{ll} \text{SE} & X \notin [\mu - 3\sigma, \mu + 3\sigma], \\ \text{ENTÃO} & X \text{ é um valor anômalo.} \end{array}$$

- No caso de detectar alguma anormalidade, o operador deve ser avisado (e.g. por meio de um alarme sonoro ou visual).

Aplicação em Controle de Processos

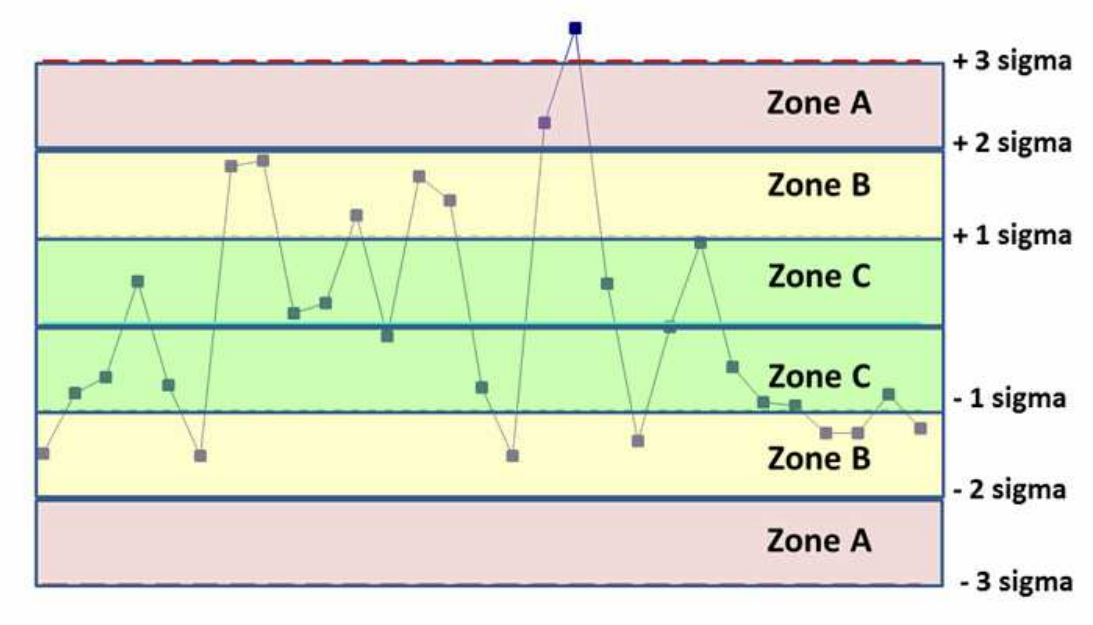

Zonas B e C: Normal (zona de maior probabilidade de ocorrências).

Zona A: Suspeita de prováveis anomalias. Atenção redobrada.

Aplicação em Controle de Processos

- A aplicação desta regra de detecção de anomalias é muito usado na indústria. Neste caso, ela é chamada de *Regra 1 de Nelson*[a], compondo a área denominada *Statistical Process Control*.
- Como já destacado, a regra 1 de Nelson exige que a variável aleatória sendo monitorada seja gaussiana. Além disso, exige que amostras sucessivas sejam descorrelacionadas; ou seja, não haja dependência estatística entre amostras sucessivas.
- Em outras palavras, se houver tendências ou padrões de natureza não-aleatória, isto também pode ser encarado como uma anomalia, mesmo que os valores estejam dentro da zona de *normalidade*.

[a] Lloyd S. Nelson (1984). "The Shewhart Control Chart-Tests for Special Causes´´. *Journal of Quality Technology*, vol. 16, no. 4, 238-239.

Regra 2 de Nelson

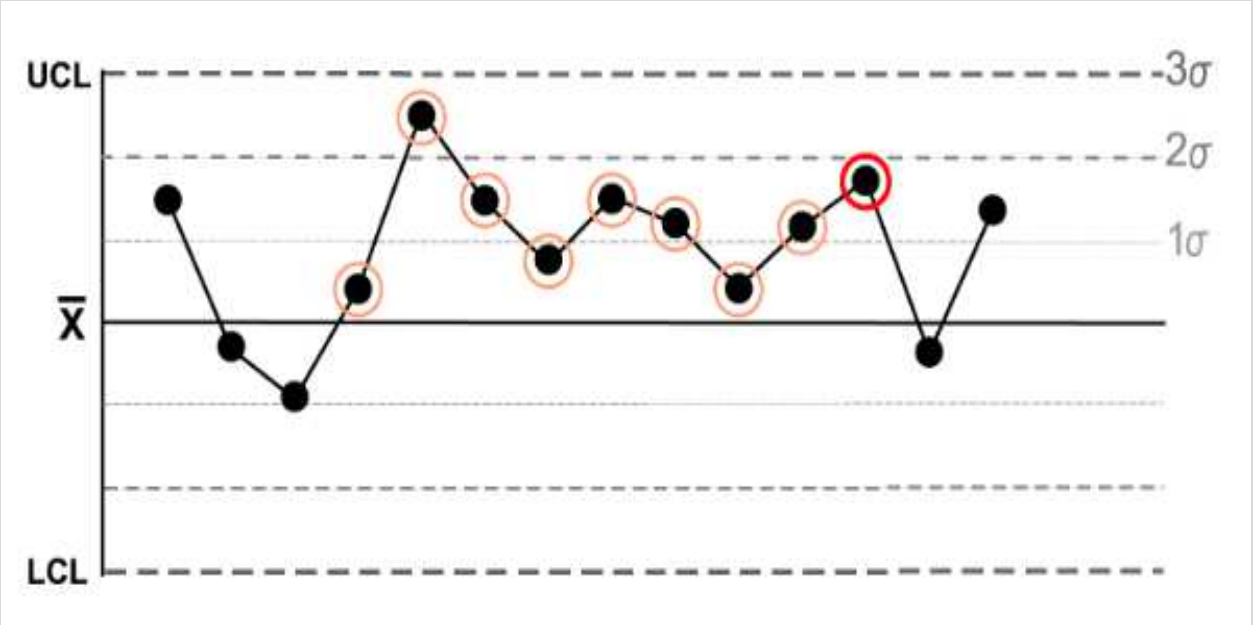

Regra 2 : Nove pontos consecutivos que residem consistentemente no mesmo lado (acima ou abaixo) da média (existe algum viés prolongado).

Regra 3 de Nelson

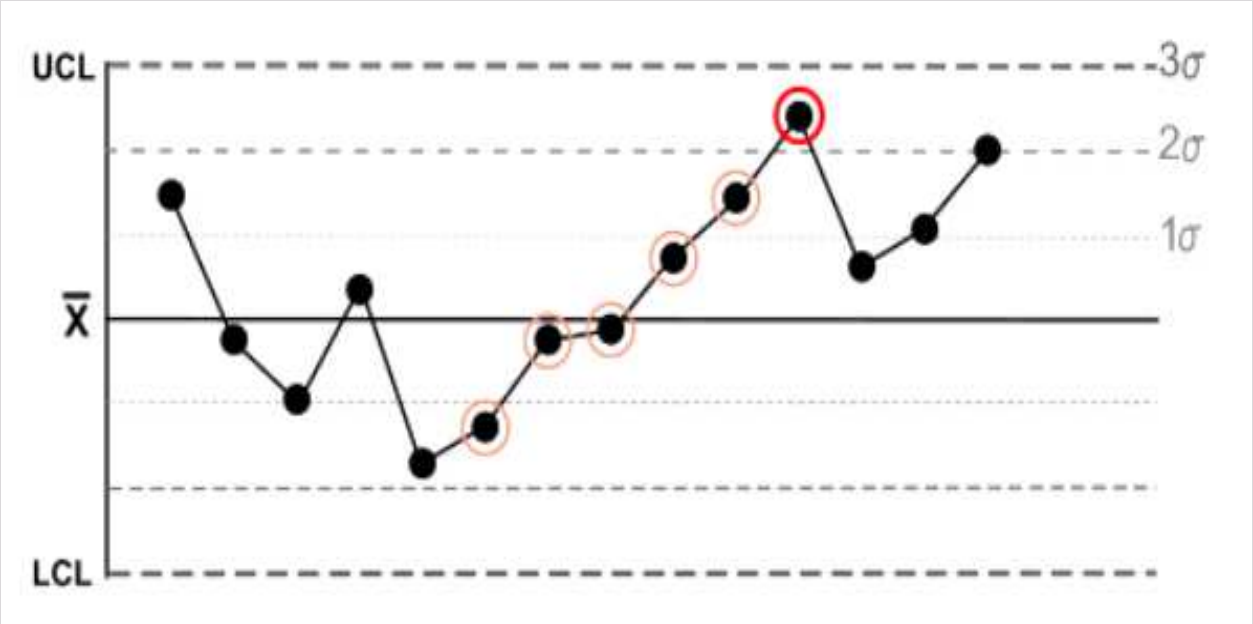

Regra 3 : Seis pontos consecutivos exibindo uma clara tendência de aumento ou diminuição (existe uma tendência).

Regra 4 de Nelson

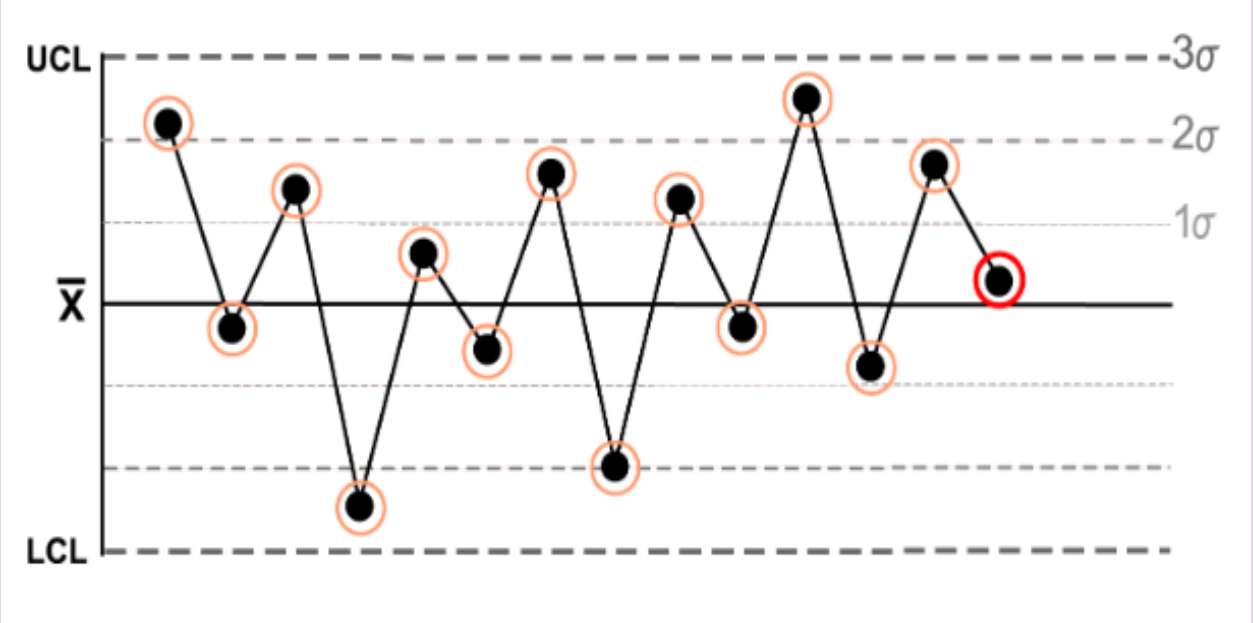

Regra 4 : Quatorze (ou mais) pontos consecutivos alternando em direção, aumentando e depois diminuindo (essa oscilação excessiva vai além do ruído).

Regra 5 de Nelson

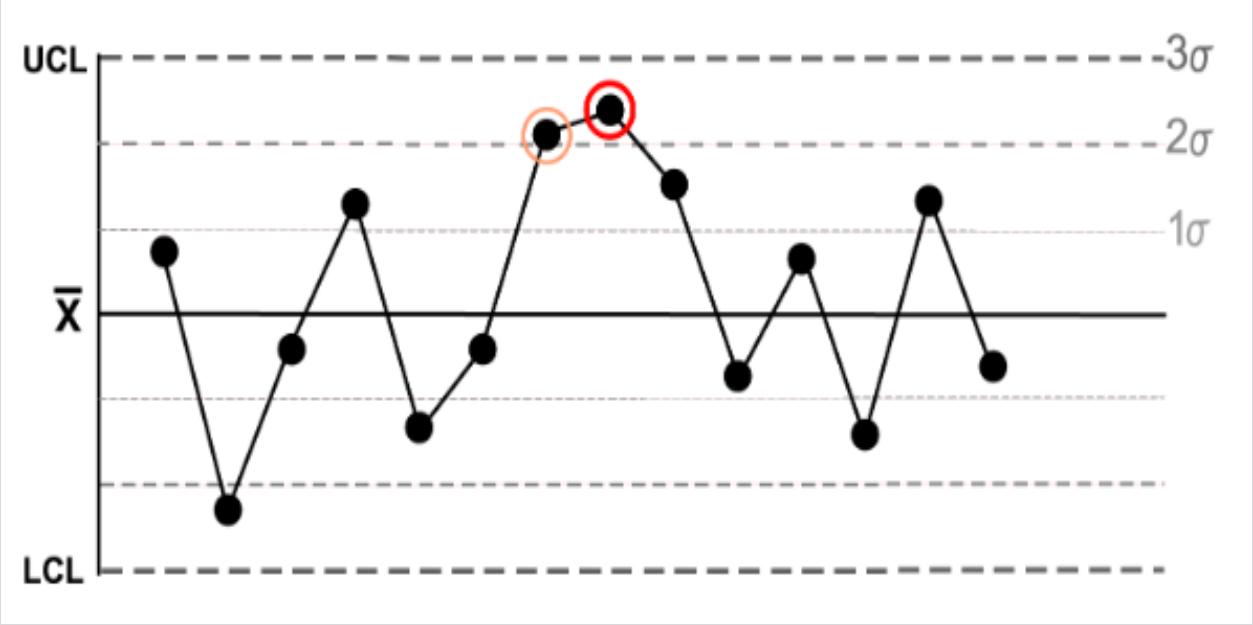

Regra 5 : Dois (ou três) de três pontos consecutivos estão a mais de 2 desvios padrão da média na mesma direção (existe uma tendência moderada de que as amostras estejam moderadamente fora de controle).

Regra 6 de Nelson

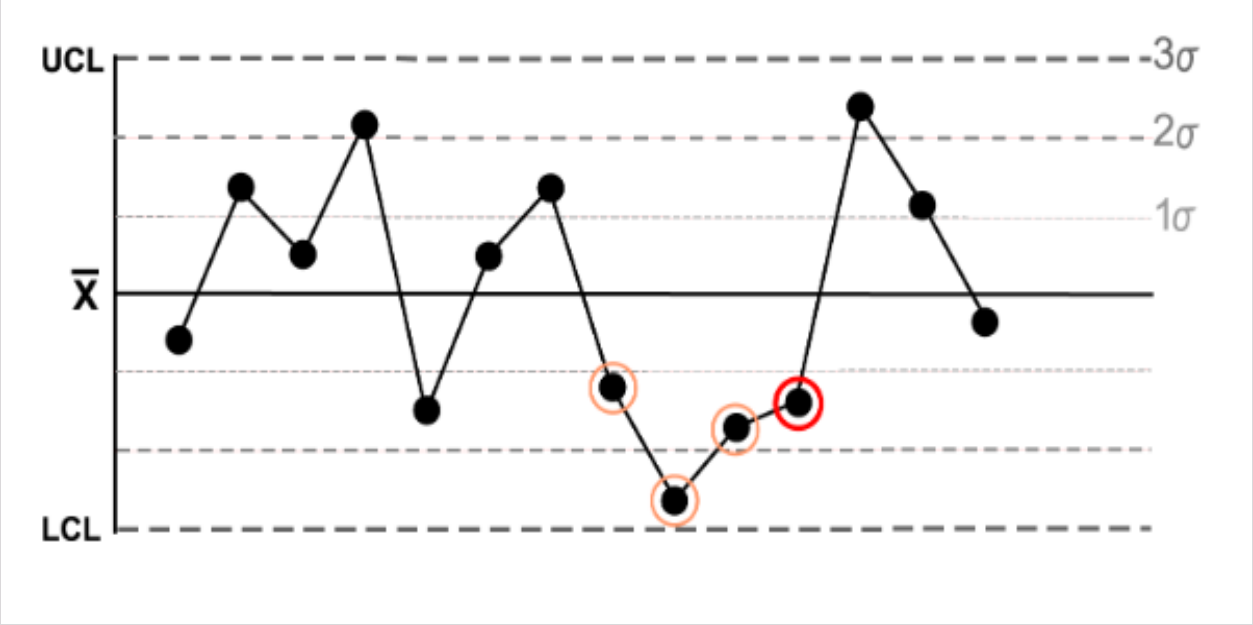

Regra 6 : Quatro (ou cinco) de cinco pontos consecutivos estão a mais de 1 desvio padrão da média na mesma direção (existe uma forte tendência para que as amostras estejam levemente fora de controle).

Regra 7 de Nelson

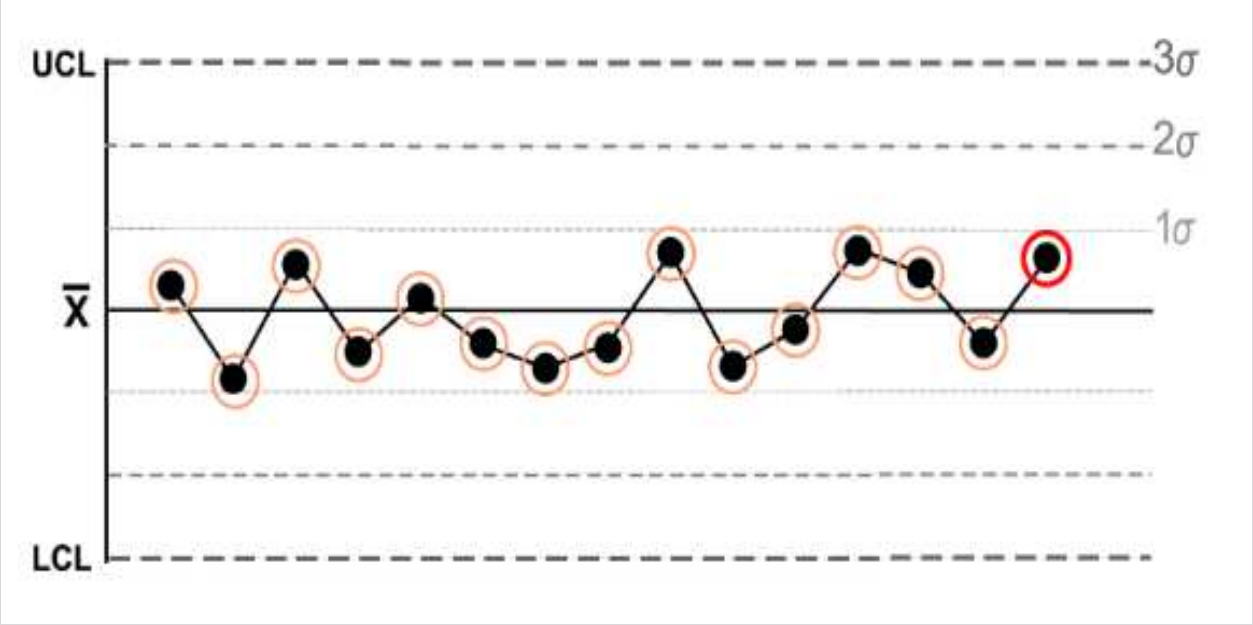

Regra 7 : Quinze pontos consecutivos estão todos dentro de 1 desvio padrão da média em ambos os lados da média (com 1 desvio padrão, uma variação maior seria esperada).

Regra 8 de Nelson

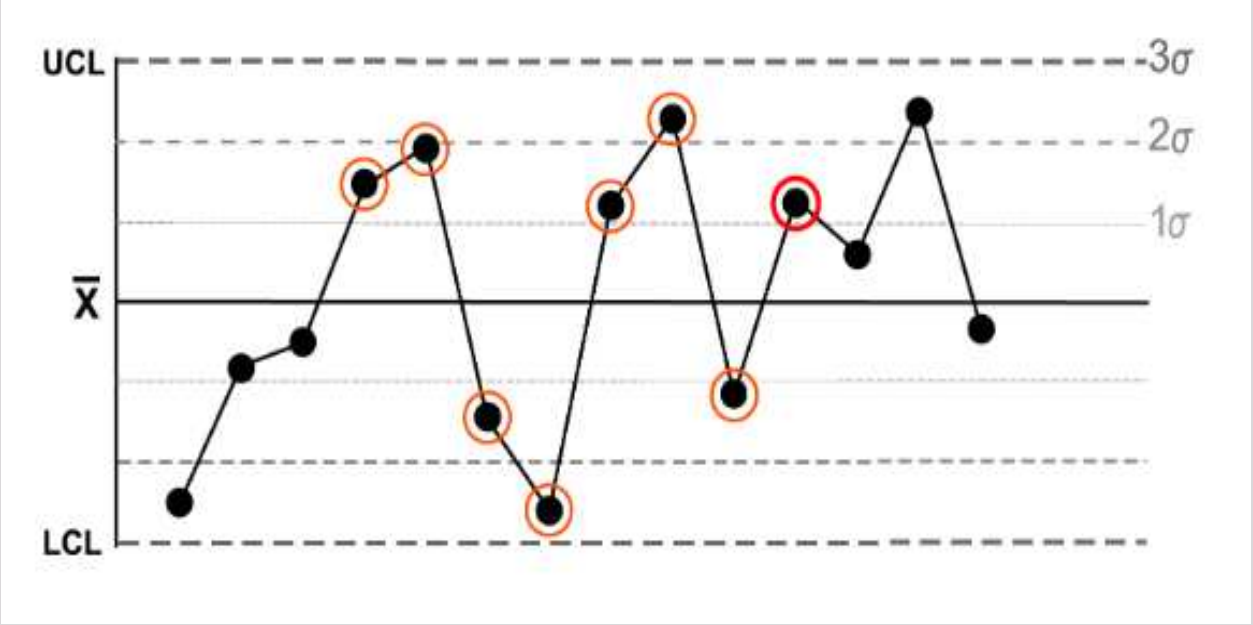

Regra 8 : Existem oito pontos consecutivos, mas nenhum dentro de 1 desvio padrão da média, e os pontos estão em ambas as direções a partir da média (saltar de cima para baixo sem atingir a primeira faixa de desvio padrão raramente é aleatório).

Transformação de Box-Cox

- Muitas variáveis não seguem uma distribuição normal.
- Porém, normalidade é uma importante suposição para muitas técnicas e métodos estatísticos.
- Nestes casos, é possível realizar uma operação, conhecida como *transformação de Box-Cox*[a], sobre a variável x_i:

$$x_i^* = \begin{cases} \frac{x_i^{\lambda}-1}{\lambda}, & \text{se } 0 < \lambda < 1. \\ \ln x_i, & \text{se } \lambda = 0. \end{cases} \tag{16}$$

- Com isso, variáveis não gaussianas terão uma distribuição com uma forma mais simétrica, mais próxima da normal.

[a] G.E.P. Box and D.R. Cox, 'An Analysis of Transformations', Journal of the Royal Statistical Society B, 26:211-252 (1964).

Exemplo da Transformação de Box-Cox

- Seja uma variável aleatória X que segue uma FDP exponencial de parâmetro $\gamma = 3$.
- No Octave, 5000 observações de X são geradas pelo seguinte comando: `>> x=exprnd(3,5000,1)`
- O histograma de X, com uma gaussiana ajustada às observações de X, é visualizada pelo seguinte comando:
  ```
  >> histfit(x)
  ```
- Aplica-se a transformação de Box-Cox às observações de X, para um expoente $\lambda = 0.2$, pela seguinte operação:
  ```
  >> lamb=0.2;
  >> xstar=(x.^lamb - 1)/lamb;
  >> figure; histfit(xstar)
  ```

Resultado da aplicação da transformação de Box-Cox

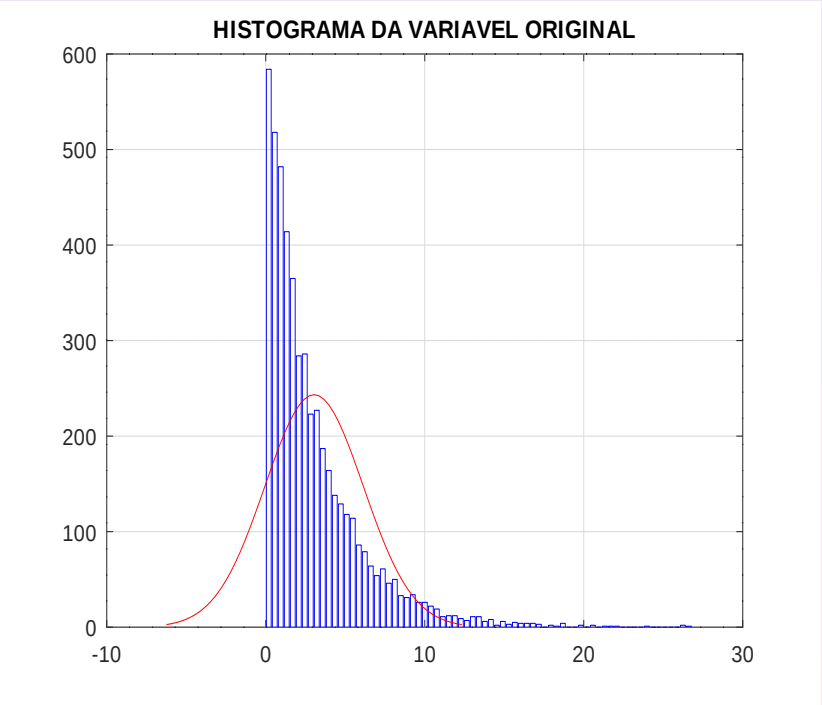

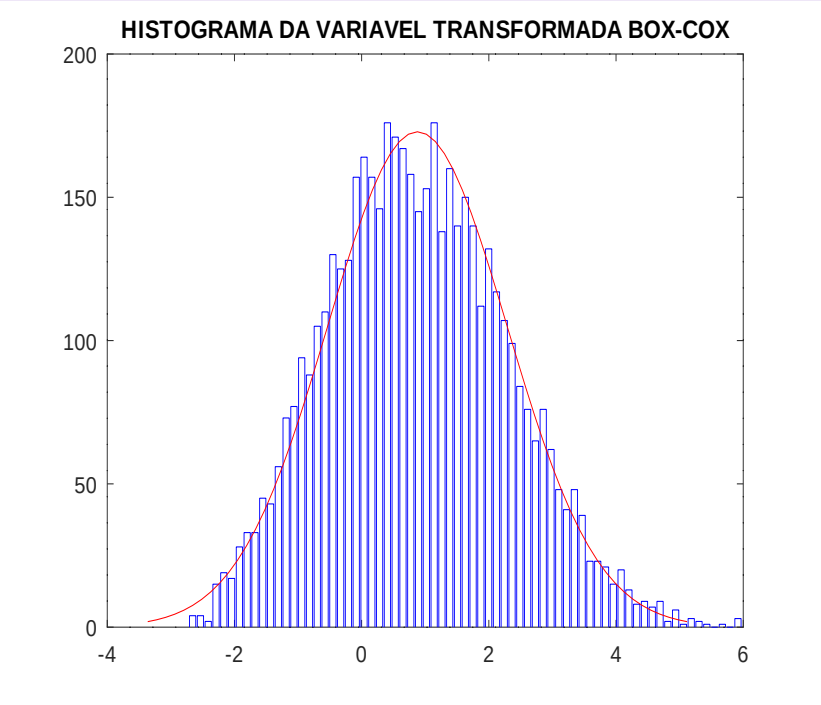

Exemplo da Transformação de Box-Cox

- Uma questão interessante que surge com a aplicação da transformação de Box-Cox é como saber se a distribuição resultante é similar o suficiente de uma gaussiana.
- Para isso, podemos usar 2 métodos. O primeiro deles é qualitativo, e se baseia numa comparação visual das curvas da função distribuição acumulada (FDA) da distribuição transformada e da gaussiana de mesma média e variância.
- O segundo é métodos é quantitativo, e se baseia na aplicação do teste de hipótese de Kolmogorov-Smirnov (HS).
- Iremos detalhar os procedimentos a seguir.

Avaliação Qualitativa da Transformação de Box-Cox

- Este procedimento compara a FDA da amostra transformada por Box-Cox e a FDA de uma amostra normalmente distribuída com mesma média e mesma variância que a amostra Box-Cox.
- A comparação das FDAs resulta mais acurada do que pela comparação dos histogramas das duas amostras.
- Em muitas aplicações, este procedimento é suficiente, uma vez que se busca uma boa aproximação e não uma confirmação da gaussianidade entre as amostras.

Avaliação Qualitativa da Transformação de Box-Cox

- Usando o vetor `xstar` com as medidas transformadas por Box-Cox, realizar as seguintes operações no Octave/Matlab:

```
>> mxstar=mean(xstar); % media das medidas em xstar
>> dpxstar=std(xstar); % desvio padrao das medidas em xstar
>> xnorm=normrnd(mxstar,dpxstar,5000,1); % N(mxstar,dpstar)
>> h1=cdfplot(xstar); % FDA empirica de xstar
>> hold on; % mantem figura para proximo plot
>> h2=cdfplot(xnorm); % FDA empirica de N(mxstar,dpstar)
```

Verificando se distribuição resultante é gaussiana comprando a sua FDA com a Normal de mesma média e variância.

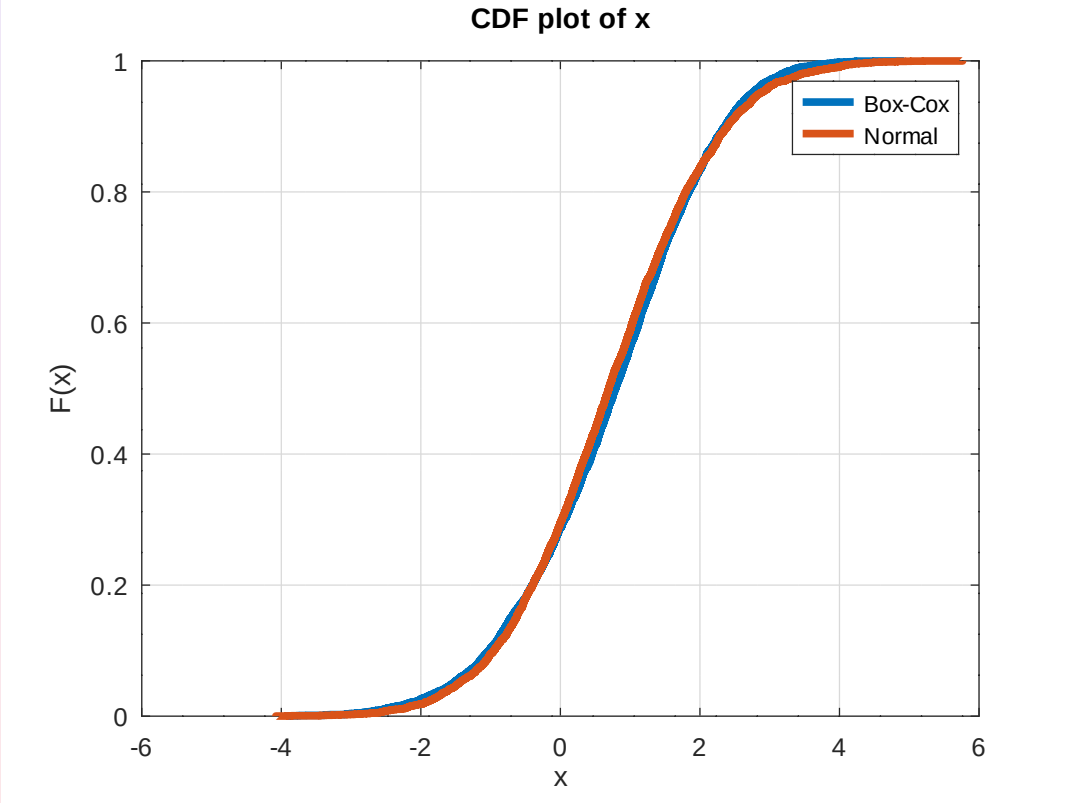

Avaliação Quantitativa da Transformação de Box-Cox

- Este procedimento também compara as FDAs da amostra transformada por Box-Cox e a de uma amostra normalmente distribuída de mesma média e variância.
- Trata-se, porém, de um procedimento mais formal por ser um teste de hipóteses. Para isso, calcula-se uma estatística de teste baseada na maior distância vertical entre as duas FDAs comparando-a com o valor-p, para um certo nível de significância α.
- Este procedimento é mais rigoroso que a simples inspeção visual, uma vez que busca confirmar $(H = 0)$ ou não $(H = 1)$ a gaussianidade entre as amostras.
- Em *Python*: `scipy.stats.kstest`

Avaliação Quantitativa da Transformação de Box-Cox

- Usando o vetor `xstar` com as medidas transformadas por Box-Cox, realizar as seguintes operações no Octave/Matlab:

```
>> mxstar=mean(xstar); % media das medidas em xstar
>> dpxstar=std(xstar); % desvio padrao das medidas em xstar
>> xnorm=normrnd(mxstar,dpxstar,5000,1); % N(mxstar,dpstar)
>> H=kstest2(xstar,xnorm); % Teste Kolmogorov-Smirnov
H=1
```

Comentário: Pelo resultado acima a distribuição da amostra transformada por Box-Cox não pode ser considerada como sendo compatível com uma gaussiana.

FDP Gaussiana Padronizada

- Após a aplicação da transformação de Box-Cox, é usual fazer com que o conjunto de medidas possua $\mu = 0$ e $\sigma^2 = 1$.
- Esta propriedade pode ser imposta a qualquer conjunto de medidas, através da seguinte transformação:

$$z_i = \frac{x_i - \mu}{\sigma}, \qquad i = 1, 2, \ldots, N. \tag{17}$$

- Para voltar para aos valores originais, aplica-se a seguinte transformação inversa:

$$x_i = \sigma z_i + \mu, \qquad i = 1, 2, \ldots, N. \tag{18}$$

- Para o caso de variáveis gaussianas, a nova FDP é chamada de *gaussiana padronizada*, sendo denotada por $Z \sim N(0, 1)$.

Gráfico da FDP Gaussiana de Média=0 e Variância=1

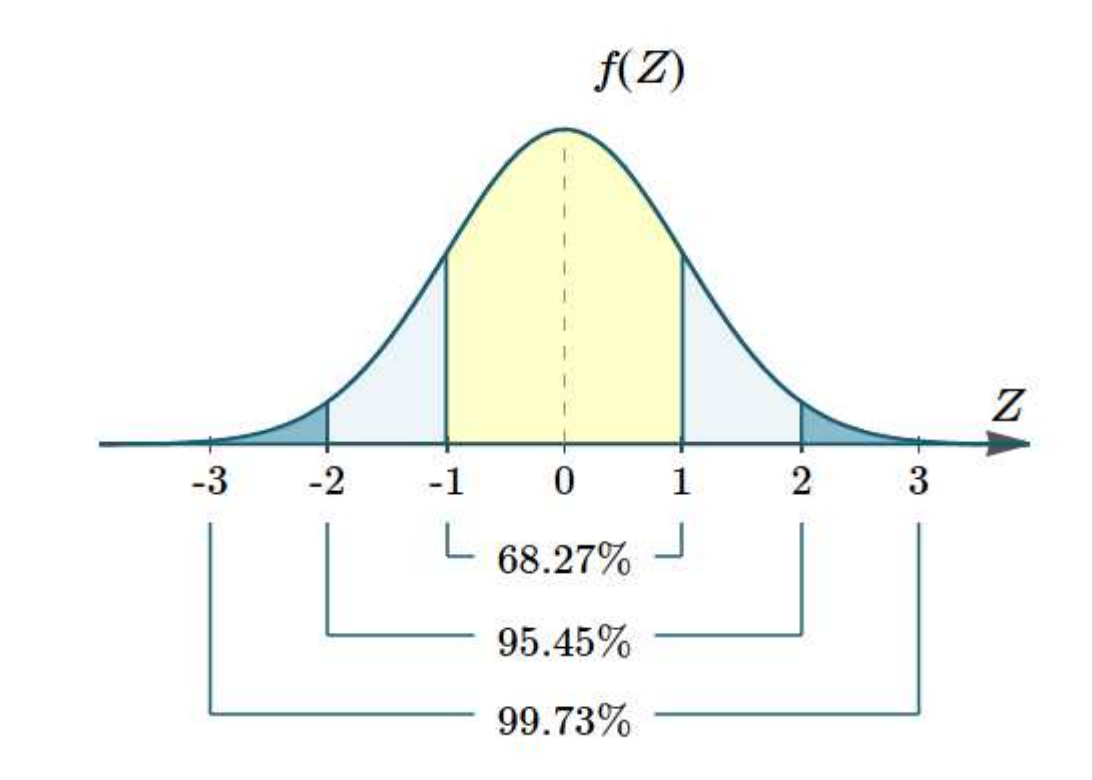

Entendendo a FDP Gaussiana Padronizada

- Com base no gráfico anterior da FDP gaussiana padronizada temos que:
  1. 68% dos valores de Z estarão no intervalo $[-1, +1]$.

     $$\Pr(-1 \leq Z \leq +1) \approx 0{,}68$$

  2. 95% dos valores de Z estarão no intervalo $[-2, +2]$.

     $$\Pr(-2 \leq Z \leq +2) \approx 0{,}95$$

  3. 99% dos valores de Z estarão no intervalo $[-3, +3]$.

     $$\Pr(-3 \leq Z \leq +3) \approx 0{,}99$$

- Esta propriedade da FDP gaussiana padronizada é usada para detecção de observações atípicas ou anômalas.

Aplicação em Detecção de Anormalidades em Processos

- Suponha que estejamos monitorando (medindo e armazenando) uma grandeza física X que representa o estado de um processo industrial.
- Se há razões para assumir que $X \sim N(\mu, \sigma^2)$, então podemos usar a seguinte regra de decisão:

$$\begin{array}{ll} \text{SE} & Z = \frac{X-\mu}{\sigma} \notin [-3, +3], \\ \text{ENTÃO} & X \text{ é um estado anormal.} \end{array}$$

- No caso de detectar alguma anormalidade, o operador deve ser avisado.

Gerando e Visualizando VAs Gaussianas no Octave/Matlab

- Os comandos abaixo geram e visualizam um conjunto de observações de uma variável contínua gaussiana de média $\mu = 10$ e variância $\sigma^2 = 2$.

```
>> mi=10; vari=2; % parametros da distribuicao
>> N=5000; % No.  de observacoes desejadas
>> X=normrnd(mi,sqrt(vari),N,1); % VAs gaussianas
>> X=mi+sqrt(vari)*randn(N,1); % (alternativa)
>> mi=mean(X); % media amostral
  mi = 9.9907
>> s2=var(X,1); % variancia amostral
  s2 = 1.9932
>> histfit(X,20); % histograma de X
```

Calculando Probabilidades Usando FDA Gaussiana

- Softwares como Matlab/Octave/Scilab/Excel possuem comandos que determinam facilmente o valor de $F_X(x)$ para qualquer valor de x.
- Por exemplo, suponha que $X \sim N(100, 4)$ e que queremos estimar a probabilidade de que X seja menor que ou igual a 104; isto é, $P(X \leq 104) = F_X(104)$.
- **Matlab/Octave**: `>> P=normcdf(104,100,sqrt(4));`
- **Python**:

```
import math
from scipy.stats import norm
P = norm.cdf(104, loc=100, scale=math.sqrt(4))
print(f"P(X < 104) = P")
```

Gerando Números (Pseudo)Aleatórios Gaussianos

- Vamos agora abordar o problema de determinar valores de $F_X(x)$ sob uma perspectiva diferente.
- Suponha que temos um conjunto de N medidas de uma certa variável X, ou seja, $\mathcal{X} = \{X(1), X(2), X(3), \ldots, X(N)\}$.
- Vamos gerar artificialmente $N = 5000$ medidas de uma variável aleatória $X \sim N(100, 4)$.
- **Matlab/Octave**: `>> X=normrnd(100,sqrt(4),5000,1);`
- **Python**:

```
import math
from scipy.stats import norm
P = norm.rvs(104, loc=100, scale=math.sqrt(4),
size=5000)
```

Estimando Probabilidades - Método 1

- De posse do conjuntos de medidas $\mathcal{X}$, vamos determinar $F_X(104) = P(X \leq 104)$ de duas maneiras diferentes.
- **Método 1**: Consiste simplemente em contar quantos elementos do conjunto $\mathcal{X}$ são menores que ou iguais a 104.
- Em Matlab/Octave e Python, usamos os seguintes comandos:

  Matlab/Octave: `>> P=length(find(X<=104))/5000;`
  Python: `P = len(X[X <= 104])/5000`

Estimando Probabilidades - Método 2

- **Método 2**: Consiste em determinar o valor buscado diretamente no gráfico da FDA empírica do conjunto $\mathcal{X}$.

- No Matlab/Octave usamos o seguinte comando para gerar a FDA empírica: `>> cdfplot(X);`

- **Em Python**:

```
import seaborn as sns
sns.ecdfplot(p)
plt.xlabel('Valores')
plt.ylabel('Frequência Cumulativa')
plt.title('Gráfico da FDC (ECDF) com Seaborn')
plt.show()
```

Estimando Probabilidades - Método 2 (cont.)

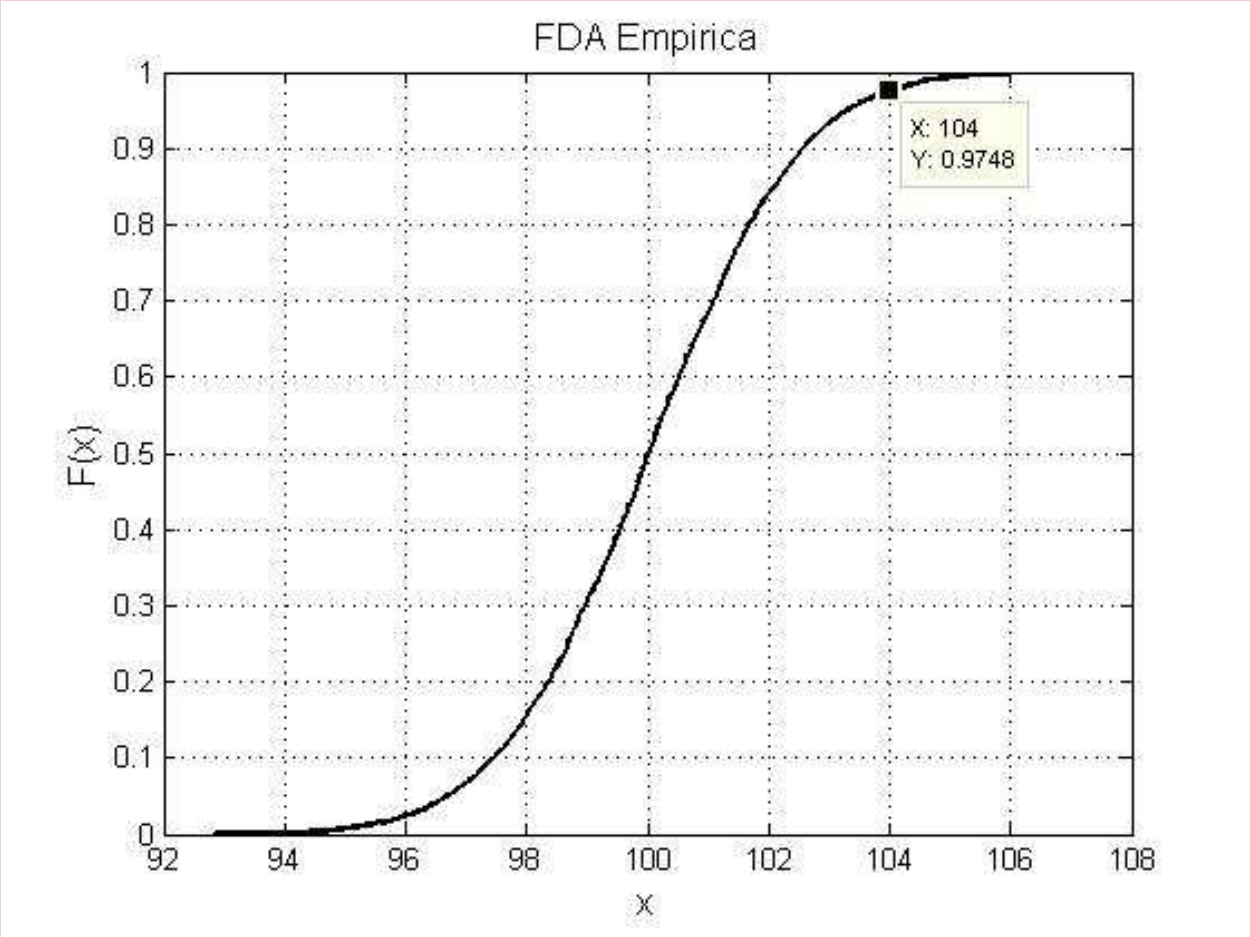

Estimando Probabilidades - Método 3

- **Método 3**: Trata-se, na verdade, do Método 1 implementado como uma função do Octave.
- Neste caso usamos o comando:

```
>> P=empirical_cdf(104,X);
```

Entendendo o Histograma

Passo 1 - Calcular a média ($\bar{x}$) e a desvio padrão (s) amostrais de X.

Passo 2 - Definir o domínio de X: $[\bar{x} - k \cdot s, \bar{x} + k \cdot s]$ (e.g. $k = 5$).

Passo 3 - Discretizar o domínio de X em $M + 1$ pontos x_i, $i = 0, 1, \ldots, M$.

Passo 4 - Para cada intervalo $\Delta x_i = x_i - x_{i-1}$, $i = 1, \ldots, M$, determinar:

$$\boxed{C(\Delta x_i) = \text{No. de observações de } X \in \Delta x_i}$$

Passo 5 - Desenhar o gráfico de barras $C(\Delta x_i) \times \Delta x_i$.

Gráfico da FDP Empírica (Histograma)

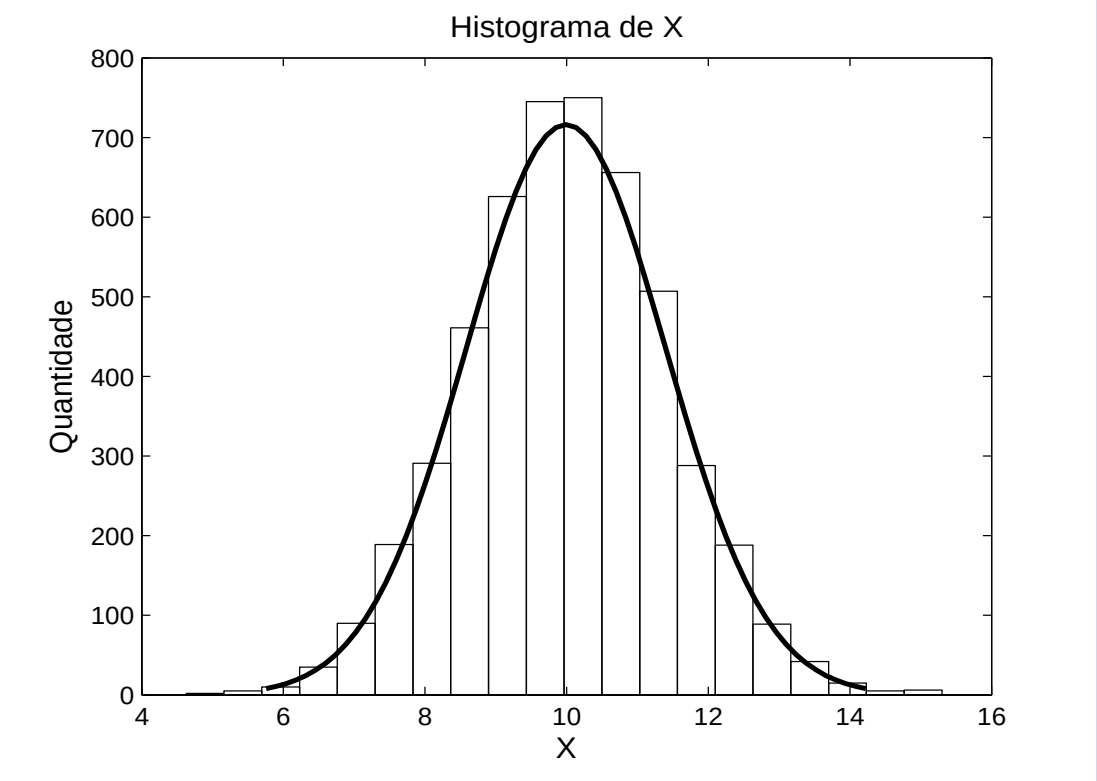

Entendendo a FDA Empírica

Passo 1 - Ordenar em ordem crescente os valores observados da variável aleatória X.

Passo 2 - Para cada valor x_i na lista (ou vetor) ordenado, calcular a quantidade de medidas menores ou iguais a x_i; ou seja: $N_i = \#(X <= x_i)$.

Passo 3 - Calcular a frequência acumulada dos pontos menores que ou iguais a x_i; ou seja: $P_i = N_i/N$.

Passo 5 - Fazer o gráfico de $P_i \times x_i$.

Código FDA Empírica no Octave/Matlab

```
>> mi=5; vari=2; % parametros da distribuicao
>> N=5000; % No.  de observacoes desejadas
>> X=mi+sqrt(vari)*randn(N,1); % (alternativa)
>> Xsorted=sorted(X); % ordena medidas
>> y = 1:length(Xsorted); % cria grid
>> y = y/length(Xsorted); % Calcula frequencias
>> plot(Xsorted,y,'r-','linewidth',3);
>> xlabel('Variavel aleatoria (X)');
>> ylabel('FDA de X'); grid
```

Código FDA Empírica no Python

```
import matplotlib.pyplot as plt
import numpy as np
Xsorted = np.sort(X)
y = np.arange(1, len(Xsorted) + 1) / len(Xsorted)
plt.plot(Xsorted, y, linewidth=2)
plt.title('FDA Empirica')
plt.xlabel('Variavel aleatoria (X)')
plt.ylabel('FDA de X')
plt.grid(True)
plt.show()
```
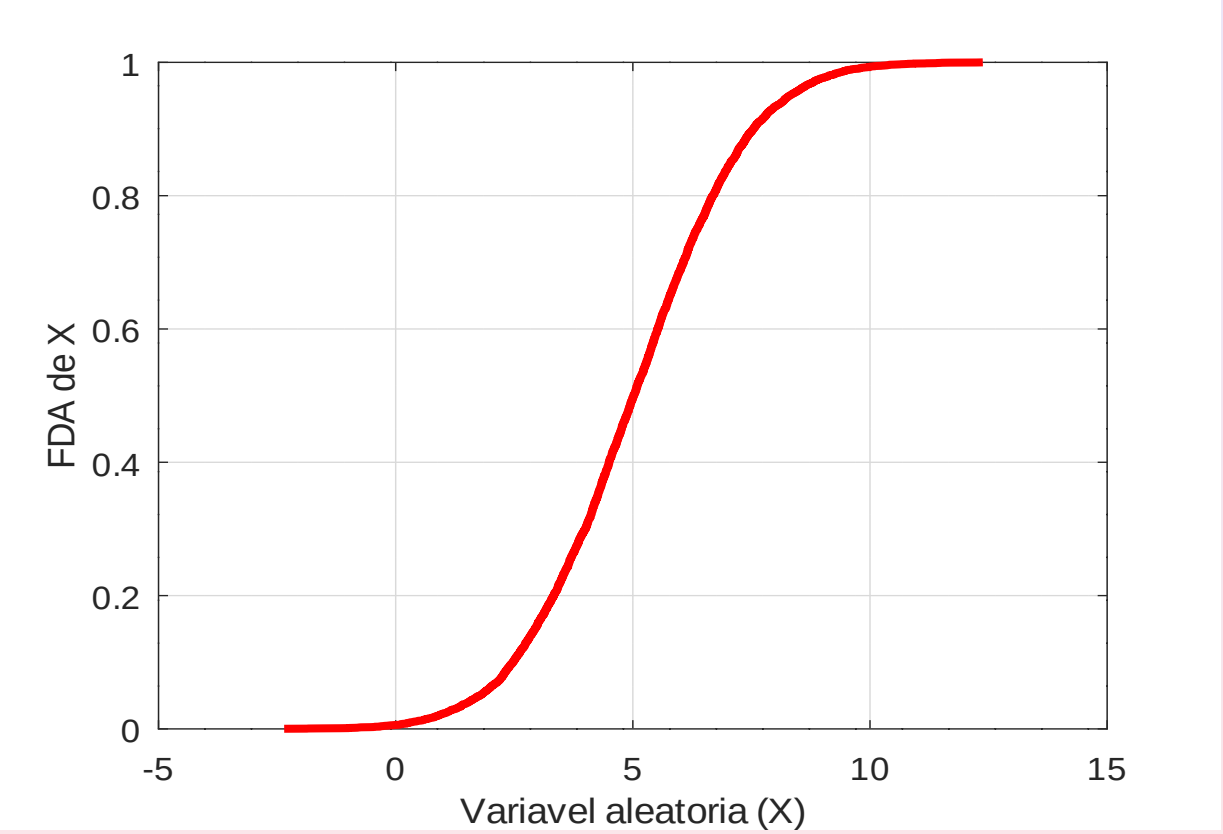
Gráfico resultante da FDA Empírica